



上海交通大学学位论文

复杂城市作战环境下大规模无人机集群
通信保持任务规划研究

姓 名：xxx

学 号：xxx

导 师：xxx

院 系：集成电路学院

学科/专业：电子与通信工程

学位类型：专业型

申请学位：工学硕士

2026 年 4 月

A Dissertation Submitted to
Shanghai Jiao Tong University for Master Degree

**CONNECTIVITY-PRESERVING MISSION
PLANNING FOR LARGE-SCALE UAV SWARMS
IN COMPLEX URBAN COMBAT
ENVIRONMENTS**

Author: xxx

Supervisor: xxx

School of Integrated Circuits
Shanghai Jiao Tong University
Shanghai, P.R.China

April 28th, 2026

上海交通大学

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

日期： 年 月 日

上海交通大学

学位论文使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。

本学位论文属于 ☐ 公开论文

☐ 内部论文，☐1 年/☐2 年/☐3 年 解密后适用本授权书。

☐ 秘密论文，____ 年（不超过 10 年）解密后适用本授权书。

☐ 机密论文，____ 年（不超过 20 年）解密后适用本授权书。

（请在以上方框内打“√”）

学位论文作者签名：

日期： 年 月 日

指导教师签名：

日期： 年 月 日

摘 要

在现代作战样式持续演进的背景下,大规模无人机集群凭借强机动性、动态组网与高效协同等优势,已成为城市作战场景中的重要力量。然而,不同于开阔作战场景,城市作战环境具有建筑物密集以及电磁环境复杂等特点,不仅加剧了无人机运动与感知的不确定性,更导致集群的通信链路面临严重的衰减与中断风险。在此场景下,现有侧重于路径最优性或覆盖效率的任务规划研究,由于缺乏对动态复杂通信拓扑的显式建模约束,在应对大规模集群协同任务时容易面临效率低下以及陷入局部最优的情况,难以有效满足智能无人机集群网络对通信的基本需求。为此,本文面向复杂城市作战环境下大规模无人机集群协同任务规划问题,针对集群通信保持路径规划与区域覆盖侦察部署两个核心任务,开展了基于现有路径规划算法与多目标优化算法的研究。本文的主要研究工作包括:

针对大规模无人机集群在复杂城市环境下通信保持路径规划问题,提出了一种基于分层分簇的通信保持快速扩展随机树人工势场(Clustered Rapidly-exploring Random Tree*-Artificial Potential Field, C-RRT*-APF)路径规划算法。考虑到无人机集群在运动过程中面临的密集建筑物和严重电磁干扰等约束,该算法在全局规划阶段采用 RRT* 算法为各簇搜索可行全局路径,并引入基于簇间距离的全局路径约束机制,在确保路径可行性与最优性的同时为跨簇通信连通提供基础;在局部规划阶段,提出一种基于最大信干噪比(Signal-to-Interference-plus-Noise Ratio, SINR)瓶颈生成树的通信保持人工势场法(Maximum-Bottleneck- Spanning-Tree-based Artificial Potential Field, MBST-APF),通过仅对关键通信瓶颈链路构建势场约束,相较于传统方法显著降低了势场复杂度。仿真实验表明,在所提典型场景下该算法相较于通信保持无人机编队控制(Connectivity-Maintenance UAV Formation Control, CMUFC)算法平均到达时间降低 29%,通信连通率提高 17%,证明该算法不仅能有效实现规避密集障碍的路径规划,更能显著提升复杂电磁环境下集群的通信保持效果。

针对大规模无人机集群在复杂城市环境下区域覆盖侦察部署问题,提出了一种基于多种群引导的改进非支配排序遗传算法(Multi-Population Guided Non-dominated Sorting Genetic Algorithm II, MPG-NSGA-II)的通信保持区域覆盖算法。考虑到建筑物遮挡与电磁干扰带来的覆盖与通信约束,该算法在 NSGA-II 基础上,结合领域知识设计了两种局部引导变异算子:Voronoi 覆盖引导算子(Voronoi Coverage Guided Operator, VCGO)通

过计算每个无人机节点在当前分布下的最近责任区域质心以确定变异方向，从而有效提升覆盖性能；节点度连通引导算子（Degree Connectivity Guided Operator, DCGO）通过识别低度数节点引导其向链路修复位置定向变异以增强网络连通性能。最后通过多种群岛模型精英迁移策略动态实现所提变异子种群的协同进化。仿真实验表明，在所提典型场景下，该算法相较于传统 NSGA-II 算法在各个顶点连通度目标下覆盖率平均提升约 7%，并且在多参数场景均能在更少节点下实现区域的全覆盖目标，证明该机制有效平衡了算法的全局探索与局部开发能力，在同等网络连通性能下实现了更高的区域覆盖率，提高了网络抗损毁性能。

综上所述，本文针对复杂城市作战环境下大规模无人机集群协同任务规划问题，实现了在强电磁干扰与密集建筑环境下的高通信保持效果，对提升城市作战场景下无人机集群的协同任务能力具有重要的工程应用价值，也为未来智能化无人机网络的组网提供了扎实的理论与方法支撑。

关键词：无人机集群，连通保持，路径规划，区域覆盖，多目标优化

ABSTRACT

With the continuous evolution of modern warfare, large-scale Unmanned Aerial Vehicle (UAV) swarms have emerged as a significant force in urban combat scenarios, by virtue of their high maneuverability, dynamic networking, and efficient coordination. However, unlike open-field combat scenarios, urban combat environments are characterized by dense buildings and complex electromagnetic conditions, which not only exacerbate the uncertainty of UAV motion and perception, but also expose the swarm's communication links to severe attenuation and interruption risks. Under such circumstances, existing task planning studies that primarily emphasize path optimality or coverage efficiency are prone to low computational efficiency and local optima when addressing large-scale swarm coordination, owing to the lack of explicit modeling constraints for dynamic and complex communication topologies, thereby failing to effectively satisfy the fundamental communication requirements of intelligent UAV swarm networks. To this end, this thesis investigates the collaborative task planning problem of large-scale UAV swarms in complex urban combat environments, with a focus on two core tasks: connectivity-preserving path planning and area coverage reconnaissance deployment, by improving path planning algorithms and multi-objective optimization algorithms. The main research contributions of this thesis are as follows:

To address the connectivity-preserving path planning problem of large-scale UAV swarms in complex urban environments, a Clustered Rapidly-exploring Random Tree*-Artificial Potential Field (C-RRT*-APF) path planning algorithm based on hierarchical clustering is proposed. Considering the constraints of dense buildings and severe electromagnetic interference encountered during swarm movement, the algorithm employs the RRT* algorithm in the global planning stage to search for feasible global paths for each cluster, and introduces a global path constraint mechanism based on inter-cluster distance, which provides a foundation for cross-cluster communication connectivity while ensuring path feasibility and optimality. In the local planning stage, an Artificial Potential Field method based on the Maximum-Bottleneck-Spanning-Tree (MBST-APF) of the Signal-to-Interference-plus-Noise Ratio (SINR) is proposed, which effectively reduces the potential field complexity of traditional methods by constructing potential field constraints exclusively on critical communication bottleneck links. Simulation experiments demonstrate that, under the proposed typical scenarios, the average arrival time of the proposed algorithm is reduced by 29% and the communication connectivity rate is increased by 17% compared with the Connectivity-Maintenance UAV Formation Control (CMUFC) algorithm, indicating that the proposed algorithm can not only effectively achieve

path planning for dense obstacle avoidance, but also significantly enhance the connectivity-preserving performance of the swarm in complex electromagnetic environments.

To address the area coverage reconnaissance deployment problem of large-scale UAV swarms in complex urban environments, a connectivity-preserving area coverage algorithm based on the Multi-Population Guided Non-dominated Sorting Genetic Algorithm II (MPG-NSGA-II) is proposed. Considering the constraints imposed on coverage and communication by building occlusions and electromagnetic interference, the algorithm designs two local guided mutation operators on the basis of NSGA-II, incorporating domain knowledge: the Voronoi Coverage Guided Operator (VCGO) improves coverage performance by calculating the nearest responsible region centroid of each UAV node under the current distribution to determine the mutation direction; the Degree Connectivity Guided Operator (DCGO) enhances network connectivity by identifying low-degree nodes and directing their mutation towards link repair locations. An elite migration strategy based on the multi-population island model is subsequently adopted to dynamically achieve the co-evolution of the proposed mutated sub-populations. Simulation experiments demonstrate that, under the proposed typical scenarios, the proposed algorithm achieves an average coverage rate improvement of approximately 7% across various vertex connectivity objectives compared with the conventional NSGA-II algorithm, and is capable of achieving full area coverage with fewer nodes across multi-parameter scenarios. These results indicate that the proposed mechanism effectively balances the global exploration and local exploitation capabilities of the algorithm, achieving a higher area coverage rate under identical network connectivity performance while improving network resilience.

In summary, targeting the collaborative task planning problem of large-scale UAV swarms in complex urban combat environments, the methods proposed in this thesis achieve high connectivity-preserving performance under strong electromagnetic interference and dense building environments. The proposed approaches hold significant engineering application value for enhancing the collaborative task capabilities of UAV swarms in urban combat scenarios, and also provide solid theoretical and methodological support for the networking of future intelligent UAV networks.

Key words: UAV swarms, connectivity preservation, path planning, area coverage, multi-objective optimization

目 录

摘 要	I
ABSTRACT	III
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	4
1.2.1 无人机集群路径规划研究现状	4
1.2.2 无人机集群区域覆盖研究现状	6
1.3 主要研究内容	10
1.4 论文结构安排	11
第二章 集群协同规划与连通理论基础	13
2.1 引言	13
2.2 多智能体路径规划方法	14
2.2.1 RRT*算法	14
2.2.2 人工势场法	17
2.3 多目标优化理论	18
2.3.1 多目标优化基础	19
2.3.2 NSGA-II 算法	20
2.4 集群网络连通性理论	23
2.4.1 最大瓶颈生成树和 Kruskal 算法	23
2.4.2 图拉普拉斯矩阵与连通理论	24
2.5 本章小结	25
第三章 基于分层分簇的通信保持路径规划算法	26

3.1 引言	26
3.2 系统模型	27
3.2.1 场景模型	27
3.2.2 通信模型	29
3.3 分层分簇规划算法	30
3.3.1 分层分簇规划总体架构	30
3.3.2 簇间距离约束的 C-RRT* 全局路径规划	31
3.3.3 最大瓶颈生成树引导的 MBST-APF 局部路径规划	39
3.4 仿真实验与结果分析	43
3.4.1 仿真实验设置	44
3.4.2 仿真结果分析	46
3.5 本章小结	58
第四章 基于多种群引导协同进化的通信保持区域覆盖算法	59
4.1 引言	59
4.2 系统模型	60
4.2.1 场景模型	60
4.2.2 优化问题	61
4.3 多种群引导协同进化算法	63
4.3.1 多种群引导协同进化总体架构	63
4.3.2 种群多样性初始化方法	64
4.3.3 局部引导变异算子	67
4.3.4 多种群精英迁移机制	71
4.4 仿真实验与结果分析	73
4.4.1 仿真实验设置	73
4.4.2 仿真结果分析	74
4.5 本章小结	89
第五章 总结与展望	90

5.1 全文总结	90
5.2 不足与展望	91
参 考 文 献.....	92
攻读学位期间学术论文和科研成果目录	98

图 录

图 1-1 无人机集群城市作战场景示意图.....	1
图 1-2 智能无人机集群作战网络架构示意图.....	3
图 1-3 多智能体通信保持路径规划算法分类.....	5
图 1-4 区域覆盖部署问题算法分类.....	8
图 2-1 RRT 规划过程.....	15
图 2-2 RRT*关键机制.....	16
图 2-3 人工势场法示意图.....	18
图 2-4 NSGA-II 算法流程图.....	21
图 2-5 支配等级与拥挤距离.....	22
图 2-6 最大瓶颈生成树.....	24
图 3-1 城市作战场景集群路径规划示意图.....	28
图 3-2 C-RRT*-APF 算法框架示意图.....	30
图 3-3 单簇全局路径搜索示意图.....	33
图 3-4 簇间距离约束示意图.....	35
图 3-5 感知驱动重规划机制.....	37
图 3-6 Kruskal 算法构建通信骨干网络.....	40
图 3-7 MBST-APF 局部规划示意图.....	41
图 3-8 典型场景路径规划过程轨迹图.....	47
图 3-9 C-RRT*-APF 算法路径规划.....	48
图 3-10 到达无人机数量时序图.....	49
图 3-11 平均节点度时序图.....	50
图 3-12 最大连通分量时序图.....	51
图 3-13 不同算法指标分布.....	52
图 3-14 不同参数规模下算法指标对比.....	54
图 3-15 不同干扰功率平均到达时间对比.....	55
图 3-16 不同干扰功率通信连通率对比.....	56
图 3-17 不同干扰功率代数连通度对比.....	56
图 4-1 城市作战场景集群区域覆盖示意图.....	61

图 4-2 MPG-NSGA-II 算法总体架构.....	64
图 4-3 Voronoi 覆盖引导算子原理示意图.....	68
图 4-4 节点度连通引导算子原理示意图.....	69
图 4-5 多种群精英迁移机制示意图.....	72
图 4-6 代数= 200 时覆盖引导变异机制图	75
图 4-7 代数= 200 时连通导向变异机制图	76
图 4-8 代数= 200 时多项式变异机制图	77
图 4-9 15 节点场景下解集和迭代效果对比.....	78
图 4-10 20 节点场景下解集和迭代效果对比.....	79
图 4-11 25 节点场景下解集和迭代效果对比.....	80
图 4-12 不同节点数量下顶点连通度与覆盖性能分析.....	83
图 4-13 不同节点数目下网络顶点连通度和覆盖性能分析.....	84
图 4-14 不同顶点连通度下部署方案.....	85
图 4-15 高建筑密度场景算法对比.....	87
图 4-16 强干扰场景算法对比.....	88
图 4-17 大规模场景算法对比.....	89

表 录

表 3-1 路径规划仿真参数设置.....	45
表 3-2 典型场景下的消融实验对比.....	57
表 4-1 区域覆盖仿真参数设置.....	73
表 4-2 NSGA-II 和 MPG-NSGA-II 算法参数设置.....	74
表 4-3 不同节点规模下性能指标对比.....	80

第一章 绪论

1.1 研究背景与意义

在现代作战样式持续演进的背景下，无人机（Unmanned Aerial Vehicle, UAV）凭借其强机动性、动态组网和高效协同等优势，已成为军事行动中的重要作战力量，其应用规模与作战频次不断提升^[1-3]。如图 1-1 所示，随着作战任务复杂化与体系化需求的增强，无人机的作战职能已由早期以单平台执行侦察或精确打击为主，逐步向多平台协同、功能互补的集群化作战模式演进^[4-6]。相较于单体无人机作战方式，多无人机集群式协同能够通过任务分解与信息共享实现并行作业，在提升任务执行效率的同时显著增强系统的鲁棒性、抗干扰能力与抗损毁能力，已成为当前智能化作战的重要发展方向^[7, 8]。

在多种典型作战环境中，城市作战场景对无人机集群协同能力提出了更为严苛的要求^[9]。相较于海面、荒漠或高空等相对开阔、环境结构简单的作战区域，城市环境具有建筑物密集、空间尺度受限、遮挡与多径效应显著以及电磁环境高度复杂等特点^[10]。这些因素不仅加剧了无人机机动与感知的不确定性，也使集群内部的通信保持、协同决策与碰撞避免面临更高难度，从而显著提升了集群协同控制与任务规划问题的复杂性。



图1-1 无人机集群城市作战场景示意图

Fig. 1-1 Schematic diagram of UAV swarms in urban combat scenarios

在此特定场景下，城市作战中的无人机集群通常需要执行包括对关键区域的持续监视与覆盖^[11, 12]、协同路径规划避障^[13, 14]、对高价值目标的识别与动态跟踪^[15-17]、协同火力或打击支援^[18, 19]以及作为空中节点构建临时通信与信息中继网络^[20, 21]等任务。其中集群路径规划^[22]与区域覆盖侦察^[23]表现为典型的两类核心任务：1) 集群路径规划任务侧

重于在复杂环境约束下,为多架无人机协同生成从起始位置到目标位置的最优飞行路径,其核心目标是在保证飞行安全的前提下,优化飞行距离、时间或能量消耗等代价指标,同时避免集群内部的路径冲突,体现多无人机之间的协同一致性;2)区域覆盖侦察任务则关注无人机集群在任务区域内的空间部署与协同行为,其主要目标是在有限资源条件下实现对目标区域的高效、全面覆盖,并保持持续的环境感知能力,以提升信息获取效率和任务完成质量。这两类任务在优化目标和侧重点上各有不同,但共同构成了城市环境下无人机集群协同执行复杂任务的核心应用场景。

在上述主要任务场景下,随着军事作战向信息化与智能化方向演进,以知识定义网络(Knowledge-Defined Networking, KDN)^[24,25]为代表的智能组网技术以及智能无人机集群技术^[26]逐渐成为未来战场蜂群的重要发展方向,其通过融合环境感知、先验知识与智能决策机制,使通信网络具备自主感知和自适应决策能力,从而为无人机集群的智能协同提供底层支撑。如图 1-2 所示,在此背景下,无人机集群间的通信已不再是单纯的信息传输通道,而是实现集群智能交互与自主协作的基础纽带。因此在上述两类任务执行过程中,保障实时且稳定的通信网络不仅是保障无人机集群协同作战的核心条件,也是支撑集群智能化发展的基础要求^[27]。然而由于不同于开阔地形作战环境,城市作战环境本身具有极高的复杂性。高密度建筑群不仅对无人机的飞行路径构成物理障碍,同时会对无线通信链路产生显著遮挡和衰减效应^[28]。电磁干扰、移动目标遮挡、多径效应以及气象因素均可能导致信号质量下降或通信中断^[29,30],从而直接影响集群任务的执行效率和完成率。上述复杂电磁干扰与未知城市环境增加了路径规划和覆盖任务的不确定性,使得传统环境下的路径规划与覆盖侦察算法在无人机智能协同作战场景中效率大幅降低,难以直接迁移应用。

现有多数无人机集群任务规划研究主要关注路径最优性或覆盖效率,而忽略复杂城市环境中通信拓扑的动态变化及其约束条件,难以满足未来智能无人机集群作战需求。这导致为维持集群连通性,必须扩展搜索空间或引入额外约束,从而使算法计算复杂度呈指数级增长,难以应对大规模集群和实时任务^[3]。此外,现有方法在多任务、多目标优化方面不足,通常只优化单一指标,如覆盖率,而缺少综合考虑通信稳定性、任务完成时间和抗干扰能力的多维优化策略。因此,构建能够在复杂城市环境下兼顾路径规划、区域覆盖与通信约束的协同优化方法成为当前无人机集群研究的迫切需求^[31]。




图1-2 智能无人机集群作战网络架构示意图

Fig. 1-2 Schematic diagram of the intelligent operational network architecture for UAV swarms

基于上述背景，本文的研究具有重要的理论与工程意义：1）在理论层面，研究旨在建立适用于城市复杂环境的无人机集群路径规划与区域覆盖侦察模型，综合考虑通信连通性、抗干扰能力及任务完成效率，为大规模无人机城市协同任务执行提供理论基础。2）在工程应用层面，本文提出的方法能够提升无人机集群在城市复杂环境中的任务执行效率和可靠性，为城市作战中的军事行进与侦察等任务提供可实施的技术方案。通过解决路径规划、区域覆盖两大核心任务与通信保持约束的协同优化问题，本文不仅为大规模无人机集群在城市作战场景下的实战应用提供系统性的解决方案，也为未来智能化无人机网络的通信需求提供理论与方法支持。

1.2 国内外研究现状

本节系统综述了无人机集群在城市作战场景下的两类典型任务研究方向：集群路径规划与区域覆盖侦察问题。通过梳理国内外相关研究进展，分析了现有方法在通信建模、环境复杂性建模及集群规模扩展性等方面的不足。

1.2.1 无人机集群路径规划研究现状

在城市作战场景下，无人机集群通常需要在建筑物密集、空间受限且环境未知的空域中协同执行任务，其飞行路径不仅需要满足建筑物的安全避障与效率最优等基本要求，还必须在多无人机同时运动的条件下避免无人机间相互冲突。由此，集群路径规划问题成为无人机集群实现协同作战的关键基础之一，并逐渐成为国内外研究的重点方向。

在无人机集群路径规划研究中，早期工作主要聚焦于避障与路径最优化。Sharon 等人提出的基于冲突搜索（Conflict-Based Search, CBS）算法通过冲突树与单体路径搜索相结合^[32]，有效解决了多智能体间的路径冲突问题；Kottinger 等人提出的 K-CBS 算法进一步将 CBS 扩展至具动力学约束的多智能体系统^[33]；Wang 等人提出的稀疏 CBS-D* 算法通过分层搜索实现无人集群在突发威胁下的协同动态航迹规划^[34]。然而，基于冲突搜索的方法仅关注空间冲突与时间调度，无法对无人机集群的通信连通性进行建模，在建筑密集或电磁干扰严重的城市环境中难以满足通信保持需求。为克服这一局限，如图 1-3 所示，相关研究通过将其他已有的路径规划算法与设计的通信保持机制相结合，形成基于启发式优化、强化学习和改进人工势场法的三类主要研究方向。

第一类是基于启发式优化的算法，这类方法通过全局搜索与多目标优化机制相结合实现无人机通信协同路径规划的需求：He 等人提出的混合粒子群优化（Hybrid Particle Swarm Optimization, Hybrid PSO）算法在传统粒子群优化中引入局部与全局双层搜索结构，并通过自适应权重调整机制平衡全局探索与局部收敛，从而提升多无人机协同路径规划的优化稳定性与收敛速度^[35]。其核心优势在于搜索精度高、可同时优化多目标性能，但由于粒子更新过程仍依赖迭代群体信息，在高维连续空间下计算开销较大，实时性受限。Meng 等人提出的 PPSwarm 算法将优先级约束的快速扩展随机树（Rapidly-exploring Random Tree*, RRT*）算法与粒子群全局搜索相结合，构建了全局采样引导结合局部粒子更新的混合框架^[36]。该方法在复杂环境中能够有效避免局部最优并提升路径平滑性，但其双层混合结构在节点数量增加时搜索树扩张迅速，规划时间复杂度随无人机数量呈指数增长，限制了算法在实时多机系统中的应用。Güven 等人提出了一种基于多目标进化算法（Multi-Objective Evolutionary Algorithm, MOEA）的连通性覆盖路径规

划框架，引入连接时间作为连通性度量指标，保证无人机多跳通信链路鲁棒性的同时优化区域覆盖时间，能够为指挥决策提供不同通信-覆盖权衡下的多样化路径选择^[37]。然而，作为一种典型的进化计算方法，该策略在处理大规模无人机集群时，种群迭代与非支配排序过程带来了巨大的计算开销，且主要侧重于离线预规划，面对动态突发威胁时其实时重规划能力仍有待提升。综上所述，启发式优化类算法在路径通信联合优化中具有较强的全局搜索能力，但其普遍存在依赖全局信息、搜索效果不足和收敛时间长等问题，限制了其在大规模无人机集群动态任务场景下的应用潜力^[38]。




图1-3 多智能体通信保持路径规划算法分类

Fig. 1-3 Classification of communication-preserving path planning algorithms for multi-agent systems

第二类是基于强化学习的方法，通过针对已知场景的学习训练完成对通信保持路径的规划^[39]。Bayerlein 等人提出的深度强化学习无线数据采集算法 DRL-WDH 采用 Actor-Critic 架构联合优化路径与功率分配，在能效与通信覆盖间取得平衡；但该方法训练样本需求大、收敛速度慢，难以实时应用^[40]。Yu 等人的通信连通性强化学习算法 DRL-CC 在奖励函数中引入通信约束，利用 DQN-CNN 框架实现路径与连通性联合决策，提升链路稳定性^[41]；但依赖精确环境状态，模型泛化与迁移能力不足。Cheng 等人提出的分层强化学习结合模拟退火算法 HRL-SA 通过高层任务规划与低层路径控制实现协同优化，并利用模拟退火增强探索性^[42]；其结构复杂、参数调优困难，计算开销较高，实时性受限。总体来看，强化学习类算法具备自学习与动态适应优势，但普遍存在训练代价高、收敛慢及实时部署困难等问题，在大规模集群与复杂环境下应用仍受限制^[42, 43]。

针对第一、二类方法存在的可观测环境信息受限和新环境迁移困难问题,第三类方法是基于传统人工势场(Artificial Potential Field, APF)提出的通信保持改进方法^[22]。Zhang 等人提出的鲁棒多无人机网络设计算法 R-UAVNet 在传统势场模型中引入通信链路质量与障碍信息联合约束,通过构建复合势能函数提升障碍密集环境下的网络鲁棒性。其核心机制在于利用通信质量梯度调节无人机间引力分布,以维持拓扑稳定^[44]。但算法对势场参数敏感、在动态环境下易出现响应滞后与实时性下降。Zhu 等人提出的基于连通保持的编队控制算法 CMUFC 采用图论约束与拓扑恢复机制,通过邻接矩阵实时更新实现小规模无人机编队的连通维持^[45];该算法结构简单、控制稳定,但计算依赖局部拓扑重构频率,且集群集中规划,通信保持势场耦合度高,难以在大规模集群中保持实时性。Gong 等人提出的分布式自适应容错编队控制算法 DAFT-FC 在异构无人机系统中引入自适应补偿,实现通信链路故障下的编队保持^[46];其核心在于通过分布式估计与补偿提高系统鲁棒性,但算法参数调整复杂、收敛速度受噪声干扰影响显著。Wei 等人提出的抗干扰协同通信算法 AJ-APF 将通信信道信噪比与干扰功率建模为势场约束项,实现通信链路的自适应调节与抗干扰保持^[47]。该方法在电磁干扰环境下提升了通信鲁棒性,但其最多考虑了 7 架无人机且无建筑障碍的场景。随着无人机数量增加和建筑障碍的引入,多源势场叠加易引发局部振荡与死锁现象,导致在大规模复杂场景下效果不足。总体来看,现有改进人工势场方法通过将通信需求与势场模型结合,实现了路径规划与通信保持的统一建模,具备良好的分布式与实时特性;然而,其在大规模集群和动态复杂环境下仍存在多源势场耦合加剧导致规划稳定性下降等问题^[22, 48]。

由上述可知当前相关研究主要存在以下两个方面的不足:1)扩展性不足:现有基于改进人工势场算法在大规模复杂环境中易出现多源势场叠加导致振荡或死锁,从而导致算法性能和规划效率下降;2)通信保持效果不足:现有部分算法缺少对城市环境下复杂信道的建模,所提启发式算法和强化学习在大规模复杂环境下难以有效满足通信保持需求。

1.2.2 无人机集群区域覆盖研究现状

无人机集群区域覆盖侦察部署问题是无人机集群作战与协同任务中的另一个典型应用场景,在持续侦察与战场监测等任务中具有重要的工程与军事价值。该类任务通常要求多架无人机在有限数量和通信能力约束下,对给定任务区域实现无空洞的整体覆盖,同时保证无人机之间能够维持稳定的通信链路,以支持协同感知、信息共享和联合决策^[49-52]。因此,无人机集群的区域覆盖侦察部署任务不仅是几何意义上的覆盖问题,更是一个同时受制于网络拓扑结构、通信约束与建筑遮挡的复杂优化问题。

覆盖部署问题最早在无线传感网络 (Wireless Sensor Networks, WSN) 领域中得到系统研究, 相关研究通常根据覆盖类型的不同, 将覆盖问题划分为目标覆盖 (Target Coverage)、区域覆盖 (Area Coverage) 和边界覆盖 (Barrier Coverage) 三类^[53, 54]。其中, 目标覆盖^[55]侧重于对有限离散目标点的监测, 边界覆盖^[56]关注对特定边界或通道的封锁与检测, 而区域覆盖^[57]则要求对整个连续区域实现尽可能完整的感知覆盖, 是应用最为广泛且计算复杂度高的一类问题。本文研究的无人机集群覆盖部署问题属于典型的区域覆盖问题, 其目标是在给定区域内通过合理部署无人机实现对区域的整体面积覆盖, 并在此基础上进一步考虑通信连通性约束。由于问题建模的高度相似性, 无人机区域覆盖部署研究在很大程度上沿用了无线传感器网络领域已有的理论框架与算法体系。现有大量研究表明, 无论是在覆盖度建模、节点间连通性约束, 还是在优化目标的构建方式上, WSN 的覆盖优化方法均可作为无人机覆盖问题的重要理论基础, 成为无人机覆盖部署研究的重要参考范式^[58]。

如图 1-4 所示, 现有研究的区域覆盖部署方法大体可以归纳为四类: 基于虚拟力的方法、基于网格的方法、基于 Voronoi 图的方法以及基于元启发式优化的方法^[54, 59]。前三类传统方法通常依赖明确的几何结构或局部规则, 具有计算复杂度低、实现简单等优点, 但在复杂建筑与通信约束场景下往往难以获得全局最优或近似最优解; 而基于元启发式的方法则通过启发式搜索机制对解空间进行全局探索, 更适合处理多约束、多目标的复杂区域覆盖部署问题。

基于虚拟力的方法是最早应用于覆盖控制的策略之一, 其核心思想是通过构造人工势场或虚拟引力与斥力, 使节点在局部作用下逐步调整位置以改善覆盖效果。Howard 等人提出的虚拟力算法 VFA 通过在节点之间引入排斥力、在覆盖空洞区域引入吸引力, 使传感器节点逐步趋于均匀分布, 从而提高区域覆盖率^[60]。该方法结构直观、实现简单, 但易陷入局部最优, 且难以显式建模网络连通性约束。随后, Li 等人将 VFA 引入无人机覆盖部署中, 通过调节力模型参数实现覆盖均匀性提升^[61], 但在复杂障碍环境和通信受限场景下仍存在明显不足。Wang 等人提出在虚拟力的基础上引入反向竞争群优化器 OCSO 作为全局搜索驱动的混合策略, 并结合了维诺图来精确计算局部覆盖空洞, 实现了在不规则障碍物环境下的高覆盖率与网络连通性保持, 但算法引入了大量超参数, 计算效率有所降低^[62]。

基于网格的方法通常通过将连续区域离散化为规则或非规则网格, 将覆盖问题转化为有限离散点的选择与优化问题。Kim 等人提出了一种基于规则几何结构的传感器部署方法, 用于实现 q -覆盖与 p -连通性, 并考虑了通信半径与感知半径比例不同对部署结构的影响^[63]。针对不同的半径比例关系, 分别采用正方形、六边形和三角形晶格等规

则部署模式,并通过节点间距与通信/感知半径之间的几何关系推导满足 p 与 q 约束的部署条件,该方法在理论分析上较为严谨,但计算复杂度随网格精度快速增长。类似思想被引入无人机覆盖部署中,例如 Wang 等人采用三维网格对空间进行离散建模,通过搜索无人机在网格点上的部署方案来提升覆盖完整性,但该类方法在大尺度连续空间中的适用性受到限制^[64]。在蜂窝网络通信场景中, Rahimi 等人将三维空域离散化为有限的候选网格点集合,把无人机基站的连续定位问题转化为离散组合优化问题,利用随机优化算法从海量候选点中筛选出能最大化用户接入覆盖的最优子集,从而规避了非凸优化求解的困难^[65]。尽管该类方法在理论分析上较为严谨,但其计算复杂度随网格精度呈指数级增长,导致其在大尺度连续空间以及不规则地形中的适用性受到限制。




图1-4 区域覆盖部署问题算法分类

Fig. 1-4 Classification of algorithms for area coverage deployment problems

基于 Voronoi 图的方法则从几何划分角度对覆盖问题进行建模,其核心思想是利用 Voronoi 单元描述节点的责任区域,并通过调整节点位置使 Voronoi 单元尽量均匀,从而改善覆盖质量。Cortes 等人提出基于 Voronoi 图 (Voronoi Partition) 和劳埃德算法 (Lloyd's Algorithm) 的分布式梯度下降控制算法避免了复杂的搜索过程,被广泛应用于 WSN 覆盖控制,并被后续研究引入无人机覆盖部署中^[66]。Schwager 等人基于加权 Voronoi 分区设计了覆盖控制策略,使无人机能够在连续区域内自组织形成均匀覆盖结构^[67]。尽管该类方法在连续空间覆盖中具有良好的几何解释性,但同样难以同时处理通信连通、能量约束和障碍物等复杂因素。针对环境未知与节点失效问题, Schwager 等人

提出了一种具有弹性的覆盖控制框架,该方法利用在线学习机制实时估计环境密度函数,使得无人机集群能够在无需先验信息的情况下,自动调整 Voronoi 单元以填补因节点故障产生的覆盖空洞,从而显著提升了系统的鲁棒性^[68]。该类算法具备完全分布式以及计算简单的优点,但是在面对复杂地形遮挡影响时效果不佳,并且无法有效建模除覆盖以外如通信等耦合目标。

为克服上述传统方法在全局搜索能力和复杂约束建模方面的不足,越来越多的研究开始采用元启发式优化算法求解区域覆盖部署问题。在单目标优化框架下,遗传算法 (Genetic Algorithm, GA)、粒子群优化 (PSO)^[69]和差分进化 (Differential Evolution, DE)^[70]是最常用的三类方法。Yoon 等人采用遗传算法对 WSN 区域覆盖部署进行优化,通过编码节点位置并以覆盖率为适应度函数,实现了较传统规则部署更高的覆盖性能^[71]。随后,GA 被引入无人机覆盖问题中,例如 Wen 等人通过 GA 优化无人机三维部署位置,以最大化区域覆盖率,在复杂地形下取得了较好的覆盖效果^[72]。PSO 方法则通过模拟群体协同行为对解空间进行搜索,具有收敛速度快、参数少的特点。Wang 等人基于 PSO 设计了 WSN 覆盖优化算法,通过设计分层机制并引入覆盖惩罚项避免节点聚集现象^[73];类似思想被应用于无人机覆盖部署中,Yuheng 等人通过利用 PSO 搜索三维空间中无人机最优部署位置,有效提升了整体覆盖率^[74]。Das 等人设计了将差分进化和神经网络相结合的混合模型,通过差分进化的全局优化和神经网络的预测能力之间的协同作用实现覆盖范围和网络寿命的提高^[75]。然而,上述单目标方法通常仅关注覆盖性能,难以同时兼顾通信连通性、能耗或任务时效性。

随着应用需求的提升,研究者逐渐认识到区域覆盖部署问题本质上是一个多目标优化问题^[76, 77],需要在覆盖率、网络连通性、能量消耗等多个指标之间进行权衡。Konstantinidis 等人采用基于分解的多目标进化算法 (Multi-Objective Evolutionary Algorithm based on Decomposition, MOEA/D) 框架,将覆盖率与能量均衡作为多个子问题进行分解求解,显著提升了多目标搜索效率^[78]。Thirugnansambandam 等人提出针对目标区域无线传感器网络 t-WSN 的覆盖与连通性优化问题构建了一个多目标节点部署模型,并引入基于非支配排序的遗传算法 (Non-dominated Sorting Genetic Algorithm II, NSGA-II) 同时优化部署节点数量、覆盖质量与通信范围等指标^[79]。该算法通过利用 NSGA-II 的多目标进化机制在 Pareto 前沿上平衡覆盖性和连通性目标,提高了解的多样性与整体性能。这类方法为无人机覆盖部署研究提供了直接借鉴,多目标进化算法被逐步引入无人机覆盖与通信保持问题中^[51],例如采用 NSGA-II 同时优化无人机覆盖面积与网络连通性,明确刻画二者之间的冲突关系,并通过 Pareto 前沿为任务规划提供决策依据。

然而现有相关的无人机区域覆盖部署研究在面向未来智能城市作战场景时仍存在一定局限性,主要表现为以下两点:1)传统区域覆盖部署方法在通信约束建模方面较为简单,通常采用理想化的通信半径或简化的概率模型,难以有效刻画城市环境中由建筑遮挡引起的复杂视距条件以及电磁干扰对通信质量的影响。在此类复杂约束下,问题的非线性和不确定性显著增强,现有的方法容易受到局部信息影响而陷入局部最优,难以获得整体性能较优的规划结果。2)现有的单目标和多目标优化算法在多智能体网络建模与环境复杂性刻画方面仍显不足,缺乏对相关领域知识的结合与利用,在环境复杂度和规模提高并引入干扰信号场景时,算法的搜索难度显著增加,算法的搜索效率有所下降,求解效果难以达到预期。

1.3 主要研究内容

本文面向复杂城市作战环境下的无人机集群协同任务规划问题,针对集群通信保持路径规划与区域覆盖侦察部署两个典型作战任务,分别开展基于现有路径规划算法与多目标优化算法的研究。考虑到城市战场中高密度建筑物遮挡、多源强电磁干扰带来的链路质量下降与通信盲区,以及无人机集群自身的运动学约束与自组织网络连通性需求,建立包含城市环境模型、电磁干扰模型及信道损耗模型等的综合仿真环境。采用基于图论的连通性分析理论与多目标优化理论形式化描述集群在复杂受限空间内的运动规划与网络拓扑维持过程,并在此基础上设计适应不同任务约束的通信与任务协同优化机制,完成各任务场景下的算法建模与求解。最终在复杂城市仿真测试环境中验证所提策略在提升集群通信质量、保障任务覆盖率以及增强系统鲁棒性方面的有效性。本文主要工作有以下两个方面:

(1) 针对无人机集群在复杂城市环境下通信保持路径规划问题,考虑到集群在机动过程中面临的建筑物分布密集、电磁环境干扰严重以及多机协同冲突等多重约束,本文提出了一种基于分层分簇的通信保持快速扩展随机树人工势场(Clustered Rapidly-exploring Random Tree*-Artificial Potential Field, C-RRT*-APF)路径规划算法。该算法旨在保障飞行安全与到达目标的前提下,最大化集群通信网络的通信保持能力。首先,在全局规划阶段,算法采用 RRT* 算法在感知环境内为各簇快速搜索可行全局路径,并引入基于簇间距离的全局路径约束机制,在确保路径可行性与最优性的同时,为跨簇通信连通性奠定了拓扑基础;随后,在局部规划阶段,提出一种基于最大信干噪比(Signal-to-Interference-plus-Noise Ratio, SINR)瓶颈生成树的通信保持人工势场法(Maximum-Bottleneck- Spanning-Tree-based Artificial Potential Field, MBST-APF)进行实时单步轨迹

规划。该方法通过仅对关键通信瓶颈链路构建势场约束，有效降低了传统全连接势场的叠加复杂度，同时显著提升了集群在强干扰环境下的通信稳定性与运动平滑性。实验结果表明，在所提典型场景下该算法相较于 CMUFC 算法平均到达时间降低 29%，通信连通率提高 17%，证明该算法不仅能有效规划出规避密集障碍的轨迹，更能显著提升复杂电磁环境下集群的通信保持效果。

(2) 针对无人机集群在复杂城市环境下区域覆盖侦察部署问题，考虑到建筑物遮挡导致的侦察盲区、强电磁干扰及视距受阻引起的通信链路质量下降等约束，本文提出一种基于多种群引导协同进化的改进非支配排序遗传算法(Multi-Population Guided Non-dominated Sorting Genetic Algorithm II, MPG-NSGA-II)的通信保持区域覆盖算法。该算法致力于在多目标优化框架下，高效搜寻区域覆盖率最大化与网络代数连通度维持之间的平衡解集。算法首先结合覆盖与连通场景的领域知识，设计了两种新颖的局部引导变异算子：Voronoi 覆盖引导算子(Voronoi Coverage Guided Operator, VCGO)通过构建 Voronoi 图划分局部责任域，精确计算责任域质心，引导无人机向质心移动以快速填补覆盖盲区，显著提升解集的覆盖性能；节点度连通引导算子(Degree Connectivity Guided Operator, DCGO)则通过分析网络拓扑特征识别低度数弱连通节点，结合 SINR 阈值引导其向链路修复位置移动，从而有效增强网络的整体连通抗毁性。在此基础上，为克服传统多目标算法易陷入局部最优的缺陷，本文引入了基于上述两种算子的多种群岛模型精英迁移策略。该策略依据子种群的进化状态，基于个体支配等级和拥挤距离动态调控精英个体的迁移，有效平衡了算法的全局探索与局部开发能力。实验结果表明，在所提典型场景下该算法相较于传统 NSGA-II 算法在各个顶点连通度目标下覆盖率平均提升约 7%，并且在多参数场景均能在更少节点下实现区域的全覆盖目标，证明该机制有效平衡了算法的全局探索与局部开发能力，在同等网络连通性能下实现了更高的区域覆盖率，提高了网络抗损毁性能。

1.4 论文结构安排

本文面向复杂城市作战环境下大规模无人机集群协同任务规划问题，针对集群通信保持路径规划与区域覆盖侦察两个关键任务分别开展研究。充分考虑城市环境中的建筑遮挡、电磁干扰以及集群通信连通性约束，提升无人机集群在通信受限环境下的自主协同能力和任务执行效率。全文共分为五个章节，每章节主要研究内容如下：

第一章绪论部分，介绍了无人机集群在城市作战环境下的研究背景及意义，指出当前通信受限条件下集群协同规划面临的挑战，系统梳理了国内外在无人机集群路径规划

与区域覆盖部署领域的最新研究进展与不足，对本文的主要研究内容、创新点及论文结构安排进行了概括总结。

第二章集群协同规划与连通理论基础部分，介绍了多智能体路径规划（Multi-Agent Path Finding, MAPF）的基础理论，包括具有渐近最优性的 RRT* 算法以及实时性强的人工势场法，阐述了多目标优化理论，包括帕累托最优概念及 NSGA-II 算法的核心机制，介绍了图论与连通性相关理论，包括最大瓶颈生成树与代数连通度的计算方法。

第三章基于分层分簇的通信保持路径规划算法部分。本章提出一种基于分层分簇的 C-RRT*-APF 通信保持路径规划算法，以解决大规模无人机集群在复杂城市环境中兼顾避障与通信连通的路径规划问题。首先，构建包含密集建筑物与电磁干扰的城市作战场景模型及路径损耗通信模型。接着，阐述算法的分层规划架构：在全局层，利用引入簇间距离约束的 C-RRT* 算法生成各簇的协同引导路径，确保簇间空间分布的合理性与连通基础；在局部层，提出基于最大 SINR 瓶颈生成树引导的 MBST-APF 算法，通过构建关键通信链路势场实现簇内节点的实时避障与连通保持。最后，通过多组仿真实验从不同方面验证了该算法在不同建筑密度、干扰数量与强度及集群规模下的有效性与鲁棒性。

第四章基于多种群引导协同进化的通信保持区域覆盖算法部分。本章提出一种基于多种群引导协同进化的 MPG-NSGA-II 算法，用于解决通信约束下的无人机集群区域覆盖侦察部署问题。首先，建立考虑视距遮挡与干扰禁区的覆盖与连通性优化模型。进一步针对复杂环境下多目标优化易陷入局部最优的问题，设计了基于连通和贪心覆盖的混合初始化策略以提升初始种群质量，并提出了 Voronoi 覆盖引导算子与节点度连通引导算子，利用领域知识加速算法收敛。在此基础上，构建了多种群岛模型精英迁移机制，平衡全局探索与局部开发能力。最后，通过仿真实验对比分析了所提算法在覆盖率、连通性及收敛速度和稳定性等方面的性能优势。

第五章总结与展望部分，对全文的研究内容与创新成果进行了系统回顾与总结，分析了当前研究中存在的局限性，如无法适应动态干扰等问题，并对未来在动态环境适应性、多目标维度及实物验证等方向的研究工作进行了展望。

第二章 集群协同规划与连通理论基础

2.1 引言

在复杂城市作战环境中开展无人机集群协同路径规划与区域覆盖任务，往往需要同时面对高维搜索空间、环境多样性以及多重物理约束等挑战。为有效支撑后续章节中所提出的通信保持路径规划与区域覆盖算法，需从多智能体路径规划方法、多目标优化理论以及集群网络连通性理论等三个理论层面对本研究涉及的相关基础方法进行系统的梳理与介绍。本章旨在对上述与本文研究工作密切相关的理论基础进行归纳介绍，为后续关键算法设计与性能对比分析提供必要的理论支撑。

首先，针对多智能体路径规划方法，本章介绍基于改进快速扩展随机树的路径规划方法与人工势场法的基本原理与典型实现。其中，改进快速扩展随机树算法作为一种具有渐近最优性的采样规划方法，在高维复杂环境中表现出良好的可扩展性；而人工势场法因其结构简单、实时性强，在局部避障与协同控制中被广泛应用。通过对上述方法的原理与实现流程进行分析，为后续将全局采样规划与局部控制机制相结合的路径规划算法提供理论基础。

然后，针对无人机集群在区域覆盖侦察部署过程中涉及连通和覆盖两个相互冲突的优化目标，本章进一步介绍多目标优化问题的基本概念与常用理论方法，重点介绍帕累托最优理论及典型多目标优化算法的常用指标，并对非支配排序遗传算法的核心机制进行详细说明，为后续多目标性能评估与算法对比分析提供理论依据。

最后，为刻画无人机集群通信网络的结构特性与连通性约束相关的机制设计方法，本章引入图论相关基础理论，对最大瓶颈生成树的构造方法以及图拉普拉斯谱与代数连通度等基本理论进行说明。这些理论为后续通信保持机制设计与性能对比指标提供了数学基础，有助于从集群网络结构层面理解通信保持相关问题。

通过上述内容的系统梳理，本章为后续章节中所提路径规划算法的设计、区域覆盖多目标优化问题的构建、算法关键机制设计以及实验性能分析提供统一可行的理论基础与分析工具。

2.2 多智能体路径规划方法

多智能体路径规划是指在同一环境中为多个具有自主决策能力的智能体同时规划从初始位置到目标位置的可行路径，使其在满足环境约束与任务约束的前提下，实现安全、高效的协同运动。与单智能体路径规划相比，多智能体场景不仅需要考虑障碍物规避与路径可行性，还需进一步处理智能体之间的碰撞避免以及通信或连通性要求。因此，多智能体路径规划通常呈现出高维、强约束与耦合的特征，是当前无人系统领域的重要研究方向。基于随机采样（Sampling-based）的路径规划方法与基于人工势场的方法因其良好的实时性与计算效率，被广泛应用于求解复杂环境下的多智能体路径规划问题。

2.2.1 RRT*算法

在高维、复杂城市作战约束环境下的路径规划问题中，搜索空间呈现出非凸性强、障碍分布复杂、搜索维度高等特点，传统的基于栅格或确定性搜索的方法，如 A*、Dijkstra 算法等，往往面临维数灾难导致计算复杂度急剧上升的问题^[80]。为此，基于随机采样的路径规划算法逐渐成为解决连续空间路径规划问题的重要技术路线。随机采样算法的核心思想是在状态空间中通过随机采样构建离散路径点树，并利用局部连接策略逐步探索可行空间，最后获得从起始点到目标点的可行路径，代表性算法包括 PRM（Probabilistic Roadmap）^[81]、RRT^[82]及其相关的一系列改进算法。相比 PRM 算法更偏向于多查询场景，RRT 算法通过增量式构建搜索树，更适用于单次起点到目标点路径规划任务，因此在无人船、机器人运动规划及无人机路径规划领域得到了广泛应用。RRT* 算法是在 RRT 算法的基础上引入路径优化机制的改进算法，其核心思想是在保持随机探索能力的同时，通过重布线机制不断优化已有路径质量，从而在采样次数增加时收敛到最优解^[83]。

RRT 算法通过在连续状态空间中不断引入随机采样点并逐步构建树结构，实现对高维可行空间的高效探索。算法首先在排除障碍物后的可行空间 $\mathcal{X}_{free}$ 中定义搜索区域，并以起始状态 x_{start} 作为根节点初始化搜索树 T ，此时树中仅包含一个节点，其路径代价被初始化为 0。如图 2-1（a）所示，在每一次迭代过程中，算法首先在可行空间内按照给定的概率分布随机生成一个采样点 x_{rand} ，或直接以 x_{goal} 为采样点，用于引导搜索树向尚未被充分探索的区域扩展，其采样过程可表示为：

$$x_{rand} \sim U(\mathcal{X}_{free}) \quad (2-1)$$

随后，在当前搜索树中通过最近邻搜索操作，确定与该随机采样点在状态空间距离下最近的已有节点 x_{near} ，该过程是在离散节点集合中求解最小欧几里得距离问题，其

数学定义为：

$$x_{near} = \arg \min_{x \in T} |x - x_{rand}| \quad (2-2)$$

在获得最近邻节点后，算法并不直接将采样点加入搜索树，而是通过带有最大步长 η 约束的状态扩展函数，从 x_{near} 沿指向 x_{rand} 的方向生成新的候选节点 x_{new} ，以避免单次扩展跨度过大而降低对应的路径无碰撞可行性，该扩展过程可表示为：

$$x_{new} = x_{near} + \min(\eta, |x_{rand} - x_{near}|) \frac{x_{rand} - x_{near}}{|x_{rand} - x_{near}|} \quad (2-3)$$

随后，算法对 x_{near} 与 x_{new} 之间的连接路径进行连续碰撞检测，以验证该路径段是否完全位于可行空间内部；若检测结果表明路径与障碍物发生碰撞，则本次迭代被舍弃并直接进入下一轮采样，否则新节点被加入搜索树，并记录其父节点关系以保持树结构的连通性。随着上述过程的不断重复，搜索树在随机采样的驱动下持续向外扩展，并逐渐覆盖整个可行空间，如图 2-1 (b) 所示，当搜索树中某一新加入节点首次进入目标区域 x_{goal} 时，即可判定路径规划成功，此时通过沿父节点指针自该节点向根节点回溯，能够获得一条从起点到目标点的完整可行路径。需要指出的是，在整个构建过程中，RRT 算法始终以路径的可达性作为节点扩展与连接的主要判定依据，并未对路径代价进行显式优化，因此其在保证概率完备性的同时，通常只能获得一条非最优但计算效率高的可行路径。




图2-1 RRT 规划过程

Fig. 2-1 RRT planning process

尽管 RRT 算法能够在复杂连续空间中以高效率构建可行路径，但其增量式生长策略在搜索树规模不断扩大的情况下并不会对已生成的路径结构进行主动优化，从而导致在获得可行解后继续增加采样次数时，路径质量难以得到实质性提升。为克服上述不足，RRT* 算法在继承 RRT 随机采样与增量式扩展框架的基础上，引入了面向路径代价优

化的局部结构调整机制,使搜索树在扩展过程中具备自我优化能力。具体而言,如图 2-2 (a) 所示,在 RRT^* 的每一次迭代中,当新节点按照与 RRT 相同的随机采样、状态扩展及碰撞检测流程生成后,算法不再立即固定其父节点关系,而是以该新节点为中心,在搜索树中构造一个邻域节点集合,从中选择全局代价最优父节点。其对应的邻域半径随当前节点总数 n 动态变化,定义为:

$$r(n) = \min \left\{ \gamma \left(\frac{\log n}{n} \right)^{\frac{1}{d}}, \eta \right\} \quad (2-4)$$

其中 d 表示状态空间维数, γ 为与空间体积相关的给定常数。在获得邻域节点集合后, RRT^* 通过比较不同候选父节点所对应的从起点到新节点的累计路径代价,选择能够使总代价最小的节点作为新节点的最优父节点,其选择准则为:

$$x_{parent} = \arg \min_{x \in X_{near}} (c(x) + c(x, x_{new})) \quad (2-5)$$

随后,如图 2-2 (b) 所示,在新节点被加入搜索树之后,算法进一步遍历其邻域内的其他节点 x_i , 并判断是否可以通过以新节点作为中继来降低这些节点原有的路径代价,当满足:

$$c(x_{new}) + c(x_{new}, x_i) < c(x_i) \quad (2-6)$$

即对相关节点的父节点关系进行更新,从而完成局部重布线操作。通过在每一次节点扩展后重复执行上述最优连接与重布线过程, RRT^* 使得局部路径代价的改进能够逐步传播至整棵搜索树,从而在保持概率完备性的同时,从理论上保证当采样次数增加时,算法能够逐渐优化已有路径,避免规划路径距离过长,实现了相对于 RRT 算法的渐近最优性提升。




图2-2 RRT^* 关键机制

Fig. 2-2 Key mechanisms of RRT^*

2.2.2 人工势场法

人工势场法是一种基于连续空间势函数构造的路径规划方法，其基本思想是将路径规划问题转化为在虚拟势场中搜索势能最小轨迹的过程。在该方法中，智能体被视为在势场中运动的质点，目标点对其产生吸引作用，而障碍物则对其产生排斥作用，通过吸引势场与排斥势场的共同作用，引导智能体沿着势能不断下降的方向运动，从而实现从起始位置到目标位置的路径规划。由于人工势场法具有模型构建直观、计算开销小以及易于在线实现等优点，尤其适用于未知环境下的局部路径规划与实时避障问题，因此在无人机运动规划、机器人导航以及多智能体协同控制等领域得到了广泛应用。

人工势场法首先在连续工作空间中为目标点构造吸引势函数，使智能体在规划时产生指向目标方向的引力。通常情况下，吸引势函数可定义为与智能体当前位置 $\mathbf{x}$ 到目标点 $\mathbf{x}_{goal}$ 的欧几里得距离相关的二次函数形式，即：

$$U_{att}(\mathbf{x}) = \frac{1}{2} k_{att} \|\mathbf{x} - \mathbf{x}_{goal}\|^2 \quad (2-7)$$

其中 k_{att} 为吸引势场的权重系数，用于调节目标点对智能体的吸引强度。由吸引势函数对位置的梯度可进一步得到吸引力，其方向始终指向目标点，表达式为：

$$\mathbf{F}_{att}(\mathbf{x}) = -\nabla U_{att}(\mathbf{x}) = -k_{att}(\mathbf{x} - \mathbf{x}_{goal}) \quad (2-8)$$

为了避免智能体与障碍物（通常包括场景中的建筑物以及其他智能体）发生碰撞，需要在障碍物周围构造排斥势函数，使移动体在接近时受到逐渐增强的排斥作用。设 $d(\mathbf{x})$ 表示智能体当前位置到最近障碍物的最小距离，当该距离小于给定影响范围 d_0 时，排斥势函数通常定义为：

$$U_{rep}(\mathbf{x}) = \begin{cases} \frac{1}{2} k_{rep} \left(\frac{1}{d(\mathbf{x})} - \frac{1}{d_0} \right)^2, & d(\mathbf{x}) \leq d_0 \\ 0, & d(\mathbf{x}) \geq d_0 \end{cases} \quad (2-9)$$

其中 k_{rep} 为排斥势场权重系数， d_0 表示障碍物对智能体产生影响的距离。由排斥势函数对位置的梯度可得到排斥力，其方向指向远离障碍物的方向，具体表达式为：

$$\mathbf{F}_{rep}(\mathbf{x}) = -\nabla U_{rep}(\mathbf{x}) \quad (2-10)$$

在人工势场法中，整个环境的总势函数由吸引势函数与排斥势函数叠加而成，即：

$$U(\mathbf{x}) = U_{att}(\mathbf{x}) - \sum_{i=1}^{N_{obs}} U_{rep}^{(i)}(\mathbf{x}) \quad (2-11)$$

其中 N_{obs} 表示环境中障碍物的数量。对应的合力可表示为吸引力与各障碍物排斥力之和：

$$F(x) = F_{att}(x) + \sum_{i=1}^{N_{obs}} F_{rep}^{(i)}(x) \quad (2-12)$$

如图 2-3 所示，在规划过程中，智能体将按照势场中合力方向进行运动，其运动轨迹可通过沿势函数负梯度方向的迭代更新得到，从而在实现避障的情况下逐步向对应的目标点靠近。

尽管人工势场法在实时性与计算效率方面具有明显优势，但其仍然存在一些固有缺陷，例如在复杂环境中容易陷入局部极小点、在狭窄通道附近产生振荡现象以及目标点与障碍物势场叠加导致不可达区域等问题。这些不足在一定程度上限制了人工势场法在复杂城市作战场景环境中的全局规划能力。因此，在实际应用中，人工势场法往往作为一种局部规划或引导机制，与其他路径规划算法或优化策略相结合，以弥补其在复杂环境中的上述问题。




图2-3 人工势场法示意图

Fig. 2-3 Schematic diagram of the artificial potential field method

2.3 多目标优化理论

在很多实际的复杂工程问题中，系统往往需要同时满足多个相互冲突的优化目标，以当前的区域覆盖部署任务为例，包括区域覆盖率、网络通信能力与能量消耗等。此类

问题由于难以衡量目标之间的取舍关系,通常难以通过单一目标函数进行问题建模与求解,因此需要引入多目标优化理论,通过协调多个目标之间的性能,获得一组具有可选的具有代表性的最优解。

2.3.1 多目标优化基础

多目标优化问题 (Multi-objective Optimization Problem, MOP) 可以表示为:

$$\text{Minimize } \mathbf{F}(\mathbf{x}) = (f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_m(\mathbf{x})), \quad \mathbf{x} \in \Omega \quad (2-13)$$

其中, $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$ 为决策向量, Ω 为可行解空间, $\mathbf{F}(\mathbf{x})$ 为由 m 个目标函数组成的向量函数。多目标优化的核心在于不同目标函数之间通常存在冲突,即在优化某一目标时,可能会导致其他目标恶化,因此不存在单一解能够同时最优地满足所有目标。

为此,引入非支配解 (Pareto Optimal Solution) 的概念: 若对于两个解向量 $\mathbf{x}_1, \mathbf{x}_2 \in \Omega$, 满足:

$$f_i(\mathbf{x}_1) \leq f_i(\mathbf{x}_2), \quad \forall i \in \{1, 2, \dots, m\}, \quad \text{且存在 } j \text{ 使 } f_j(\mathbf{x}_1) < f_j(\mathbf{x}_2) \quad (2-14)$$

则称 $\mathbf{x}_1$ 支配 $\mathbf{x}_2$ (记作 $\mathbf{x}_1 < \mathbf{x}_2$)。非支配解集合由不被其他解支配的个体组成,其在目标空间中形成帕累托前沿 (Pareto Front, PF), 代表在各目标之间取得最优折中关系的解集。帕累托前沿不仅体现了解集的收敛性,同时也反映了解集在多目标空间中的多样性。

为了定量评价多目标优化算法的性能,通常需要从收敛性和多样性两个角度对解集整体进行分析。常用指标包括反向代距离 (Inverted Generational Distance, IGD)、超体积 (Hypervolume, HV)、均匀性指标 (Spread, Δ) 和间距指标 (Spacing, SP), 对应的具体含义和计算方法如下:

(1) IGD 用于衡量算法生成的解集到真实帕累托前沿的距离,从而反映解集的收敛性。设真实帕累托前沿为 $PF^* = \{y_1^*, \dots, y_{|PF^*|}^*\}$, 算法生成解集为 $\mathcal{A} = \{y_1, \dots, y_{|\mathcal{A}|}\}$, 则 IGD 定义为:

$$\text{IGD}(\mathcal{A}, PF^*) = \frac{1}{|PF^*|} \sum_{y_i^* \in PF^*} \min_{y_j \in \mathcal{A}} \|y_j - y_i^*\| \quad (2-15)$$

IGD 值越小, 表示解集越接近真实帕累托前沿。

(2) HV 用于评估解集覆盖目标空间的能力。给定参考点 $\mathbf{r}$ (通常取大于所有目标值的点), HV 定义为解集 $\mathcal{A}$ 与参考点构成的超体积:

$$\text{HV}(\mathcal{A}) = \text{Volume} \left(\bigcup_{y \in \mathcal{A}} [y_1, r_1] \times [y_2, r_2] \times \dots \times [y_m, r_m] \right) \quad (2-16)$$

其中, $[y_m, r_m]$ 表示第 m 个目标维度上由个体目标值与参考点分量构成的闭区间, 各维度区间的笛卡尔积共同构建了该解在目标空间中的超立方体区域; **Volume** 则代表勒贝格测度 (Lebesgue Measure), 用于计算所有解对应的超立方体在求并集并剔除重叠部分后的总体积。该指标数值越大, 说明解集与参考点之间围成的区域越广, 反映了算法在收敛性、广度及分布均匀性上的综合性能。

(3) **Spread** 用于衡量解集在帕累托前沿上的均匀性。定义:

$$\Delta = \frac{\sum_{i=1}^m d_i^{ext} + \sum_{i=1}^{|\mathcal{A}|-1} |d_i - \bar{d}|}{\sum_{i=1}^{|\mathcal{A}|-1} d_i} \quad (2-17)$$

其中, $d_i = \min_{j \in \mathcal{A}, j \neq i} (\sum_{k=1}^m |f_k(x_i) - f_k(x_j)|)$ 表示解集中第 i 个解与最邻近解之间的距离, $\bar{d}$ 为所有 d_i 的均值, d_i^{ext} 表示解集端点与真实帕累托前沿端点的距离。**Spread** 用于综合评估算法生成解集的分布广泛性与均匀性。其分子前项计算了解集边界点与真实帕累托前沿端点的偏离程度, 后项则通过相邻解间距的绝对偏差之和表征分布的均匀度。 Δ 值越小, 说明解集在目标空间中覆盖越完整且排布越均匀; 当解集完全均匀分布且包含了所有端点解时 $\Delta = 0$ 。

(4) **SP** 用于衡量解集中各解之间分布的均匀程度。该指标通过计算每个解到其最近邻解的距离与平均距离之差的均方根来表示, 其定义为:

$$SP = \sqrt{\frac{1}{|\mathcal{A}| - 1} \sum_{i=1}^{|\mathcal{A}|} (\bar{d} - d_i)^2} \quad (2-18)$$

SP 值越小, 表示解集中的个体分布越均匀。当 $SP = 0$ 时, 代表解集中所有个体之间的间距完全相等。

通过以上指标, 可以从所求解集的收敛性和多样性两个方面综合评估多目标优化算法的性能, 为算法选择和参数调优提供理论依据。

2.3.2 NSGA-II 算法

带精英策略的非支配排序遗传算法 **NSGA-II** 是当前应用最为广泛的多目标进化算法之一, 其通过引入快速非支配排序与拥挤度距离机制, 在保证解集多样性的同时提升了算法效率。

NSGA-II 算法具体流程如图 2-4 所示。算法运行时首先生成初始种群 P_0 , 然后对每个个体计算所有目标函数值, 并将其存储于目标空间中。随后对种群进行快速非支配排序 (Fast Non-dominated Sorting), 如图 2-5(a) 所示, 将个体划分为多个前沿 $F_1, F_2, \dots$,

其中 F_1 为第一前沿，包含所有不被其他个体支配的解。非支配排序确定了个体的优先等级，为后续选择操作提供依据。




图2-4 NSGA-II 算法流程图

Fig. 2-4 Flowchart of the NSGA-II algorithm

在同一个前沿内部，为保证解集的多样性，算法计算每个个体的拥挤度距离（Crowding Distance, CD），用于衡量个体在目标空间中的相对稀疏性。如图 2-5（b）所示，对于目标维度为 m 的个体 i ，拥挤度距离定义为：

$$CD_i = \sum_{k=1}^m \frac{f_k^{i+1} - f_k^{i-1}}{f_k^{max} - f_k^{min}} \quad (2-19)$$

其中， f_k^{i+1} 和 f_k^{i-1} 分别为按第 k 个目标排序后相邻个体的目标值， f_k^{max} 和 f_k^{min} 为当前前沿中该目标的最大值与最小值。拥挤度距离越大，个体在目标空间中越稀疏，选择优先级越高，从而避免解集过度集中。




图2-5 支配等级与拥挤距离

Fig. 2-5 Dominance rank and crowding distance

快速非支配排序与选择操作采用基于非支配等级和拥挤度距离的比较算子：若个体 x_i 所在前沿等级低于个体 x_j ，则优先选择 x_i ；若两者等级相同，则选择拥挤度距离更大的个体。此策略兼顾了解集的收敛性和分布均匀性。

随后，算法通过遗传操作生成子代种群 Q_t ，包括模拟二进制交叉（Simulated Binary Crossover, SBX）和多项式变异（Polynomial Mutation, PM），以实现全局搜索和局部探索。交叉操作用于个体间信息交换和全局探索，变异操作用于增加多样性，防止算法陷入局部最优。

再经过交叉变异生成子代后，将父代与子代合并形成联合种群 $R_t = P_t \cup Q_t$ ，并对 R_t 进行非支配排序和拥挤度距离计算，从中选取前 N 个个体形成下一代种群 P_{t+1} 。整个迭代过程持续至达到预设最大代数或满足收敛准则，最终输出的解集即为帕累托前沿的近似最优解。

NSGA-II 算法通过非支配排序确定优先等级,通过拥挤度距离维护解集多样性,通过遗传操作实现全局搜索能力,使算法在大多数多目标优化问题中具有良好的收敛性和鲁棒性。其快速非支配排序算法复杂度为 $O(MN^2)$,能够有效降低计算成本,同时父代子代联合选择机制保证了解集覆盖目标空间的均匀性和广度,因此 NSGA-II 算法常作为多目标优化算法性能比较的基准。

2.4 集群网络连通性理论

在无人机集群系统中,无人机通信网络的连通性是保证信息共享和协同决策能力的关键因素。集群网络连通性相关的图论提供了一种统一的数学框架,用于描述和分析多智能体的通信网络结构。通过构建图模型,可以将无人机个体视为图的节点,通信链路视为边,从而将网络连通性问题转化为图的结构分析问题。在此基础上,本研究引入的最大瓶颈生成树和 Kruskal 算法、图拉普拉斯矩阵和连通度相关指标等图连通性理论能够有效刻画系统的网络连通特性,并为本文所设计的通信保持关键机制以及指标对比提供对应的有效理论依据。

2.4.1 最大瓶颈生成树和 Kruskal 算法

最大瓶颈生成树是指在加权无向图中,使生成树最小边权最大化的生成树,从而保证最弱链路(瓶颈边)的权值尽可能高。这一特性在无人机通信网络中尤为重要,因为生成树的最小边权往往对应最弱的通信链路,通过优化瓶颈边可以增强整体网络的鲁棒性。设无人机网络加权无向图为 $G = (\mathcal{V}, \mathcal{E}, \mathcal{W})$,其中 $\mathcal{V}$ 为节点集合, $\mathcal{E}$ 为边集合, $\mathcal{W}: \mathcal{E} \rightarrow R^+$ 为边权函数,一般代表链路质量,则最大瓶颈生成树 $\mathcal{T}_{MBST} \subseteq \mathcal{E}$ 满足:

$$\mathcal{T}_{MBST} = \arg \max_{T' \in \mathcal{T}} \min_{e \in T'} W(e) \quad (2-20)$$

其中 $\mathcal{T}$ 为图 G 的所有生成树集合, $W(e)$ 为边 e 的权重。构造最大瓶颈生成树通常可采用 Kruskal 的贪心策略。其核心思想是将图的所有边按权重从大到小排序,然后依次选择边加入生成树,但每次加入边前需要检查是否形成环。

如图 2-6 所示为对应 6 节点图的最大瓶颈生成树,算法主要步骤包括:

- (1) 初始化生成树为空集合;
- (2) 按边权降序排序边集合;
- (3) 逐条检查边,如果加入边不会形成环,则将边加入生成树,重复此过程直到生成树包含 $|\mathcal{V}| - 1$ 条边。

该方法能够保证生成树的最小边权最大化,从而实现网络通信链路的最大瓶颈控制,

使得整个通信网络在链路层面最易于维护。




图2-6 最大瓶颈生成树

Fig. 2-6 Maximum bottleneck spanning tree

2.4.2 图拉普拉斯矩阵与连通理论

图拉普拉斯矩阵 (Graph Laplacian, L) 为分析网络连通性提供了重要工具。对于加权无向图 $G = (\mathcal{V}, \mathcal{E}, \mathcal{W})$, 其拉普拉斯矩阵 $L \in R^{|\mathcal{V}| \times |\mathcal{V}|}$ 定义为:

$$L = D - A \quad (2-21)$$

其中 A 为邻接矩阵, 元素 $a_{ij} = W(e_{ij})$ 表示节点 i 和 j 之间的边权, 若无边则 $a_{ij} = 0$; D 为度矩阵, 元素 $d_{ii} = \sum_j a_{ij}$, 其余元素为零。拉普拉斯矩阵具有若干重要性质: 其特征值非负, 且零特征值的个数等于图的连通分量数。如果图完全连通, 则 L 仅有一个零特征值, 其余特征值均为正。

代数连通度 (Algebraic Connectivity, $\lambda_2(L)$) 定义为拉普拉斯矩阵的第二小特征值, 记作 $\lambda_2(L)$:

$$\lambda_2(L) > 0 \quad \text{if } G \text{ 连通} \quad (2-22)$$

代数连通度越大, 表示图的连通性越强, 相应地系统对单个节点或边失效的鲁棒性也越高。

在图连通性理论中, 除代数连通度外, 顶点连通度 (Vertex Connectivity, k) 与节点度 (Node Degree, d) 两者也是刻画网络结构连通强度与鲁棒性的重要指标。对于无向图 G , 若删除任意不超过 $k - 1$ 个节点后图仍保持连通, 则称该图为 k 连通图, 其最大满足条件的 k 称为图的顶点连通度, 记为 $k(G)$ 。顶点连通度从组合意义上刻画了网

络在最坏情况下能够容忍的节点失效数量，是对连通性的严格强化。另一方面，节点度 d_i 表示节点 i 的邻接节点数，最小节点度 $\delta(G) = \min_i d_i$ 反映了网络中最薄弱节点的局部连接冗余。经典图论结果表明，上述三个指标之间存在如下基本关系：

$$\lambda_2(\mathbf{L}) \leq k(G) \leq \delta(G) \quad (2-23)$$

上式建立了谱连通性、顶点连通性与节点度之间的理论关联。该关系表明，当代数连通度取值较大时，网络不仅在谱意义下连通性增强，其节点连通度和最小节点度通常也相应提高，网络对节点或边失效的鲁棒性随之增强。因此， $\lambda_2(\mathbf{L})$ 可视为在保持计算可行性的同时，对 k -连通性和节点度约束进行综合反映的一个有效的连续值指标，在无人机集群系统通信拓扑分析与优化中具有重要的理论意义。

2.5 本章小结

本章系统介绍了多智能体路径规划、多目标优化以及集群网络连通性理论基础。首先，介绍了改进快速扩展随机树算法和人工势场法，前者通过随机采样与重布线生成渐近最优路径，后者通过虚拟势场实现实时局部避障，为后续所提的路径规划算法提供理论支持。随后，介绍了多目标优化理论，包括非支配解、帕累托前沿及常用性能指标(IGD、HV、 Δ 和 SP)，并详细阐述了 NSGA-II 算法的非支配排序、拥挤度距离及遗传进化机制，说明了其在保证解集收敛性与多样性方面的优势。最后，针对无人机集群通信网络，介绍了最大瓶颈生成树及 Kruskal 构造方法、图拉普拉斯矩阵、代数连通度及其与顶点连通度、节点度之间的数学关系，提供了评估网络连通性和系统鲁棒性的数学工具。上述理论为后续路径规划与区域覆盖的通信约束优化算法的设计奠定了理论基础。

第三章 基于分层分簇的通信保持路径规划算法

3.1 引言

随着无人机技术的快速发展与现代作战样式的不断演进,大规模无人机集群在城市作战场景中的应用需求日益突出。在情报侦察、目标跟踪与协同打击等类型的任务中,无人机集群往往需要在建筑物密集、环境结构复杂且信息未知的城市空间内执行长距离的协同行进任务。这类任务对现有路径规划算法在可扩展性、实时性以及协同稳定性等方面提出了更高要求。尤其是在无人机集群规模不断扩大的背景下,传统单机或小规模多智能体路径规划方法已难以满足未来城市作战需求。

在未来城市作战环境中,无人机集群路径规划问题不仅表现为对建筑障碍的规避和目标区域的到达,更关键的是需要在规划过程中保持集群通信网络的连通性。不同于其他视野无遮挡且相对开阔的作战场景,城市作战场景在通信保持方面主要存在以下两方面的难点:一方面,高密度建筑群造成的非视距传播会严重衰减信号,降低链路质量;另一方面,作战环境下的复杂外部敌对干扰会进一步削弱通信稳定性,使得集群在运动过程中易出现链路中断甚至网络分裂。由于路径规划与通信保持在空间层面存在强耦合关系,如何在避障、抗干扰与通信约束并存的条件下实现高效、稳定的协同路径规划,成为大规模无人机集群面临的核心挑战之一。针对上述问题,现有的研究主要从基于冲突搜索、启发式优化、强化学习以及人工势场法方向进行探索。然而,现有方法或侧重于空间避障与无人机间调度,缺乏对通信连通性的显式建模与针对性机制设计;或依赖全局信息与大量迭代计算进行通信保持优化,难以满足大规模集群在未知复杂环境下的实时规划需求;又或者在引入复杂通信约束后,由于多源势场叠加复杂度提高,容易出现路径振荡或死锁等导致规划效率显著下降等问题。因此,如何在提高集群网络通信连通性的同时,兼顾路径规划效率与集群规模可扩展性,对于城市作战场景下大规模无人机集群路径规划问题仍有进一步研究的需求。

本章针对城市作战场景下大规模无人机集群的通信保持路径规划这一问题,提出一种结合全局路径采样与局部人工势场法的分层分簇通信保持路径规划算法。该方法以分层分簇机制为核心,将大规模无人机集群路径规划算法划分为全局引导与局部执行两个层面:在全局层面,通过采样关键路径点为各无人机簇生成协同的全局参考路径;在局部层面,结合环境感知信息与通信状态,实时完成无人机集群避障与连通保持的单步规

划，从而实现路径规划与通信保持的协同优化目标。

具体而言，本章所提算法的主要创新点体现在以下三个方面：首先，通过引入分簇优化与分层规划机制，有效降低了大规模无人机集群路径规划的势场复杂度，提升了算法在城市作战场景下的规模可扩展性；其次，在全局路径规划阶段，引入基于簇间距离约束的簇路径生成与重规划机制，在保证路径全局可达性与优化的同时，为跨簇通信连通规划提供了基础；最后，在局部规划阶段，提出基于最大 SINR 瓶颈生成树的通信保持人工势场方法，通过仅对关键通信链路进行选择与维护，以降低势场复杂度并显著提升了集群在敌对干扰存在场景下的通信稳定性与运动平滑性。

本章将首先给出城市作战场景下的场景模型与通信模型描述，然后详细介绍所提算法的总体框架与关键机制，为仿真实验验证提供基础，最后针对路径规划效果、时序分析、性能分布、多场景参数适应性和消融实验等五个不同方面分析了所提算法对比现有算法的性能提升效果。

3.2 系统模型

为对所研究的无人机集群通信保持路径规划问题进行合理建模，并为后续算法设计与性能验证提供统一的分析基础，本节综合考虑城市环境中的建筑物分布特性以及无人机集群通信机制，对实际城市作战场景进行系统建模，主要从场景模型与通信模型两个方面对仿真环境进行详细说明。其中场景模型主要描述无人机集群运动特性及建筑物与干扰分布特征，通信模型用于说明无人机之间的信道以及通信网络建模，为后续的路径规划算法设计提供理论依据。

3.2.1 场景模型

本文将城市作战场景建模为二维矩形区域 $\mathcal{A} \subset R^2$ ，其几何尺寸为 $[0, L_x] \times [0, L_y]$ 。如图 3-1 所示，若干建筑物、干扰节点与无人机集群分布在该矩形二维区域中。场景中的建筑物集合表示为 $\mathcal{O} = \{O_1, O_2, \dots, O_M\}$ ，其中， M 为建筑物数量，建筑物 $O_j \subset \mathcal{A}$ 为矩形；场景中部署有位置固定的单个敌方干扰节点，干扰节点 J 的位置为 $\mathbf{o}^J = (o_x^J, o_y^J)$ ，其干扰功率为 P_J ，等效干扰半径为 J_r ；无人机集群表示为 $\mathcal{U} = \{u_1, u_2, \dots, u_N\}$ ，每架无人机的初始位置集合为 $\mathcal{O}_{start} = \{\mathbf{o}_1(0), \mathbf{o}_2(0), \dots, \mathbf{o}_N(0)\}$ ，目标位置集合为 $\mathcal{O}_{target} = \{\mathbf{o}_1^g, \mathbf{o}_2^g, \dots, \mathbf{o}_N^g\}$ ，其中 N 为无人机数量。无人机集群的任务目标是在满足环境约束的前提下，实现从初始位置到目标位置的路径规划。




图3-1 城市作战场景集群路径规划示意图

Fig. 3-1 Urban combat scenario swarm path planning diagram

不失一般性，本文采用离散时间建模方式，将总仿真时长划分为 T 个步长，时间集合记为：

$$\mathcal{T} = \{k \Delta t \mid k = 0, 1, \dots, T\} \quad (3-1)$$

其中 Δt 为采样间隔。每架无人机 u_i 在 t 时刻的位置为 $\mathbf{o}_i(t) = (o_{i,x}(t), o_{i,y}(t))$ 。同时在运动过程中，每架无人机最大线速度为 v_{max} ，对应 Δt 内的最大移动距离为 d_{move} 。并且为保障飞行安全，无人机与其他无人机以及建筑物之间需满足以下距离约束：

$$d(\mathbf{o}_i(t), O_j) \geq d_{safe}, \forall O_j \in \mathcal{O} \quad (3-2)$$

$$\|\mathbf{o}_i(t) - \mathbf{o}_j(t)\| \geq d_{safe}, \forall i \neq j, u_i, u_j \in \mathcal{U} \quad (3-3)$$

其中 d_{safe} 为无人机与建筑物或其他无人机之间的最小安全距离， $d(\mathbf{o}_i(t), O_j)$ 表示无人机到矩形建筑物 O_j 任意一条边的最小欧几里得距离。

为表征未知作战场景情况，所提系统假设每架无人机都携带有限距离的感知设备，用于探测半径为 l 圆形区域内的干扰源以及建筑物信息。记时刻 t 的观测信息为 $\mathcal{O}_t \subseteq \mathcal{O}$ ，其随无人机集群的位置变化而实时感知更新。

3.2.2 通信模型

考虑到实际城市作战环境中建筑遮挡导致的信道影响,本文采用自由空间传播模型并引入城市环境路径损耗补偿因子来刻画信道特征^[30],具体公式为:

$$P_{r,ij} = P_{t,i} \left(\frac{c}{4\pi f d_{ij}} \right)^2 10^{-\eta/10} \quad (3-4)$$

其中 $P_{t,i}$ 为发射机 i 的发射功率, c 为光速, f 为载波频率, d_{ij} 为收发双方的距离, η 为附加城市环境路径损耗补偿因子, $P_{r,ij}$ 为接收机 j 的接收功率。

仿真中根据收发节点间是否存在建筑物遮挡将信道划分为视距信道和非视距信道。收发无人机 i 与 j 之间的遮挡状态取决于其连线段 $L(\mathbf{o}_i, \mathbf{o}_j)$ 是否与建筑物集合 $\mathcal{O}$ 中的任一矩形区域相交。如果接收机和发射机之间不存在建筑物遮挡,则为视距信道,其附加视距情况下城市环境路径损耗补偿因子为 η_{LOS} ; 如果接收机和发射机之间有建筑物遮挡,则为非视距信道,其附加非视距情况下城市环境路径损耗补偿因子为 η_{NLOS} :

$$\eta = \begin{cases} \eta_{LOS}, & L(\mathbf{o}_i, \mathbf{o}_j) \cap \mathcal{O} = \emptyset \\ \eta_{NLOS}, & L(\mathbf{o}_i, \mathbf{o}_j) \cap \mathcal{O} \neq \emptyset \end{cases} \quad (3-5)$$

根据城市环境信道建模相关论文[28],在本文给定的城市环境下设置对应的 $\eta_{LOS} = 1.0$, $\eta_{NLOS} = 20.0$ 。

由于干扰信号的存在,收发双方与干扰信号的距离差异会导致双方的 SINR 存在差异,因此需要通过计算双向信干噪比 SINR,并以通信门限 γ_{th} 作为通信链路是否双向连通的判断依据。 γ_{th} 是以 dB 为单位的通信门限,其大小取决于实际系统中接收机的解调阈值与最低服务质量 (Quality of Service, QoS) 要求。考虑上述因素下,从发射机 i 到接收机 j 的接收 SINR_{ij} 为:

$$\text{SINR}_{ij} = 10 \log \left(\frac{P_{r,ij}}{P_{r,pj} + N_0 B} \right) \quad (3-6)$$

其中 $P_{r,pj}$ 为接收机 j 接收到的干扰功率,在存在多个干扰节点的情况下为所有干扰节点干扰功率的累计值, N_0 为白噪声功率谱密度, B 为带宽。接收功率由发射功率、信道模型采用视距信道或非视距信道以及干扰功率计算得出。对无人机 u_i 和无人机 u_j 之间的通信链路,如果满足:

$$\text{SINR}_{ij} \geq \gamma_{th}, \text{SINR}_{ji} \geq \gamma_{th} \quad (3-7)$$

则认为 u_i 和 u_j 之间存在有效的通信链路。在此基础上,定义动态通信拓扑图 $G(t) = (\mathcal{U}, \mathcal{E}(t))$, $\mathcal{E}(t)$ 为 t 时刻整个无人机集群之间存在的有效单跳通信链路。如果任意两个无人机都存在有效的单跳或者多跳通信链路,即图 $G(t)$ 为连通图,则认为整

个无人机集群网络在 t 时刻是通信连通的。

3.3 分层分簇规划算法

为解决复杂城市作战环境下大规模无人机集群在路径规划过程中面临的全局可达性、通信连通性以及局部避障协同性等问题，本文提出一种基于分层分簇的通信保持路径规划算法 C-RRT*-APF。本节将分别从分层分簇规划总体架构、簇间距离约束的 C-RRT* 全局路径规划，以及基于最大 SINR 瓶颈生成树的 MBST-APF 局部路径规划三个方面对所提出算法进行详细说明。

3.3.1 分层分簇规划总体架构

本文提出的全局路径采样与局部人工势场法相结合的通信保持路径规划方法 C-RRT*-APF 总体框架如图 3-2 所示，算法首先在路径规划初始阶段执行分簇预处理，然后结合全局路径规划和局部路径规划进行分层路径规划。其中，全局路径规划层负责生成到达目标的全局参考路径点并进行簇间距离协调，同时引入感知驱动的全局路径重规划机制，以应对未知环境随感知信息探测而产生的动态更新；局部路径规划层负责簇内节点对建筑物、邻近无人机及电磁干扰的避让，并负责维持实时的通信连通性。




图3-2 C-RRT*-APF 算法框架示意图

Fig. 3-2 C-RRT*-APF algorithm framework diagram

在路径规划初始阶段,为保障算法对大规模无人机集群的可扩展性与稳定性,算法首先依据无人机的初始空间分布将其划分为若干簇。参考现有人工势场类算法的相关研究,并考虑到仿真中 CMUFC 算法随无人机规模扩大而出现的性能下降问题,本文将复杂城市场景下各簇的无人机数量限制在 10 架以内,以降低簇内多源势场叠加而导致的算法性能下降。在规划过程中,各无人机的簇从属关系保持固定,以确保全局规划的连续性。

全局路径规划层 C-RRT* 采用 RRT* 算法实时生成各簇的全局引导路径,以确保路径的可行性,同时通过设计簇间距离约束机制,对簇间路径的相对距离进行约束,从而在路径生成与重规划阶段实现簇间的安全间距保障,并为局部规划层提供通信连通保持的基础。感知驱动的全局路径重规划机制通过利用无人机实时感知更新的地图信息,对失效或违反约束冲突的全局路径进行重新规划,以确保全局路径的可达性。

局部路径规划层 MBST-APF 采用基于最大 SINR 瓶颈生成树的人工势场法实现单步路径规划。在单步规划过程中,每架无人机首先计算避障斥力,然后以全局参考路径中的下一关键路径点作为目标产生引导引力,同时算法在势场函数中引入基于最大 SINR 瓶颈生成树的通信引力项,对维持簇内连通的关键通信链路进行势能建模,引导无人机在局部运动中自动调整相对位置,主动补偿因电磁干扰或建筑遮挡导致的链路衰减或中断,从而完成单步规划位置的实时计算。局部层执行后的环境感知信息将实时反馈至全局路径层,用于重规划机制并实现跨层协同优化。

3.3.2 簇间距离约束的 C-RRT*全局路径规划

在算法的总体架构中,C-RRT* 全局路径规划层负责为各无人机簇生成可行的全局参考路径,并为 MBST-APF 局部规划层提供关键路径点引导。该模块以无人机簇为规划单位,通过单簇全局路径搜索机制在保证单簇路径可行性的同时,引入基于簇间距离约束的路径确认机制以维持集群不同簇的空间分布与通信连通性。本节首先介绍单簇条件下的全局路径搜索方法,然后给出基于簇间距离的路径确认机制,最后结合感知驱动的全局路径重规划机制,给出基于簇间距离约束的 C-RRT* 全局路径规划算法的完整实现流程。

3.3.2.1 单簇全局路径搜索

单簇路径搜索算法将以簇为单位,采用 RRT* 算法为小规模数量的无人机子集群生成从当前位置到达目标位置的全局路径,用于引导无人机避开建筑物以及干扰禁区。该全局路径会随着未知区域的更新而实时更新,主要由簇划分和全局路径搜索两个部分组成。

首先在簇划分阶段, 系统将根据无人机在初始时刻的空间位置分布和给定的单簇无人机数量 K 对所有无人机进行分簇, 尽可能均匀地将无人机分配到各簇, 得到对应的簇集合:

$$\mathcal{C} = \{C_1, C_2, \dots, C_{N/K}\}, C_i \subset \mathcal{U} \quad (3-8)$$

其中每个簇 C_i 的成员在整个规划过程中保持固定, 即无人机的簇归属保持不变, 并且各簇以 t 时刻的虚拟簇中心 s_i 作为全局路径规划的起始点:

$$s_i = \frac{1}{|C_i|} \sum_{u_j \in C_i} o_j(t) \quad (3-9)$$

同时算法将以虚拟簇目标中心点 g_i 作为目标点执行全局路径规划:

$$g_i = \frac{1}{|C_i|} \sum_{u_j \in C_i} o_j^g \quad (3-10)$$

在全局路径搜索阶段, 将采用 RRT* 算法为每个簇 C_i 独立搜索最优路径。该算法通过在状态空间 $\mathcal{A} \subset R^2$ 内进行随机采样并逐步扩展路径点组成的树结构 $\mathcal{T}$ 实现对单簇路径的搜索。

如图 3-3 所示, 以四架无人机组成的单个簇为例, 其具体搜索过程主要有以下八个步骤:

(1) 采样生成路径点: 如图 3-3 (a) 所示, 在每次迭代中, 采用目标偏置采样策略, 以概率 p_g 直接采样目标点 g_i , 以 $1 - p_g$ 的概率从区域 $\mathcal{A}$ 的可行区域中均匀随机采样得到 o_{rand} :

$$o_{rand} \in \mathcal{A} \setminus \mathcal{O}_t \quad (3-11)$$

其中 $\mathcal{O}_t \subseteq \mathcal{O}$ 为当前时刻所有传感器观测到的建筑物集合, 遵循乐观估计原则, 设定无人机集群当前时刻的未感知区域视作无障碍的可通行自由空间。

(2) 邻近父节点选择: 通过遍历当前已有树结构 $\mathcal{T}$ 中的所有节点, 检索与当前采样点最近欧几里得距离的路径点 o_{near} 作为父节点:

$$o_{near} = \arg \min_{o \in \mathcal{T}} \|o - o_{rand}\| \quad (3-12)$$

(3) 新路径点生成: 沿 o_{near} 指向 o_{rand} 的方向, 以全局规划步长 d_{step} 生成新路径点 o_{new} :

$$o_{new} = o_{near} + \frac{d_{step}(o_{rand} - o_{near})}{\|o_{rand} - o_{near}\|} \quad (3-13)$$

(4) 新生成路径碰撞检测: 若线段 $L(o_{near}, o_{new})$ 与当前观测环境信息 $\mathcal{O}_t$ 中的任意建筑物或干扰禁区无交集, 则将 o_{new} 加入树结构, 完成一次完整的采样扩展过程。

(5) 父节点重选: 如图 3-3 (b) 所示, 新采样节点生成后, 将为其 d_{step} 步长邻域范围内的候选父节点集合 $\mathcal{N}_{near} \subseteq \mathcal{T}$ 计算代价函数, 并选择累计代价最小的节点 (即路径最短的节点) 作为新的父节点:

$$Cost(o) = Cost(parent(o)) + \|o - parent(o)\| \quad (3-14)$$

(6) 邻域节点重布线优化: 如图 3-3 (c) 所示, 遍历当前新增节点 o_{new} 对应 d_{step} 步长邻域范围内的所有节点, 逐一检查 o_{new} 是否能为其邻域节点提供更短的路径, 是则更新该路径, 以实现搜索树的动态优化。




图3-3 单簇全局路径搜索示意图

Fig. 3-3 Schematic diagram of single-cluster global path search

(7) 满足条件时规划终止: 为满足当前全局路径规划算法的一定路径随机性需要, 本机制采取首次到达作为规划终止条件, 即当树中存在路径点 o 满足:

$$\|\mathbf{o} - \mathbf{g}_i\| \leq d_{move} \quad (3-15)$$

其中 d_{move} 为无人机局部路径规划中的单步最大运动距离，则判定当前全局路径搜索成功。

(8) 回溯获取全局路径：如图 3-3 (d) 所示，通过回溯当前新增节点的父路径点即可获得从起点 $\mathbf{s}_i$ 到目标点 $\mathbf{g}_i$ 的全局可行路径：

$$P_i = (\mathbf{s}_i, \mathbf{o}_{i,1}, \mathbf{o}_{i,2}, \dots, \mathbf{g}_i) \quad (3-16)$$

该单簇全局路径搜索机制保证了单簇全局路径在当前可观测环境下的可行性与一定的优化性，并结合建筑物集合 $\mathcal{O}_t$ 的动态感知更新机制能够实现对未知区域的自适应扩展。

3.3.2.2 簇间距离约束的路径确认

为避免不同簇之间独立规划的全局路径距离过近或过远，导致在干扰禁区以及建筑物周围引发集群通信协同失效的问题，本研究在 C-RRT* 全局规划中引入了簇间距离约束的路径确认机制。通过在全局路径层对各簇规划的全局路径的空间位置关系进行定量约束，该机制旨在防止路径过近引发的势场叠加与振荡，以及路径过远导致的通信链路难以维护，并在此基础上保障路径可达性。

首先为避免簇间全局路径过远导致簇间通信难以维护，引入 Fréchet 距离作为评估簇间路径相似性与间距的指标，并以此设定距离约束的上界 U 。Fréchet 距离可视为一种衡量两条离散路径在空间与时间维度上整体距离的指标，相较于欧氏距离，它能更准确地反映路径的形状差异和时间顺序上的对应关系。其计算过程可以形式化进行如下表示：

设两条不同簇对应的全局规划路径为 $P_i = (\mathbf{p}_{i,0}, \dots, \mathbf{p}_{i,k})$ 与 $P_j = (\mathbf{p}_{j,0}, \dots, \mathbf{p}_{j,l})$ ，则离散 Fréchet 距离定义为：

$$d_F(P_i, P_j) = \min_{\alpha, \beta} \max_t \|\mathbf{P}_i(\alpha(t)) - \mathbf{P}_j(\beta(t))\| \quad (3-17)$$

其中 α 和 β 为从 $[0,1]$ 映射到 $[0,1]$ 的连续单调递增重参数化函数。该函数用于保证两条路径在比较过程中具备时间维度的同步性，从而更准确地刻画集群在动态演进过程中的空间拓扑关系。在本算法中，若对应簇新生成的全局路径 P_i 与其余已经固定的簇路径 P_j 的 Fréchet 距离 $d_F(P_i, P_j)$ 不超过预设上界 U ，则认为该新的簇路径和其余的簇路径保持易于通信维护的空间分布；若 d_F 大于上界 U ，则表明当前簇的全局路径与其他簇的全局相距过远，在经过干扰禁区以及大型建筑时簇间通信难以通过后续的局部路径规划进行维护，从而破坏不同簇之间的网络连通性。同时为避免簇间全局路径过近导致簇间无人机拥挤、势场叠加而出现路径振荡，引入欧氏距离作为簇间距离约束的

下界。因后续路径由 Fréchet 距离动态约束，故只需要保证各个簇的首段全局路径最小欧几里得距离 d_E 大于 L 即可。如图 3-4 所示，展示了四个簇组成的无人机集群已规划的四条全局路径中的距离约束情况，其中存在两条不满足距离约束的全局路径后续需要重新进行规划。

在此基础上，为适应不同场景参数与无人机规模，需根据场景参数与集群规模设置合理的上下界区间 $[L, U]$ ，以同时保证跨簇的安全距离与整体通信协同性能。本算法基于无人机子簇规模、单机安全距离以及外部干扰半径等因素，构建了物理意义明确的路径约束上下界计算方法。




图3-4 簇间距离约束示意图

Fig. 3-4 Schematic diagram of inter-cluster distance constraint

首先，下界 L 用于确保不同簇之间在规划过程中保持必要的最小安全距离，避免簇间过度接近导致局部拥挤或碰撞风险。假定簇内部呈准正方形布置，则簇尺度可近似表示为 $\sqrt{(K)}d_{safe}$ 。因此，本文将不同簇路径的最小约束距离设为：

$$L = \alpha_L \sqrt{(K)}d_{safe}, \alpha_L \geq 1 \quad (3-18)$$

其中 α_L 为相关调整系数，用于根据不同场景的安全需求设置必要的安全裕度。

上界 U 用于限制跨簇全局路径的最大距离，从而防止在干扰环境下，簇间路径在遇到干扰时不同的簇分别在干扰禁区或大型建筑的两侧分开通行，导致簇间通信难以维

持。给定干扰源的有效干扰半径为 J_r ，则最大距离约束由干扰直径决定，本文将上界设为：

$$U = \alpha_U(2J_r), \alpha_U \leq 1 \quad (3-19)$$

其中 α_U 依据任务的通信覆盖需求与抗干扰要求进行适当调整，以满足 $L < U$ 并留有一定的裕度。

在生成单簇全局路径时，算法都会对规划生成的簇路径与其他已固定簇路径进行对应的距离校验。若与所有已固定的簇路径满足上述约束条件，则保留当前全局规划结果，确认该路径作为该簇当前的全局路径。

3.3.2.3 感知驱动的路径重规划

在单簇全局路径搜索与簇间距离约束机制的基础上，无人机集群已具备满足路径可行性与通信连通性的路径规划基础，但仅依靠初始时刻的静态规划难以应对复杂的环境信息未知的城市作战环境。若采取全部簇即时重规划，在增加计算开销的同时也容易导致已建立的簇间协同状态发生振荡。针对该问题，本节引入感知驱动的路径重规划机制，从而完整构建了融合全局路径生成与动态更新相结合的 C-RRT* 全局路径规划算法。

感知驱动路径重规划机制利用实时更新的环境信息对当前各簇的全局路径进行有效性验证，通过基于距离约束对失效路径的增量式重规划完成全局路径的实时更新。如图 3-5 所示，具体步骤主要分为以下四个步骤：

(1) 初始化操作：分别构建待检测路径集合 $\mathcal{P}_{check}$ 与已确认路径集合 $\mathcal{P}$ ，并设定初始状态为空集。

(2) 路径有效性验证：在簇内层面对所有无人机簇进行遍历，对当前簇对应的全局路径 P_i 进行有效性判定，包括路径是否因环境更新而失效、是否发生碰撞、以及是否已到达下一路径点的目标范围。若不满足有效性要求，则将对路径加入待重规划集合，即 $\mathcal{P}_{check} \leftarrow \mathcal{P}_{check} \cup \{P_i\}$ ；否则，将其路径加入已确认路径集合，表示为 $\mathcal{P} \leftarrow \mathcal{P} \cup \{P_i\}$ 。

(3) 重规划路径搜索：算法对集合 $\mathcal{P}_{check}$ 中的各簇依次执行单簇全局路径搜索。对于任一待重规划簇，其路径生成过程仅依赖于该簇的当前中心位置、目标中心位置以及当前环境感知信息，从而保证路径规划在簇内层面的独立性与可行性。该阶段对应单簇全局路径生成过程，为后续簇间协同提供备选路径。

(4) 簇间距离约束校验：在获得备选路径后，在簇间层面对路径进行距离约束校验。设当前生成的路径为 P_i ，并与已确认路径集合中的任一路径 $P_j \in \mathcal{P}$ 进行计算与已固定路径间距离判断其是否满足区间 $[L, U]$ 。若不满足则触发该簇路径的重新生成，利用 RRT* 生成新的备选路径，否则加入到已确认路径集合，直到所有簇路径有效。然后

执行局部规划层算法更新无人机位置与环境信息，重复直到所有无人机到达目标位置。




图3-5 感知驱动重规划机制

Fig. 3-5 Perception-driven replanning mechanism

该机制的关键在于簇间距离约束并不直接干预路径生成过程，而是以约束判定结果的形式反馈至簇内规划层，仅对随着环境信息以及无人机位置更新导致的违反约束或路径失效的簇触发局部重规划，而其余簇的路径保持不变。选择性更新策略有效避免了集中式全局重规划带来的计算负担，同时维持了不同簇之间的协同稳定性。

在上述交互机制下形成的基于簇间距离约束的 C-RRT* 全局路径规划完整流程如算法 1 所示。

算法 1 基于簇间距离约束的 C-RRT* 全局规划算法

输入：无人机各簇集合 C_i ，无人机起始位置集合 O_{start} ，目标集合 O_{target} ，初始环境信息 M_0 ，RRT* 规划步长 d_{step} ，距离约束上下界 $[L, U]$

输出：各簇实时全局参考路径集合 $\mathcal{P}(t)$

```

1: 初始化各簇中心  $s_i$  与目标  $g_i$ 
2: while 未满足所有簇到达目标区域 do
3:      $\mathcal{P}_{check} \leftarrow \emptyset$ ,  $\mathcal{P} \leftarrow \emptyset$ 
4:     for 每个簇  $C_i$  顺序执行:
5:         if RRT* 路径  $P_i$  为空或和  $M_t$  中当前建筑物碰撞或到达下一目标
           点范围
6:             将其加入  $\mathcal{P}_{check}$ 
7:         else 加入  $\mathcal{P}$ 
8:         end if
9:     end for
10:    for 每个簇  $C_i \in \mathcal{P}_{check}$  顺序执行:
11:        生成随机采样点  $o_{rand}$ 
12:        寻找最近路径点  $o_{near} \leftarrow Nearest(T_i, o_{rand})$ 
13:        沿方向扩展  $d_{step}$  生成新路径点  $o_{new}$ 
14:        if  $[o_{near}, o_{new}]$  与障碍物集合  $O_t$  不相交 then
15:            加入树结构  $T_i \leftarrow T_i \cup o_{new}$ 
16:            计算路径代价  $Cost(o_{new})$ ，并执行路径重布线优化
17:        end if
18:        if 路径  $P_i$  与其他簇  $C_i \in \mathcal{P}$  的  $P_j$  的距离未处于  $[L, U]$ 
19:            重新规划

```

```

20:         end if
21:     end for
22:     输出各簇的全局参考路径集合  $\mathcal{P}(t)$ 
23:     执行 MBST-APF 局部规划算法 2, 更新  $M_{t+1}$  和  $\mathcal{O}_{t+1}$ 
24: end while

```

3.3.3 最大瓶颈生成树引导的 MBST-APF 局部路径规划

本节针对无人机集群在复杂环境下的局部路径规划问题,介绍基于最大 SINR 瓶颈生成树引导的 MBST-APF 局部路径规划。该方法从通信拓扑构建与局部运动控制两个层面展开。首先基于最大 SINR 瓶颈生成树构建易于维护的通信主干网络,其次结合改进的人工势场法实现避障、路径跟踪与通信保持的协同优化。通过上述两个机制的协同设计,实现局部路径的可行性与通信连通保持。

3.3.3.1 基于 MBST 的通信主干构建机制

针对现有研究中通信保持机制存在的势场叠加复杂问题,本文在局部规划层引入基于最大 SINR 瓶颈生成树引导的通信主干构建机制,以最小化网络链路维护难度为目标,实时提取当前通信拓扑中的关键链路,从而降低通信保持力的复杂性以及因维护通信连通而产生的额外路径开销

本研究采用降序 Kruskal 算法为每一离散时刻 t 动态生成最大 SINR 瓶颈生成树 $MBST(t)$ 。具体而言,系统首先根据当前时刻 t 的信道状态计算所有无人机之间的通信链路的 SINR,并据此作为权重构建加权图 $G(t) = (\mathcal{U}, \mathcal{E}(t))$,其中节点集合 $\mathcal{U}$ 表示无人机节点,边集合 $\mathcal{E}(t)$ 表示节点间可建立的通信链路,每条边的权值定义为 $w_{ij} = \min(SINR_{ij}, SINR_{ji})$ 。

如图 3-6 所示,在此基础上执行降序 Kruskal 算法以获取当前时刻的最大 SINR 瓶颈生成树的基本步骤如下:

- (1) 将所有边按权值 w_{ij} 从大到小排序;
- (2) 初始化森林集合 $\mathcal{F} = \{\mathcal{U}\}$, 逐条遍历排序后的边;
- (3) 若当前边 (i, j) 连接的两个节点属于不同子集, 则将该边加入 $MBST(t)$, 并合并对应的子集;
- (4) 重复步骤 3, 依此添加连接不同无人机的边。
- (5) 获取有 $|\mathcal{U}| - 1$ 条边的最大 SINR 瓶颈生成树。




图3-6 Kruskal 算法构建通信骨干网络

Fig. 3-6 Kruskal algorithm for constructing the communication backbone network

该过程确保了在每个时刻生成的 MBST 拥有易于维护的通信主干网络结构。随着无人机的运动和信道环境的变化，系统每执行完单步规划会重新计算 SINR 并更新 $MBST(t)$ ，为后续人工势场法所需的通信保持力计算提供基础。

3.3.3.2 基于 MBST 的 APF 局部规划

基于 MBST 的 APF 局部规划通过基于最大 SINR 瓶颈生成树构建的主干通信保持网络，将局部避障、全局路径引导与通信保持等任务转化为连续的势场叠加问题，从而实现无人机的协同控制，确保无人机在复杂干扰与动态环境下保持单步路径可行的同时维持通信连通性与运动稳定性。

如图 3-7 所示，在该机制中，每个无人机 i 在时刻 t 的总作用力 $\mathbf{F}_i(t)$ 被分解为三个互补的力场分量：目标导向引力 $\mathbf{f}_{att,i}(t)$ 、碰撞避免斥力 $\mathbf{f}_{rep,i}(t)$ 与基于最大 SINR

瓶颈生成树的连通保持引力 $f_{coh,i}(t)$ 。第 i 个无人机在二维空间中受到的总合力向量为：

$$F_i(t) = \alpha f_{att,i}(t) + \beta f_{rep,i}(t) + \eta f_{coh,i}(t) \quad (3-20)$$

其中, $\alpha, \beta, \eta \in R^+$ 为吸引力、斥力与保持力分量的正权重系数, 用以反映不同任务场景下各分量在总合力中的相对重要性。参考文献[45]并结合一般情况下的经验参数, 为体现不同任务优先级, 通过数量级控制实现力场作用的分层调节, 满足:

$$\beta \gg \eta \approx \alpha \quad (3-21)$$

其中, $\gg$ 表示在数值尺度上相差至少一个数量级以上, 即满足 $\beta/\eta \geq 10 \sim 100$; $\approx$ 表示通信保持力的权重和目标引力的权重基本保持同一数量级。通过该数量级设计, 力场叠加模型能够在复杂城市环境下优先确保物理安全, 再考虑路径效率与通信保持。




图3-7 MBST-APF 局部规划示意图

Fig. 3-7 Schematic diagram of MBST-APF local planning

(1) 目标导向引力分量

目标导向引力分量 $f_{att,i}(t)$ 提供无人机全局路引导的驱动力, 其作用是将簇内的

无人机引导至全局 C-RRT* 所规划的下一关键点范围内。该分量由当前位置与目标点的向量差定义：

$$\mathbf{f}_{att,i}(t) = \mathbf{o}_{i,d} - \mathbf{o}_i(t) \quad (3-22)$$

其中 $\mathbf{o}_{i,d} = (o_{i,d,x}, o_{i,d,y}) \in R^2$ 表示由 C-RRT* 全局规划得到的该无人机所在簇的下一目标位置； $\mathbf{o}_i(t) = (o_{i,x}(t), o_{i,y}(t))$ 为当前时刻无人机的位置坐标。

(2) 碰撞避免斥力分量

碰撞避免斥力分量 $\mathbf{f}_{rep,i}(t)$ 负责无人机的局部安全控制，避免其与障碍物及其他无人机发生碰撞。设 $\mathcal{O}_i(t)$ 为当前时刻与无人机 i 保持在安全半径 s 内的障碍物集合 (包括建筑物和干扰等效的圆形区域)， $Neb_i(t)$ 为当前时刻与无人机 i 保持在安全半径 s 内的邻居集合，则该分量定义为：

$$\mathbf{f}_{rep,i}(t) = \sum_{j \in (\mathcal{O}_i(t) \cup Neb_i(t))} \phi(d(\mathbf{o}_i(t), \mathbf{o}_j)) \cdot \frac{\mathbf{o}_i(t) - \mathbf{o}_j}{\|\mathbf{o}_i(t) - \mathbf{o}_j\|} \quad (3-23)$$

其中 $d(\mathbf{o}_i(t), \mathbf{o}_j) = \|\mathbf{o}_i(t) - \mathbf{o}_j\|$ 表示欧几里得距离， $\phi(\cdot)$ 为分段势能函数：

$$\phi(d) = \begin{cases} \left(\frac{1}{d} - \frac{1}{s}\right) \cdot \frac{1}{d^2}, & d \leq s \\ 0, & d > s \end{cases} \quad (3-24)$$

该设计确保斥力仅在无人机进入危险范围内时生效，并随距离减小呈非线性增强，从而实现强制性碰撞规避，同时在安全范围外避免产生冗余力场干扰。

(3) 通信保持引力分量

为保证通信网络中最脆弱链路的质量尽可能高，从而提高整体集群网络的连通性维护效率，引入基于 MBST 的通信保持力分量 $\mathbf{f}_{coh,i}(t)$ 实现主干链路的维护。通过基于最大 SINR 瓶颈生成树构建的 $MBST(t)$ ，集群中每个无人机仅对其在 $MBST(t)$ 中的直接邻居节点施加对应的通信保持引力分量，其定义为：

$$\mathbf{f}_{coh,i}(t) = \sum_{(i,j) \in MBST(t)} F_{mbst}(i,j) \cdot \frac{\mathbf{o}_j(t) - \mathbf{o}_i(t)}{\|\mathbf{o}_j(t) - \mathbf{o}_i(t)\|} \quad (3-25)$$

其中 $F_{mbst}(i,j)$ 为 i 与邻居 j 之间的通信自适应引力幅值，定义为：

$$F_{mbst}(i,j) = \begin{cases} \left(\frac{1}{m_{eff}} - \frac{1}{m_r}\right) \cdot \frac{1}{m_{eff}^2}, & 0 < m_{eff} < m_r \\ 0, & otherwise \end{cases} \quad (3-26)$$

其中 $m_{eff} = \max(w_{ij} - s_{th}, \epsilon)$ 表示有效 SINR 裕度； s_{th} 为通信保持阈值， m_r 为裕度半径， ϵ 为数值稳定性常数。该机制能够在通信链路接近失效时增强引力以维持连通性，并在链路质量充足时减弱引力直至消失，从而在保持通信拓扑稳定的同时避免无人

机之间过度聚集。

最后局部 MBST-APF 算法为每个节点根据合力以及归一化速度更新下一步位置：

$$\mathbf{o}_i(t+1) = \mathbf{o}_i(t) + v_{\text{norm}}(\mathbf{F}_i(t)) \quad (3-27)$$

其中 $v_{\text{norm}}(\cdot)$ 为速度归一化函数，用于限制无人机的单步移动距离不超过 d_{move} ，保证局部运动的平滑性与稳定性。

对应的具体流程如算法 2 所示：

算法 2 基于 MBST 引力的 APF 通信连通保持算法

输入：当前无人机位置集合 $\sigma(t)$ ，各簇全局参考路径集合 $\mathcal{P}(t)$ ，当前环境信息 M_t ，单步移动步长 d_{move}

输出：下一时刻无人机位置集合 $\sigma(t+1)$

- 1: 计算无人机间链路 $SINR_{i,j}$
 - 2: 基于 SINR 构建最小生成树 $MBST(t)$
 - 3: for 每个无人机 i 并行执行:
 - 4: 以 $P_{i,1}(t)$ 为下一全局关键点计算目标导向吸引力 $f_{\text{att},i}(t)$
 - 5: 计算碰撞避免斥力 $f_{\text{rep},i}(t)$
 - 6: 计算 MBST 通信连通保持力 $f_{\text{coh},i}(t)$
 - 7: 计算总合力: $\mathbf{F}_i(t) = \alpha \cdot f_{\text{att},i}(t) + \beta \cdot f_{\text{rep},i}(t) + \eta \cdot f_{\text{coh},i}(t)$
 - 8: 更新位置: $\mathbf{o}_i(t+1) = \mathbf{o}_i(t) + v_{\text{norm}}(\mathbf{F}_i(t))$
 - 9: end for
 - 10: 输出 $\sigma(t+1)$
-

3.4 仿真实验与结果分析

本节围绕所提出的通信保持路径规划方法，在典型城市作战场景下开展系统性的仿真验证与性能分析。首先介绍了仿真场景搭建的相关场景参数以及实验对比所需的指标定义。然后通过典型场景规划效果对比、协同过程时序分析、性能分布统计、多场景适应性分析以及消融实验等多个方面，对所提方法的路径规划能力、通信连通保持性能及稳定性进行系统验证，并与基于冲突搜索类算法 K-CBS^[33]、启发式全局优化类算法

PPSwarm^[36]和人工势场类方法 APF、CMUFC^[45]等四种典型算法进行对比分析，全面评估其有效性与优势。

3.4.1 仿真实验设置

本节将首先介绍仿真实验的相关参数，包括具体的场景参数以及所用算法参数的设置，然后针对后续实验结果分析所需的相关性能指标的定义进行说明。

3.4.1.1 参数设置

本文设场景为 $L_x = L_y = 1 \text{ km}$ 的正方形区域，该尺度下无人机空间分布及通信交互主要发生在百米尺度范围内，符合一般城市作战路径规划场景设置。为刻画不同环境复杂度对路径规划与通信性能的影响，设建筑物数量 $M = \{10, 20, 30\}$ 中离散取值，分别对应低、中及高密度三类典型场景，在该区域尺度下，较少的建筑物数量表示场景较为开阔，障碍物对路径约束较弱，随着建筑物增加，建筑物分布趋于密集，可行通道数量减少，路径规划复杂度显著提升，同时建筑遮挡效应增强，对通信链路稳定性产生进一步影响。设无人机数量 $N = \{12, 24, 36\}$ ，分别对应低、中和高节点数量情况，无人机碰撞避免安全半径设为 $s = 10 \text{ m}$ ，局部规划步长为 $d_{move} = 5 \text{ m}$ ，全局规划步长为 $d_{step} = 200 \text{ m}$ 。本文采用等效全向辐射功率 (Equivalent Isotropically Radiated Power, EIRP) 表示通信与干扰信号的发射功率，并设所有节点采用全向天线。在此基础上，通信信号与干扰信号在相同频段与带宽内传播，从而构建同频宽带干扰模型。设通信系统工作频率 $f = 2.4 \text{ GHz}$ 、通信带宽 $B = 1 \text{ MHz}$ 、无人机发射功率 $P_i = 25 \text{ dBm}$ 、噪声功率谱密度 $N_0 = -174 \text{ dBm/Hz}$ ，并根据一般物理场景下的实际需求，设对应的 SINR 解调门限 $\gamma_{th} = 10 \text{ dB}$ 。同时设置干扰源数量 $N_j = \{1, 2, 3\}$ 、干扰功率 $P_j = 20\text{--}30 \text{ dBm}$ 内离散取值，以刻画干扰功率由弱至强变化对通信保持性能的影响。在测试干扰数量对算法性能的影响中，三个干扰源分别位于正方形区域场景中的 $(500\text{m}, 500\text{m})$ 、 $(900\text{m}, 200\text{m})$ 与 $(250\text{m}, 450\text{m})$ 位置，干扰功率均为 25 dBm 。按无人机之间相距 3 倍最小安全距离下（以保证留有一定通信裕度，为无人机绕行干扰附近建筑物提供中继能力）且 SINR 与通信门限相当的情况，计算得到对应的干扰半径 J_r 的公式为：

$$J_r = \sqrt{\frac{P_j}{\frac{P_i}{\gamma_{th}(3s)^2} - N_0 B \cdot \frac{4\pi}{\lambda} 10^{\frac{\eta_{LOS}}{10}}}} \quad (3-28)$$

代入相关场景参数可以计算出对应干扰功率区间内的干扰半径 $J_r = 50 \sim 170 \text{ m}$ 。考虑避障优先通用原则，局部规划中设目标引力系数 $k_{att} = 10$ 、斥力系数 $k_{rep} =$

1000 、通信保持力系数 $k_{coh} = 1$ 。相关具体的仿真参数设置如表 3-1 所示。

表3-1 路径规划仿真参数设置

Table 3-1 Simulation parameter settings of path planning		
参数	符号/说明	值
场景大小	$L_x \times L_y$	1 km x 1km
无人机数量	N	12,24,36
无人机功率	P_i	25 dBm
建筑物数量	M	10,20,30
干扰源功率	P_j	20- 30 dBm
首个干扰源位置	o^J	(500m, 500m)
载波频率	f	2.4 GHz
SINR 门限	γ_{th}	10 dB
系统带宽	B	1 MHz
噪声功率谱密度	N_0	-174 dBm/Hz
C-RRT*规划步长	d_{step}	200 m
APF 单步规划步长	d_{move}	5 m
下门限系数	α_L	1.0
上门限系数	α_U	1.0
引力系数	k_{att}	10
斥力系数	k_{rep}	1000
通信保持力系数	k_{coh}	1
安全半径	s	10 m
干扰半径	J_r	50 m - 170 m

3.4.1.2 评价指标

为了定量评价算法的性能，研究采用通信连通率与平均到达时间作为主要指标。通信连通率用于衡量算法在整个执行过程中保持通信连通的占比，其定义为算法执行过程中无人机网络连通的时间占总时间的比例。计算方法为在每个离散时间步 t 根据满足 SINR 双向门限约束的链路构建通信图 $G(t)$ 。若该图仅包含一个连通分量，则认为无人机集群在该时刻保持网络连通；若存在两个及以上连通分量，则表示通信拓扑发生分裂。设算法路径规划执行的最大到达时间为 T_{max} ， $C(t)$ 为 t 时刻网络连通分量数，则定义指示函数 $I[C(t) = 1]$ 表示在第 t 步通信图是否连通，算法的通信连通率可定义为：

$$R_{conn} = \frac{1}{T_{max}} \sum_{t=1}^{T_{max}} I[C(t) = 1] \quad (3-29)$$

其中， $I[\cdot]$ 为指示函数，当括号内条件成立时取值为 1，否则取值为 0。通信连通率越

高,说明在算法执行过程中无人机网络保持连通的能力越强,也意味着算法在复杂环境下对局部干扰或障碍的适应性更好。

平均到达时间为统计无人机集群中所有无人机从起始点到目标点的所使用时间 T_i 的均值:

$$\bar{T} = \frac{1}{N} \sum_{i=1}^N T_i \quad (3-30)$$

该指标能够量化算法在全局路径规划过程中无人机网络的规划效率,数值越小代表算法整体的规划效率更高。

3.4.2 仿真结果分析

本节主要从五个方面进行算法性能分析:通过路径规划效果对比与过程展示,分析不同算法的规划机制差异;结合规划过程的时序状态特性,说明系统在规划效率与连通保持方面的动态特性;通过典型场景重复实验对比不同算法指标分布评估算法稳定性;进一步通过多参数变化场景下重复实验以验证其适应能力;最后通过消融实验分析所提关键机制的具体贡献。综合上述内容对所提方法的有效性与优势进行全面验证。

3.4.2.1 典型场景规划效果对比

为直观验证所提方法在复杂环境下的路径规划效果与通信保持性能,选取大规模典型场景开展对比实验。该场景中设置单一中心干扰源,并包含 20 栋建筑物与 36 架无人机,其具体参数配置如 3.4.1.1 节所示。在该场景下,采用 4 种对比算法分别进行路径规划,并展示其对应的轨迹结果。其中,针对所提 C-RRT*-APF 方法,进一步给出规划过程中的中间状态图,以展示关键机制在规划过程中的作用。

如图 3-8 所示,分别给出了 K-CBS、PPSwarm、APF 以及 CMUFC 四种对比算法在该典型场景下的路径规划轨迹。从整体规划效果来看,不同算法在路径平滑性、避障表现以及通信约束下的行为存在明显差异。具体而言,K-CBS 算法基于冲突搜索机制,通过处理无人机间的时序冲突实现路径规划,其主要关注冲突解决而非路径优化,因此生成的路径存在较为明显的绕路与抖动现象,整体平滑性较差。PPSwarm 算法在此基础上引入粒子群优化启发式搜索策略,对路径进行进一步优化,使得规划路径整体更加平滑,同时路径长度有所缩短,规划效率相较于 K-CBS 得到一定提升。相比之下,APF 算法由于缺乏全局规划机制,在靠近干扰源区域时易受到势场作用的影响产生局部振荡,导致无人机在干扰附近区域反复调整,降低了规划效率,并且不同无人机的路径重合度较高。CMUFC 算法通过引入邻居引力等通信保持机制,使无人机在规划过程中倾向于在

干扰同侧协同运动，但由于多种势场之间存在较强耦合作用，整体势场结构复杂，导致路径振荡现象较为严重，同时增加了规划计算开销。




图3-8 典型场景路径规划过程轨迹图

Fig. 3-8 Trajectory diagram of the path planning process in the typical scenario

如图 3-9 所示进一步给出了所提 C-RRT*-APF 算法的路径规划过程及最终轨迹结果，其中中间过程图主要用于展示分层分簇规划机制的具体实现效果。如图所示在规划过程中，所提算法通过全局采样为不同簇生成满足距离约束的全局路径，并结合通信约束构建最大 SINR 瓶颈生成树，以此作为简化势场后的通信保持引力基础，从而显式给出关键通信链路关系，有效降低了势场计算复杂度。在此基础上，各无人机在局部人工势场的引导下进行单步路径规划与避障调整。由最终轨迹图可以看出，无人机整体沿干扰同侧协同穿越障碍区域，路径分布更加均衡且平滑性较好。相较于 CMUFC 算法，所

提方法在保证通信连通性的同时显著降低了路径振荡现象, 轨迹更加平滑, 体现出更高的路径规划效率与稳定性。




图3-9 C-RRT*-APF 算法路径规划

Fig. 3-9 C-RRT*-APF algorithm path planning

综合上述对比分析可以看出, 所提方法在多方面均表现出明显优势。相较于 K-CBS 与 PPSwarm 算法, 所提方法能够在未知环境中结合在线感知信息实现自适应路径规划, 具备更强的环境适应能力; 相较于传统 APF 算法, 所提方法通过引入全局路径规划机制, 有效避免了因干扰导致的局部振荡问题, 并实现了路径规划与通信约束的协同优化; 同时, 相较于 CMUFC 算法, 所提方法通过分层分簇与最大 SINR 瓶颈树对势场结构进行简化, 降低了多势场耦合带来的复杂度, 从而在保证通信连通性的前提下提升了整体规划效率与路径质量。

3.4.2.2 协同规划过程时序分析

为进一步分析不同算法在路径规划过程中的时序动态特性, 本节选取所提典型场景, 对单次规划过程中不同算法的多项时序指标进行对比分析。具体而言, 通过统计随时间变化的到达无人机数量、平均节点度以及最大连通分量节点数目, 分别从路径规划效率与集群通信保持效果两个方面对各算法性能进行对比。

如图 3-10 所示为各算法在典型场景下到达无人机数量随时间变化的时序对比结果。从整体趋势来看, K-CBS 算法与 PPSwarm 算法能够在较短时间内实现全部无人机到达, 其主要原因在于两者均基于全局已知环境信息进行路径规划, 能够在初始阶段生成较为完整的可行路径, 从而具备较高的规划效率, 同时集群到达过程呈现出较强的同步

性。其中，PPSwarm 算法由于引入了基于粒子群优化的路径启发式搜索机制，在路径质量与规划效率上进一步优于 K-CBS 算法，因此整体到达时间相对更短。相比之下，所提 C-RRT*-APF 算法的到达时间略高于上述两种方法，这是由于其针对未知环境下依赖实时感知信息进行路径规划，需要在规划过程中持续更新环境信息并进行动态调整，从而在一定程度上增加了时间开销。然而，与 APF 算法和 CMUFC 算法相比，所提方法在到达效率上具有明显优势。APF 算法由于缺乏全局路径引导，势场设计存在局部极小值问题，在干扰区域附近易陷入局部振荡现象，导致无人机在局部区域反复调整路径，从而显著延长整体到达时间，并且无人机到达时间严重不同步；CMUFC 算法则由于多势场耦合作用较为复杂，在规划过程中同样存在较为明显的路径振荡问题，增加了整体规划耗时，但其全链路吸引机制使得无人机整体到达过程具有较强的一致性。




图3-10 到达无人机数量时序图

Fig. 3-10 Time series of the number of arrived UAVs

如图 3-11 以及图 3-12 所示进一步给出了各算法在规划过程中平均节点度与最大连通分量规模的时序变化情况，分析不同方法在通信连通保持方面的性能差异。如图 3-11 所示，从平均节点度来看，在无人机逐渐接近中央干扰区域的中期阶段，K-CBS 算法、PPSwarm 算法以及 APF 算法由于缺乏有效的通信保持机制或其保持能力较弱，节点间连接数量明显减少，整体平均节点度维持在较低水平，表明网络连接较为稀疏。所提 C-RRT*-APF 算法通过引入基于最大 SINR 瓶颈生成树的关键链路通信保持机制，在干扰区域仍能够维持相对较高的节点连接数量，使得平均节点度明显高于上述三种算法，从

而有效增强了网络的局部连通性。相比之下，CMUFC 算法由于采用全链路吸引机制，在整个规划过程中维持了更高的平均节点度，但其连接关系较为冗余，增加了系统复杂度。




图3-11 平均节点度时序图

Fig. 3-11 Time series of average node degree

如图 3-12 所示，从最大连通分量规模的变化来看，K-CBS、PPSwarm 以及 APF 算法在规划过程中均存在较为明显的振荡现象，导致网络频繁发生分裂，整体连通性较差；CMUFC 算法在大部分时间内能够保持较大的连通分量，但在部分时间段仍存在少数节点因路径振荡长时间脱离主网络的情况。相比之下，所提算法在整个规划过程中仅在少数时刻出现短暂的网络分裂，并能够依靠局部 MBST-APF 机制迅速恢复连通状态，表现出更好的连通保持能力与恢复性能。

综合上述时序对比分析可知，所提 C-RRT*-APF 算法在复杂环境下展现出显著的综合优势。在路径规划效率方面，所提算法虽因实时感知未知环境增加了部分路径开销，但相比 APF 和 CMUFC 算法显著减少了路径振荡，有效缩短了集群整体到达时间。在通信保持方面，本文算法通过基于最大 SINR 瓶颈生成树的关键链路通信保持机制，在干扰区域仍能保持较高的平均节点度，且网络连通分量的稳定性明显优于 K-CBS 等对比算法。此外，所提算法具备更强的网络分裂修复能力，能够在短时间内重新建立稳定连接。综上，所提算法有效平衡了路径规划的动态实时性与集群通信的连通稳定性。




图3-12 最大连通分量时序图


Fig. 3-12 Time series of largest connectivity component

3.4.2.3 性能分布与稳定性分析

为进一步分析不同算法在路径规划过程中由于算法内部采样或启发式搜索的初始化等随机因素导致的执行差异，本节选取典型实验场景，对各算法进行 40 次独立重复实验。通过统计平均到达时间与通信连通率两项核心指标的分布情况，综合评价各算法在复杂任务环境下的执行稳定性。由于传统 APF 算法不具备随机性，其在固定参数下的规划结果保持一致，故本节对比分析主要针对具备随机采样或启发式搜索特性的 C-RRT*-APF、CMUFC、PPSwarm 及 K-CBS 算法。

如图 3-13 所示，从性能指标的统计分布来看，所提算法在路径规划效率与通信保持性能上展现出显著优势。在平均到达时间方面，PPSwarm 与 K-CBS 算法由于基于全局先验信息减少了随机搜索的不确定性，其分布极其集中且数值较低，体现了较高的规划效率；相比之下，CMUFC 算法的分布方差较大，部分实验达到所设置的 600 s 最大时间上限，这表明其在多势场耦合作用下极易产生路径振荡甚至死锁，导致规划效率严重低下或无法完成路径规划任务。所提 C-RRT*-APF 算法的到达时间均值虽然略高于全局规划算法，但其箱体高度较窄，表明在未知环境下仍能保持良好的执行稳定性，不存在极端离群值。在通信连通率方面，所提算法的优越性更为突出。实验结果显示，C-RRT*-APF 的连通率中位数达到 95%，且概率密度高度集中在高位区间，显著优于通信连通率分布在 40% 左右的 PPSwarm 与 K-CBS 算法。CMUFC 算法的通信连通率均值接

近 78%，低于所提算法且整体分布方差极大，说明其通信保持性能在不同随机实验中波动显著，稳定性不足。



(a) 平均到达时间 (a) Average arrival time (b) 通信连通率 (b) Communication connectivity rate

图3-13 不同算法指标分布

Fig. 3-13 Distribution of performance metrics for different algorithms

综上所述，本文所提算法在确保无人机集群高效到达目标区域的同时，实现了显著优于对比算法的通信连通保持性能。统计分布结果表明，该算法不仅在两项关键性能指标上具有显著优势，且在多次独立实验中表现出极高的鲁棒性与执行稳定性，有效规避了现有改进人工势场算法常见的死锁与振荡风险。

3.4.2.4 多场景参数适应性分析


为全面评估本文所提 C-RRT*-APF 算法在不同环境规模与干扰强度下的鲁棒性与有效性，本节开展了多场景参数适应性对比实验。实验选取建筑物数量、无人机集群规模、干扰节点数量以及干扰功率强度作为核心变量，针对每组参数配置分别进行 30 次独立重复实验，统计并分析各算法在平均到达时间与通信连通率两项关键指标上的性能表现。通过将所提算法与 CMUFC、PPSwarm、K-CBS 及传统 APF 算法进行对比，验证其在复杂城市作战环境下的适应能力。

如图 3-14 所示，在不同建筑物数量、无人机数量及干扰节点数量的场景下，各算法性能表现呈现出显著差异。如图 3-14 (a) 与 (b) 所示，在不同建筑密度场景下（建筑数量分别为 10、20 和 30），各算法的性能随环境复杂度增加均呈现下降趋势，但下降幅度存在显著差异。总体来看，随着建筑物数量的增加，环境遮挡增强、可通行空间收缩，各算法的路径规划难度显著提升，表现为平均到达时间增加、通信连通率下降。其中，所提 C-RRT*-APF 算法在通信连通率指标上始终保持最优，在平均到达时间指标上保持次优，体现出良好的环境适应能力。在平均到达时间方面，C-RRT*-APF 相较于 CMUFC 与传统 APF 算法具有明显优势，其随建筑数量增加的增长幅度较小，说明全

局关键点引导机制能够有效减少路径振荡以及降低死锁发生的概率；同时，相较于 PPSwarm 与 K-CBS，后两者在各复杂度环境下具有一定时间优势，但其依赖全局先验信息的规划方式难以适用于实时感知的未知环境。在通信连通率方面，所有算法均随建筑数量增加而下降，但 C-RRT*-APF 始终维持最高水平，且下降幅度更小。这主要归因于其在全局层通过关键点引导规避建筑遮挡区域以减少物理阻断，在局部层通过 MBST-APF 动态维持主干通信链路，二者协同作用有效降低了因建筑阻挡引起的链路中断概率。

如图 3-14 (c) 与 (d) 所示，在不同无人机规模场景下（无人机数量分别为 12、24 和 36），算法性能主要受系统规模扩展带来的协同复杂度影响。总体趋势表明，随着无人机数量增加，无人机间的势场耦合与冲突处理复杂度随规模增加而显著上升，部分算法出现明显性能下降，而所提算法表现出较强的规模鲁棒性。在平均到达时间方面，CMUFC 与传统 APF 随规模增大出现显著增长，主要由于多源势场叠加导致的路径振荡与局部拥堵问题加剧；相比之下，C-RRT*-APF 的到达时间变化幅度较小，表明其分簇分层架构有效控制了规模扩展带来的耦合复杂度增长，路径规划效率随规模增加的退化幅度显著小于对比算法。同时，PPSwarm 与 K-CBS 在各个无人机集群规模下都具有更快的规划速度，略优于所提算法。在通信连通率方面，所提算法始终保持稳定且领先的表现，且随规模增加波动较小，这得益于固定分簇结构将大规模网络划分为相对独立的子网，关键点引导机制在规模扩展时仍能维持簇间核心链路的稳定性；而对比算法在规模增大时更容易出现局部链路断裂或网络分裂，导致连通率下降更加明显。

如图 3-14 (e) 与 (f) 所示，不同干扰节点数量场景下，算法性能主要受到多源干扰叠加效应的影响。总体来看，随着干扰节点数量增加，各算法的通信性能显著下降，但路径规划效率受影响程度存在差异。对于平均到达时间，所提算法随干扰节点数量增加仅出现轻微增长，表明其路径规划过程对干扰分布具有较强的规避能力；而 CMUFC 与 APF 在干扰增多时易陷入局部极小或产生路径振荡，导致到达时间显著增加。PPSwarm 与 K-CBS 虽在部分场景下到达时间较短，但随干扰区域增多，需绕行的路径增长，平均到达时间出现小幅增加。在通信连通率方面，C-RRT*-APF 的下降幅度最小，始终维持较高水平，这主要源于簇间距离约束与关键点引导机制能够有效规避强干扰区域，同时通过主干链路维持策略保证核心通信结构的稳定；相比之下，其余算法在多干扰环境下更容易出现链路中断或网络分裂问题。




(a) 不同建筑数量平均到达时间对比

(b) 不同建筑数量通信连通率对比

(a) Comparison of average arrival time under different building numbers

(b) Comparison of communication connectivity rate under different building numbers




(c) 不同无人机数量平均到达时间对比

(d) 不同无人机数量通信连通率对比

(c) Comparison of average arrival time under different numbers of UAVs

(d) Comparison of communication connectivity rate under different numbers of UAVs



(e) 不同干扰数量平均到达时间对比

(f) 不同干扰数量通信连通率对比

(e) Comparison of average arrival time under different numbers of interference

(f) Comparison of communication connectivity rate under different numbers of interference

图3-14 不同参数规模下算法指标对比

Fig. 3-14 Comparison of algorithm performance metrics under different parameter scales

如图 3-15 所示，在干扰功率变化场景中（干扰功率从 20 dBm 到 30 dBm 增加），首先从平均到达时间角度分析可以看出，随着干扰功率从低水平逐步提升至高水平，各算法的到达时间整体变化较为平缓，未出现显著增长趋势。这表明干扰功率的增强主要影响通信质量，而对路径长度无显著直接影响。其中，C-RRT*-APF 在全功率区间内均保持较低且稳定的到达时间，说明其在引入通信约束的同时，并未产生明显的绕行代价；而 CMUFC 由于对通信质量施加强约束，维护通信连接所需的势场计算复杂度随干扰功率变化而波动，导致其路径规划效果的稳定性不足。PPSwarm 与 K-CBS 的时间性能相对稳定，数值略小于所提算法。




图3-15 不同干扰功率平均到达时间对比

Fig. 3-15 Comparison of average arrival time under different interference power levels

如图 3-16 与图 3-17 所示，进一步结合通信连通率与归一化代数连通度进行分析可以发现，随着干扰功率增加，所有算法的连通性能均呈现下降趋势，但下降幅度存在明显差异。C-RRT*-APF 在整个功率区间内始终保持最高的通信连通率，且下降过程平滑，体现出较强的抗干扰稳定性；同时，其归一化代数连通度也显著高于对比算法，说明其在拓扑结构层面仍能维持较强的整体连通性。这主要得益于算法仅对主干关键链路施加通信约束，避免了所有节点之间全链路的势场耦合计算，从而在保证核心连通性的同时降低了势场耦合强度。相比之下，PPSwarm 与 K-CBS 在高干扰功率下连通度下降更明显，而 CMUFC 由于过度依赖全局通信约束，在强干扰环境中更易出现整体性能退化。




图3-16 不同干扰功率通信连通率对比

Fig. 3-16 Comparison of communication connectivity rate under different interference power levels




图3-17 不同干扰功率代数连通度对比

Fig. 3-17 Comparison of algebraic connectivity under different interference power levels

上述结果从建筑密度、集群规模、干扰数量与干扰功率四个维度验证了所提 C-RRT*-APF 算法在通信连通率与路径规划效率两项指标上的综合优势。通过分层分簇的全局与局部协同规划框架以及关键链路维持机制,该算法在保证通信连通性的同时有效控制路径规划开销,实现了效率与鲁棒性的平衡。相较于对比算法,其不仅在复杂环境下保持更高的通信连通率与拓扑稳定性,同时在到达时间指标上也具有优势,充分验证了其在多参数复杂场景中的优越性能。

3.4.2.5 关键机制消融实验

为进一步验证所提出 C-RRT*-APF 各关键机制对整体性能的贡献,本节在干扰数量为 1、干扰功率为 25 dBm 以及建筑数量为 20 的典型场景下进行了消融实验对比,如表 3-2 所示。从结果可以看出,所提的完整 C-RRT*-APF 算法在通信连通率与平均到达时间两项指标上均取得最优表现,其中通信连通率达到 95%,平均到达时间为 297 s,均优于移除任一核心机制的版本。

表3-2 典型场景下的消融实验对比

Table 3-2 Ablation study comparison in the typical scenario

指标/算法	C-RRT*-APF	C-RRT*-APF-无 MBST	C-RRT*-APF-无距离约束
通信连通率	95%	64%	59%
平均到达时间 (s)	297	308	351

当去除局部 MBST 引力项后(C-RRT*-APF-无 MBST),通信连通率由 95% 降至 64%,下降幅度较大,而平均到达时间略微有所增加。这说明局部 MBST 引力项主要用于维持邻近无人机通信链路的连通性,其缺失将导致局部通信链路在无人机偏离连通位置时无法得到有效引导,进而引发链路中断频率上升,从而显著降低整体网络的连通率,但对路径代价影响有限。

相比之下,当移除簇间距离约束机制后(C-RRT*-APF-无距离约束),通信连通率降至 59%,且平均到达时间显著增加约 18%。其原因在于,缺少簇间距离约束机制将导致不同簇在经过干扰时会产生分裂的情况,并且在缺少簇间距离约束后局部 MBST 引力仍然能够在一定程度上保持连通性,但由于缺乏跨簇路径引导与全局距离控制,局部 MBST 引力在缺乏全局簇间距离约束控制时易使无人机陷入局部振荡,导致无效路径搜索开销显著增加,整体规划效率显著下降。

综上,局部通信保持与全局簇间距离约束机制在提升连通率与规划效率方面均发挥关键作用,且两者协同作用显著增强了算法的整体性能与稳定性。所设计的局部 MBST-

APF 连通保持与簇间距离约束机制均有效提升了算法在通信保持方面的整体性能。

3.5 本章小结

本章针对复杂城市作战环境下大规模无人机集群通信保持路径规划问题进行系统建模与算法验证。首先针对城市建筑遮挡与敌对电磁干扰并存的场景，对无人机运动模型、环境模型及基于 SINR 的通信约束进行了形式化描述。然后，提出了一种基于分簇分层的通信保持路径规划方法 C-RRT*-APF，将全局路径规划与局部通信保持机制相结合。其中，在全局规划层面引入簇间距离约束以实现多簇全局路径的生成，在局部规划层面采用基于最大 SINR 瓶颈生成树的人工势场法实现通信保持。最后，通过多组仿真实验从不同方面对所提方法在不同环境复杂度与干扰条件下的运行情况进行了验证，表明算法取得了预期的效果与提升。

第四章 基于多种群引导协同进化的通信保持区域覆盖算法

4.1 引言

无人机集群凭借高机动性、灵活部署能力及动态组网优势，在持续侦察与战场监测等作战任务中展现出巨大的应用需求。区域覆盖部署作为侦察任务的核心环节，其目标是在有限的无人机数量与复杂作战环境约束下，实现对任务区域低空洞和低冗余的感知覆盖以进行持续的监视与侦察。然而，在实际作战与应用场景中，单纯追求覆盖指标难以满足任务需求，智能无人机集群的发展要求无人机之间必须维持稳定、可靠的通信链路以支持协同感知、信息共享与联合决策。因此，区域覆盖侦察部署不仅是几何意义上的优化问题，更是一个受制于通信约束和网络拓扑结构的复杂耦合问题，如何在复杂的电磁干扰环境约束下解决空间覆盖最大化与网络抗损毁通信保持之间的平衡，已成为当前研究的重点与难点。

当前的无人机区域覆盖侦察部署研究很大程度上沿用了无线传感器网络的理论框架，现有研究大致可分为基于几何规则的确定性方法与基于元启发式的智能优化方法两大类。以虚拟力法、网格法及 Voronoi 图法为代表的确定性方法，虽然在简单场景下具有计算简便、物理意义明确的优势，但在处理存在建筑遮挡以及电磁干扰的复杂环境时往往效果不佳，容易陷入局部极值且难以显式建模网络拓扑约束。随着问题复杂度的提升，基于群智能的元启发式算法逐渐成为主流，研究目标也从早期利用遗传算法、粒子群算法求解单优化目标最大化覆盖问题，演进为利用 NSGA-II、MOEA/D 等多目标进化算法在覆盖率、连通性、能耗等多个相互冲突的目标之间寻找帕累托最优解集，旨在为决策者提供多样的解决方案。

尽管多目标进化算法在无人机覆盖部署领域已有很多理论研究，但在面向复杂的城市作战环境与强对抗场景时，现有研究仍存在显著局限，主要表现为在通信约束建模方面较为简单，通常采用理想化的通信半径或简化的连通性假设，忽略了城市环境中建筑物遮挡造成的非视距传输损耗以及敌对信号带来的电磁干扰影响。当环境复杂度提高并引入干扰信号后，问题的非线性和不确定性显著增强，解空间将呈现高度多峰特征，导致常规的多目标优化算法的搜索效率和收敛性能明显下降，难以在有限计算资源内获得覆盖率与连通度最优的高质量前沿解。

针对上述问题，本章提出一种基于多种群引导协同进化的通信保持区域覆盖算法

MPG-NSGA-II, 旨在解决复杂干扰与建筑物遮挡环境下的无人机集群协同覆盖与连通优化问题。本章首先构建了更符合实际的区域覆盖部署系统模型, 引入视距与非视距信道模型及信干噪比 SINR 约束, 显式考虑建筑物遮挡与干扰源分布对实际通信链路的影响。在此基础上, 所提算法首先设计了一种连通-贪心覆盖混合的初始化策略, 有效提高了初始种群的多样性和质量。然后为改善传统随机性变异的盲目性, 本章提出了基于区域覆盖领域知识的局部启发式引导变异算子, 包括利用 Voronoi 单元几何特性的覆盖引导算子与针对最小度节点的通信连通引导算子, 用于有效引导变异方向。最后, 通过建立基于迁移岛模型的多种群精英迁移与协同重组机制, 实现多种群协同进化, 平衡了算法的全局探索与局部开发能力, 提高了算法的搜索效率, 有效克服了复杂环境下的早熟收敛问题, 显著提升了帕累托前沿解的质量与分布效果。

4.2 系统模型

在所提研究目标基础上, 为描述复杂城市环境下无人机集群的覆盖与连通优化问题, 本节从场景模型和优化问题建模两方面构建了明确的系统模型。首先场景模型部分以二维城市区域为基础, 综合考虑建筑物遮挡、干扰信号影响以及无人机感知与通信能力, 对任务区域、单机覆盖行为及集群通信拓扑进行规范化建模。其次优化问题建模部分通过引入视距约束与通信门限, 实现对覆盖性能与连通性能的统一量化表达, 并进一步将其转化为多目标优化问题, 为后续算法机制设计与实验分析提供基础。

4.2.1 场景模型

本文将区域覆盖场景建模为二维矩形区域 $\mathcal{S} \subset R^2$, 其大小为 $[0, L_x] \times [0, L_y]$ 。如图 4-1 所示, 若干建筑物和干扰源位于对应的矩形二维区域中。建筑物集合表示为 $\mathcal{O} = \{O_1, O_2, \dots, O_M\}$, 其中, M 为建筑物数量, 建筑物 $O_j \subset \mathcal{S}$ 为矩形; 单个干扰源 J 的位置为 $\mathbf{o}^J = (o_x^J, o_y^J)$, 其干扰功率为 P_J ; 无人机集群表示为 $\mathcal{U} = \{u_1, u_2, \dots, u_N\}$, 其中 N 为无人机数量, 每架无人机 u_i 部署位置为 $\mathbf{o}_i = (o_{i,x}, o_{i,y})$ 。每架无人机 u_i 搭载全向传感器, 其最大有效感知覆盖半径为 R_s , 可以对感知半径范围内无视距遮挡的区域进行覆盖侦察。

为保障无人机安全, 无人机与其他无人机、建筑物之间需满足以下距离约束:

$$d(\mathbf{o}_i, O_j) \geq d_{safe}, \forall O_j \in \mathcal{O} \quad (4-1)$$

$$\|\mathbf{o}_i - \mathbf{o}_j\| \geq d_{safe}, \forall i \neq j, u_i, u_j \in \mathcal{U} \quad (4-2)$$

其中 d_{safe} 为无人机与建筑物或无人机之间的最小安全距离, $d(o_i, o_j)$ 表示无人机到矩形建筑物 o_j 任意一侧的最小欧氏距离。




图4-1 城市作战场景集群区域覆盖示意图

Fig. 4-1 Urban combat scenario swarm area coverage diagram

4.2.2 优化问题

在所提城市作战场景中, 单个无人机的有效感知覆盖区域不仅受限于传感器自身的探测距离, 还受到建筑物遮挡和强电磁干扰的严重制约。为了准确评估覆盖效果, 本文首先定义需持续侦察的有效任务区域 $\mathcal{S}_{task}$, 该区域是总场景区域 $\mathcal{S}$ 排除建筑物占据空间以及干扰源形成的电磁禁区后的自由空间。设干扰源 J 在其周围形成半径为 R_J 的圆形干扰禁区 $\mathcal{S}_{jam}$, 则有效任务区域的形式化表达为:

$$\mathcal{S}_{task} = \mathcal{S} \setminus (\mathcal{O} \cup \mathcal{S}_{jam}) \quad (4-3)$$

考虑到城市建筑对视线的阻挡作用, 采用视距感知模型。对于任务区域 $\mathcal{S}_{task}$ 内的任意目标点 q , 该点被无人机 u_i 有效覆盖需同时满足两个条件: 一是点 q 位于无人机的感知半径内; 二是无人机位置 o_i 与点 q 之间的连线段不与任何建筑物 $o_j \in \mathcal{O}$ 相交。为此, 定义二值视距函数 $L(o_i, q)$ 如下:

$$L(\mathbf{o}_i, \mathbf{q}) = \begin{cases} 1, & \text{若线段 } \overline{\mathbf{o}_i \mathbf{q}} \cap \mathcal{O} = \emptyset \\ 0, & \text{其他} \end{cases} \quad (4-4)$$

因此单架无人机 u_i 对应位置 $\mathbf{o}_i$ 的有效覆盖区域 $\mathcal{C}(\mathbf{o}_i)$ 定义为满足几何距离与视距约束的点集：

$$\mathcal{C}(\mathbf{o}_i) = \{\mathbf{q} \in \mathcal{S}_{task} \mid \|\mathbf{o}_i - \mathbf{q}\| \leq R_s \wedge L(\mathbf{o}_i, \mathbf{q}) = 1\} \quad (4-5)$$

无人机集群对任务区域的联合覆盖范围是所有个体有效覆盖区域的并集。为了量化评估部署方案的覆盖性能，本文将区域覆盖目标 f_{cov} 定义为联合有效覆盖面积与有效任务区域总面积的比值。该指标反映了集群对目标区域的覆盖程度指标，其计算公式为：

$$f_{cov} = \frac{S(\cup_{i=1}^N \mathcal{C}(\mathbf{o}_i))}{S_{task}} \quad (4-6)$$

为了确保无人机集群在执行任务过程中能够维持稳定的数据传输与协同控制，需建立通信网络模型并对其网络连通性能进行量化。首先将无人机集群的通信拓扑建模为无向图 $G = (\mathcal{U}, \mathcal{E})$ ，其中节点集合 $\mathcal{U}$ 代表所有无人机，边集合 $\mathcal{E}$ 包含所有满足通信链路建立条件的连接。

根据 3.2.2 节所述的通信模型，两架无人机节点 u_i 与 u_j 之间存在边 $(u_i, u_j) \in \mathcal{E}$ ，当且仅当其物理距离、视距条件以及接收端的信干噪比均满足双向通信要求。图 G 的连通性能通过代数连通度 $\lambda_2(G)$ 描述。 $\lambda_2(G)$ 可以代表网络在该状态下抵抗节点故障、链路中断或遭受攻击而不发生网络分裂的能力。考虑到代数连通度的大小与网络节点规模 N 呈正相关，为了在多目标优化过程中消除规模量级的影响，本文采用归一化代数连通度 $\bar{\lambda}_2(G)$ 作为衡量优化的网络连通目标 f_{con} ：

$$f_{con} = \bar{\lambda}_2(G) = \frac{\lambda_2(G)}{N} \quad (4-7)$$

综合上述场景建模、覆盖模型与连通模型，本文研究的通信保持区域覆盖部署问题被构建为一个带有复杂几何与拓扑约束的多目标优化问题。优化的决策变量为无人机集群的二维部署坐标集合 X ：

$$X = \{\mathbf{o}_1, \mathbf{o}_2, \dots, \mathbf{o}_N\}, \quad \mathbf{o}_i \in \mathcal{S}_{task} \quad (4-8)$$

该多目标优化问题的总目标是在严格满足物理安全与基础信道约束的前提下，寻找一组帕累托最优部署方案，使得任务区域的有效覆盖率和网络的归一化代数连通度达到最大化。该优化问题的数学模型可表述如下：

$$\text{Max} \quad F(X) = [f_{cov}(X), f_{con}(X)]^T \quad (4-9)$$

$$\text{s. t.} \quad d(\mathbf{o}_i, \mathbf{o}_j) \geq d_{safe}, \forall \mathbf{o}_j \in \mathcal{O} \quad (4-10)$$

$$\|\mathbf{o}_i - \mathbf{o}_j\| \geq d_{safe}, \forall i \neq j, u_i, u_j \in \mathcal{U} \quad (4-11)$$

上述约束分别对应：障碍物避障安全约束、无人机间防撞安全约束。这是一个典型的非线性、非凸、多约束的 NP-hard 问题，一般通过启发式算法进行求解。

4.3 多种群引导协同进化算法

本节围绕所提出的多种群引导协同进化算法 MPG-NSGA-II 的具体实现展开介绍。针对复杂城市环境下无人机集群覆盖与连通耦合的多目标优化问题，算法在 NSGA-II 框架基础上进行了改进，通过引入种群多样性初始化方法、面向覆盖与连通的局部引导变异算子以及多种群精英迁移机制，在全局探索与局部开发之间实现有效平衡，从而提升算法的收敛性能与解集质量。具体而言，本节将从所提算法的总体架构、种群多样性初始化方法、局部引导变异算子及多种群精英迁移机制四个方面进行详细阐述。

4.3.1 多种群引导协同进化总体架构

所提算法通过构建异构子种群协同进化机制，并融合基于领域知识的启发式引导变异算子进行多目标优化框架设计，旨在平衡全局探索与局部开发能力，提升算法在复杂环境约束下的收敛速度与解集质量。所提 MPG-NSGA-II 算法的总体架构基于多种群 NSGA-II 算法，将总规模为 n 的种群划分为三个功能异构的子种群，分别负责执行优化方向不同的进化搜索。其中子种群 P_1 为主导种群，采用常规多项式变异以维持种群的全局多样性；子种群 P_2 和 P_3 分别为覆盖导向变异与连通导向变异子群，专注于覆盖和连通目标的专门化搜索。

所提算法总体框架如图 4-2 所示，整体步骤主要分为初始化种群与分配、子种群变异进化和种群精英迁移三个部分。首先在初始化种群阶段，针对传统随机初始化或者拉丁超立方采样 (Latin Hypercube Sampling, LHS) 处理高维复杂问题时初始化种群质量差的问题，设计了一种基于连通-贪心覆盖的混合初始化方法 (Connectivity-Greedy Coverage Initialization, CGCI) 进行种群初始化并分配至对应的子种群。然后在子种群变异进化阶段，每一代进化中，各子种群独立进行选择、交叉与变异操作。其中选择策略采取二元竞标赛机制，交叉策略采用模拟二进制交叉机制。针对单一多项式变异算子效率低的问题，分别设计了基于领域知识的引导变异算子。其中子种群 P_1 采用传统多项式变异算子，覆盖引导子种群 P_2 采用所设计的 Voronoi 覆盖引导变异算子，连通引导子种群 P_3 采用所提的基于节点度的连通引导变异算子，该机制通过利用场景中先验的几何与拓扑特性进行变异引导以提高搜索效率。在种群精英迁移阶段，各个子种群进化固定代数后，根据多种群协同进化思想和迁移岛模型思想^[84]，为促进种群间交互，通过

基于非支配排序与拥挤度距离的精英迁移机制更新各种群对应比例的部分精英个体。该算法通过设计基于领域知识的覆盖和连通引导变异算子，实现了多种群协同进化与搜索，能够有效提高算法的搜索效率。




图4-2 MPG-NSGA-II 算法总体架构

Fig. 4-2 Overall framework of MPG-NSGA-II algorithm

4.3.2 种群多样性初始化方法

区别于传统随机初始化或者拉丁超立方采样初始化方法，本节提出一种基于连通-贪心覆盖的混合初始化方法 CGCI，通过不同权重权衡覆盖与连通性能进行种群中不同个体的初始化，构建兼具高目标值与多样性的初始种群。为实现初始化种群的多样性，本文参考 MOEA/D 的权重向量机制^[84]，首先为种群中每个个体在连通-覆盖目标空间对应一个预设单位权重向量 $w = (w_{cov}, w_{con})$ ，每个单位权重向量代表该个体在初始化时的连通或覆盖倾向。具体而言，种群中第 i 个个体对应的单位权重向量参照 MOEA/D 的均匀权重向量生成方式进行赋值。对于规模为 n 的种群，第 i 个个体的权重向量按如下公式均匀生成：

$$w_{i,cov} = \frac{i}{n}, w_{i,con} = 1 - w_{i,cov}, \quad i = 1, 2, \dots, n \quad (4-12)$$

该预设方式使 n 个个体的权重向量在覆盖-连通目标空间的单位单纯形上均匀分布，使得种群中的个体从纯覆盖目标到纯连通目标呈梯度分布，从而在初始化阶段保证种群在目标空间中的均匀多样性。

然后在初始化阶段，连通-贪心覆盖的混合初始化方法将根据每个个体在目标空间

中的预设单位权重向量动态切换个体的初始化方式：当对应个体的覆盖权重 $w_{cov} > w_{th}$ 时，采用贪心覆盖初始化策略并根据权重自适应生成高覆盖目标的初始化个体；当连通权重 $w_{con} > w_{th}$ 时采用聚集连通初始化策略并根据权重自适应生成高连通目标的初始化个体。在此基础上，本节后续将分别介绍贪心覆盖初始化策略和聚集连通初始化策略的具体实现方法。

4.3.2.1 贪心覆盖初始化策略

贪心覆盖初始化策略旨在生成覆盖性能优异且具有多样性的初始个体。具体而言，算法通过维护待覆盖区域与无人机节点位置集合 $\mathcal{U}$ ，通过最大化单步无人机部署带来的覆盖增益进行节点部署位置的顺序确定。对于第 j 个无人机的候选位置 $\mathbf{o}_j \in \mathcal{S}_{task}$ ，其覆盖目标增益 $\Delta(\mathbf{o}_j)$ 定义为：

$$\Delta(\mathbf{o}_j) = |\{\mathbf{q} \in \mathcal{S}_{task} \setminus \mathcal{S}_{cov} \mid \|\mathbf{o}_j - \mathbf{q}\| \leq R_s \wedge L(\mathbf{o}_j, \mathbf{q}) = 1\}| \quad (4-13)$$

其中对应的 $\mathcal{S}_{cov}$ 表示已经实现覆盖的区域集合。该算法通过 N 次迭代每次选择覆盖目标增益最大的位置直至所有节点的部署位置都得到确定，从而求解得到基础贪心解 X_{greedy} 。在此基础上，为避免种群中不同个体的同质化，该算法引入基于对应个体预设目标权重的扰动机制。对于第 i 个个体的第 j 个无人机节点，其对应的位置 $\mathbf{o}_{ij}$ 为：

$$\mathbf{o}_{ij} = \mathbf{o}_j + \sigma_i(\cos\theta, \sin\theta) \quad (4-14)$$

$$\sigma_i = \sigma_{max} \left(1 - (w_{i,cov} - w_{th})\right) \quad (4-15)$$

其中 σ_{max} 为最大扰动幅值， $\theta \sim U[0, 2\pi)$ 为随机生成的扰动方向角， $w_{i,cov}$ 为对应第 i 个个体的覆盖权重。该自适应扰动机制确保了不同覆盖权重个体的多样性与局部探索能力，具体的算法实现如算法 3 所示。

算法 3: 贪心覆盖初始化算法

输入：任务区域 $\mathcal{S}_{task}$ ，无人机数量 N ，种群规模 n ，覆盖权重阈值 w_{th} ，最大扰动

σ_{max}

输出：基础贪心解 X_{greedy} ，扰动后初始种群 P

1: $\mathcal{U} \leftarrow \emptyset$

2: $\mathcal{S}_{cov} \leftarrow \emptyset$

3: $j \leftarrow 1$

4: while $j \leq N$ do

```

5:   生成所有未占用位置集合  $\mathbf{o}_j$ 
6:   for each  $\mathbf{o}_j$  in  $\mathbf{o}_j$  do
7:        $\Delta(\mathbf{o}_j) \leftarrow \mathbf{q} \in \mathcal{S}_{task} \setminus \mathcal{S}_{cov}: \|\mathbf{o}_j - \mathbf{q}\| \leq R_s \wedge L[\mathbf{o}_j, \mathbf{q}] = 1$ 
8:        $g(\mathbf{o}_j) \leftarrow |\Delta(\mathbf{o}_j)|$ 
9:   end for
10:   $\mathbf{o}_j^{best} \leftarrow \operatorname{argmax}_{\mathbf{o}_j} g(\mathbf{o}_j)$ 
11:   $U \leftarrow U \cup \mathbf{o}_j^{best}$ 
12:   $\mathcal{S}_{cov} \leftarrow \mathcal{S}_{cov} \cup \Delta(\mathbf{o}_j^{best})$ 
13:   $j \leftarrow j + 1$ 
14: end while
15:  $X_{greedy} \leftarrow U$ 
16: //初始化覆盖导向子种群
17: for  $i \leftarrow 1$  to  $n \cdot w_{th}$  do
18:      $w[i] = (\frac{i}{n}, 1 - \frac{i}{n})$ 
19:      $\sigma_i \leftarrow \sigma_{max} * (1 - w[i][0]) / (1 - w_{th})$ 
20:     for  $j \leftarrow 1$  to  $N$  do
21:          $\mathbf{o}_j \leftarrow X_{greedy}[j]$ 
22:          $\theta \leftarrow U(0, 2\pi)$ 
23:          $\mathbf{o}_{ij} \leftarrow \mathbf{o}_j + \sigma_i \cdot (\cos\theta, \sin\theta)$ 
24:     end for
25: end for

```

4.3.2.2 聚集连通初始化策略

聚集连通初始化策略旨在生成连通性能优异且具有多样性的初始个体。具体而言，针对 $w_{cov} \leq w_{th}$ 的连通导向个体，采用聚集连通初始化策略生成具备密集网络拓扑的不同初始个体。该算法首先为第 i 个个体在干扰源 J 的干扰禁区外随机选取安全中心 $\mathbf{c}_i$ ，满足 $\|\mathbf{c}_i - \mathbf{p}\| \geq R_j$ 。然后根据对应第 i 个体的单位权重向量确定聚集半径 r_i ：

$$r_i = r_{min} + (r_{max} - r_{min}) \cdot \frac{w_{i,cov}}{w_{th}} \quad (4-16)$$

其中 r_{min} 和 r_{max} 为根据环境定义的聚集半径参数。则第 i 个个体的第 j 个无人机的位置 $\mathbf{o}_{ij}$ 在以 $\mathbf{c}_i$ 为圆心、 r_i 为半径的区域内按照均匀分布随机生成：

$$\mathbf{o}_{ij} = \mathbf{c}_i + r_{ij}(\cos \theta, \sin \theta) \quad (4-17)$$

$$r_{ij} \sim U(0, r_i], \theta \sim U[0, 2\pi) \quad (4-18)$$

该聚集连通初始化策略通过根据每个个体的自适应单位权重向量和聚集半径能够有效提高初始解个体的连通目标效果和多样性。

4.3.3 局部引导变异算子

为解决传统的多项式变异的高随机性和搜索效率低的问题，所提算法设计了基于区域覆盖领域知识的局部引导变异算子，包括 Voronoi 覆盖引导算子 VCGO 和节点度连通引导算子 DCGO 两部分。该机制通过利用当前个体的覆盖与拓扑特征获取局部启发式引导变异向量，实现优化对应目标的定向变异进化，从而有效提高算法的搜索效果与性能。

4.3.3.1 Voronoi 覆盖引导算子

覆盖导向子种群 P_2 采用 Voronoi 覆盖引导算子作为种群交叉后的变异算子，该算子利用确定性方法中的 Voronoi 图划分方法，根据当前个体部署情况下的每个无人机的责任区域进行对应的质心与变异向量的计算。

首先，在给定的邻居半径 R_{nbr} 约束下，为无人机 u_i 构造其局部邻居集合：

$$N_i = \{u_j \in \mathcal{U} \setminus u_i \mid \|\mathbf{o}_i - \mathbf{o}_j\| \leq R_{nbr}\} \quad (4-19)$$

即在该半径内的所有无人机均视为 u_i 的邻居节点。在得到邻居集合 N_i 后，可基于局部 Voronoi 划分确定无人机在任务区域中的几何责任区域。对任意目标点 $\mathbf{q} \in \mathcal{S}_{task}$ ，定义其到当前节点及邻居节点的几何距离为：

$$d_i(\mathbf{q}) = \|\mathbf{q} - \mathbf{o}_i\|, d_j(\mathbf{q}) = \|\mathbf{q} - \mathbf{o}_j\|, \forall u_j \in N_i \quad (4-20)$$

则由局部邻居确定的 Voronoi 责任区域 $\mathcal{V}_i$ 定义为：

$$\mathcal{V}_i = \{\mathbf{q} \in \mathcal{S}_{task} \mid d_i(\mathbf{q}) \leq d_j(\mathbf{q}), \forall u_j \in N_i\} \quad (4-21)$$

几何上，区域 $\mathcal{V}_i$ 是由 u_i 与各邻居节点之间连线的垂直平分线所围成的多边形，其边界在示意图中对应为若干条垂直平分线段的组合。需要指出的是，在存在建筑物遮挡的城市场景中，责任区域 $\mathcal{V}_i$ 内并非所有区域都应由当前无人机负责：对于位于建筑物背面无视距的位置，即使其到 u_i 的几何距离最小，实际也无法被该无人机有效感知。因此，本文在 Voronoi 图的基础上进一步引入视距修正规则，定义无人机 u_i 的可见责任区域

（视距 Voronoi 区域）为:

$$\tilde{\mathcal{V}}_i = \{ \mathbf{q} \in \mathcal{V}_i \mid L(\mathbf{o}_i, \mathbf{q}) = 1 \} \quad (4-22)$$

即从几何责任区域 $\mathcal{V}_i$ 中排除所有视距函数为零的点（包括建筑体占据空间以及建筑物背后的遮挡区域）。如图 4-3 所示展示了基于视距 Voronoi 引导的覆盖定向变异的过程。




图4-3 Voronoi 覆盖引导算子原理示意图

Fig. 4-3 Schematic diagram of the Voronoi coverage guided operator

该机制利用建筑轮廓从 $\mathcal{V}_i$ 中去除建筑物本身的占据区域，然后沿从 $\mathbf{o}_i$ 指向建筑外轮廓顶点的射线，标记出被建筑遮挡的背面扇区，将其从 $\mathcal{V}_i$ 中去除，剩余部分即为 $\tilde{\mathcal{V}}_i$ 。在得到修正后的责任区域 $\tilde{\mathcal{V}}_i$ 后，Voronoi 覆盖引导算子以其几何质心作为当前节点的期望目标位置。质心 $\mathbf{c}_i$ 定义为:

$$\mathbf{c}_i = \frac{1}{|\tilde{\mathcal{V}}_i|} \int_{\tilde{\mathcal{V}}_i} \mathbf{q} d\mathbf{q}, \quad \mathbf{c}_i \in \mathbb{R}^2. \quad (4-23)$$

由上述公式计算的质心可以获得对应无人机 u_i 的覆盖引导变异的方向向量 $\mathbf{g}_i^{cov}$ 为由 $\mathbf{o}_i$ 指向质心的单位向量 $\frac{\mathbf{c}_i - \mathbf{o}_i}{\|\mathbf{c}_i - \mathbf{o}_i\|}$ 。可在满足安全约束与视距约束的前提下，使各无人机分别朝向其视距 Voronoi 责任区域的中心质点进行定向变异，从而提升对区域整体

覆盖均匀性与效率。每次变异优先选取 $\beta \cdot n_2$ 个节点执行覆盖引导变异，以实现在变异率灵活可调的同时提高覆盖引导变异的增益：

$$\mathbf{o}_i^m = \mathbf{o}_i + \mathbf{g}_i^{cov} \cdot S_{max} \cdot |\delta_q| \quad (4-24)$$

其中 S_{max} 为设定的变异步长上界， δ_q 为常规多项式变异变量，在 4.3.3.3 节将给出。

4.3.3.2 节点度连通引导算子

连通导向子种群 P_3 采用基于节点度的连通引导算子 DCGO 进行启发式的定向变异。该算子通过网络拓扑计算，获取当前部署解中对应弱连通的节点（度值 d_i 较小的无人机节点）并引导其向网络中心的最易修复链路进行变异。

该机制首先对当前部署位置下根据 SINR 以及门限建立无人机及网络图 G ，然后按照无人机节点度数从低到高进行排序，确定每个无人机发生变异的优先级。每次变异优先选取 $\beta \cdot n_3$ 个节点执行连通引导变异，以实现在变异率灵活可调的同时提高连通引导变异的增益。如图 4-4 展示了对应 3 个度数最低的节点引导变异的示意图。




图4-4 节点度连通引导算子原理示意图

Fig. 4-4 Schematic diagram of the degree connectivity guided operator

具体而言, 对于需要进行变异的低度数节点 u_i , 先后遍历其对应的单跳链路进行搜索满足 SINR 接近阈值 γ_{th} 的非邻接节点 u_{j^*} 作为修复目标:

$$u_{j^*} = \arg \min_j (\gamma_{th} - SINR_{ij}) \quad \text{s.t.} \quad A_{ij} = 0 \quad (4-25)$$

若存在 u_{j^*} , 则连通梯度 g_i^{conn} 指向 o_{j^*} :

$$g_i^{conn} = \frac{o_{j^*} - o_i}{\|o_{j^*} - o_i\|} \quad (4-26)$$

否则, 连通梯度指向集群虚拟中心 $\bar{p}$:

$$g_i^{conn} = \bar{p} = \frac{1}{N} \sum_{i=1}^N o_i \quad (4-27)$$

从而获取变异后的无人机位置向量:

$$o_i^m = o_i + g_i^{conn} \cdot S_{max} \cdot |\delta_q| \quad (4-28)$$

该机制能够有效定向引导节点进行断裂链路的修复, 局部启发式提高网络的代数连通度目标, 增强无人机集群在复杂城市环境下的通信可靠性。

4.3.3.3 多项式变异算子

主导子种群 P_1 沿用标准的实数编码多项式变异算子 PM 以维持种群的遗传多样性, 通过随机扰动保持全局探索能力, 防止因过度依赖局部定向变异而陷入局部最优。与覆盖引导变异算子 VCGO 和连通引导变异算子 DCGO 基于特定覆盖部署先验知识的定向引导不同, 多项式变异通过在个体当前位置附近施加服从特定多项式概率分布的随机扰动来实现非定向的探索。这种机制确保了算法在解空间中具备足够的全局搜索能力, 防止陷入局部最优。

多项式变异对无人机位置向量的每一个维度独立进行。对于无人机 u_i 的当前位置 o_i , 设 $o_{i,k}$ 为其在第 k 维空间上的坐标值 (本场景表示二维平面上的横坐标或纵坐标), 其变异后的坐标值 $o'_{i,k}$ 定义为:

$$o'_{i,k} = o_{i,k} + \delta_{i,k} \cdot (o_k^{max} - o_k^{min}) \quad (4-29)$$

其中, o_k^{max} 和 o_k^{min} 分别表示无人机在第 k 维度上允许的搜索空间上界和下界, 这一项确保了变异扰动的尺度与搜索空间的范围相适应。

$\delta_{i,k}$ 为该维度上的多项式扰动因子, 其值是一个服从特定分布的随机变量, 由在区间 $[0,1]$ 内均匀分布的随机数 u_k 和分布指数 η_m 共同决定, 计算公式如下:

$$\delta_{i,k} = \begin{cases} (2u_k)^{\frac{1}{\eta_m+1}} - 1, & \text{if } u_k \leq 0.5 \\ 1 - (2(1 - u_k))^{\frac{1}{\eta_m+1}}, & \text{if } u_k > 0.5 \end{cases} \quad (4-30)$$

其中分布指数 η_m 是控制变异扰动强度的关键参数,它决定了扰动概率密度函数的形状尖锐程度。较大的 η_m 值使得 $\delta_{i,k}$ 较高的概率集中在 0 附近,从而产生微小的位移,有利于局部精细化搜索(有利于开发);反之,较小的 η_m 值使分布更平坦,增加了产生较大 $\delta_{i,k}$ 值的概率,有利于大范围的跳跃式搜索(有利于探索)。通过调节 η_m ,可以有效地平衡算法的全局探索与局部开发能力。

4.3.4 多种群精英迁移机制

多种群精英迁移机制是所提 MPG-NSGA-II 算法实现不同变异算子对应子种群间协同进化的核心机制。该机制按预定比例采用多样化精英迁移策略,每隔固定代数执行子种群间精英个体交换,实现搜索结果的共享和优势互补,避免算法早熟收敛和陷入局部最优,以提高算法的整体搜索性能。

迁移机制采取经典的岛模型(Island Model)^[85],在考虑个体交换与优化目标需求的基础上,对应迁移规则进行如下设计:(1)局部引导变异子种群(覆盖导向子种群 P_2 和连通导向子种群 P_3)的精英个体迁移到主种群 P_1 ,以提高主种群的解的质量和多样性;(2)主种群 P_1 的部分精英个体(第一前沿解的一定比例个体随机选择)迁移到局部引导变异子种群 P_2 和 P_3 ,为局部引导搜索提供多样的优质解,进一步推进前沿搜索的同时防止子种群陷入局部最优;(3)局部引导变异子种群 P_2 和 P_3 按照对应种群目标排序后进行一定比例优质个体的相互迁移,为当前目标下的优质解提供不同方向的搜索策略进行进化。

所提多种群精英迁移机制的具体执行过程如下:首先,对每个子种群 $P_i(i \in \{1, 2, 3\})$ 进行独立的质量评估,按照 NSGA-II 的非支配排序等级和拥挤度距离对各子种群独立进行综合排序。对于子种群 P_i ,算法执行非支配排序得到非支配前沿序列 $\mathcal{F}_1^{(i)}, \mathcal{F}_2^{(i)}, \dots, \mathcal{F}_k^{(i)}$,然后计算各前沿的拥挤度距离,最后根据非支配排序等级和拥挤度距离进行综合排序。排序规则为首先按照帕累托前沿等级升序排列,帕累托前沿等级相同时按拥挤度距离降序排列。排序后的个体索引序列记为 idx_i ,其中 $idx_i[0]$ 表示质量最高的个体, $idx_i[n_i - 1]$ 表示质量最低的个体。在排序完成后将按照预先定义的对比例参数计算各方向的迁移数量。所提算法定义了三个迁移比例参数: $r_{P1 \leftrightarrow P2}$ 、 $r_{P1 \leftrightarrow P3}$ 和 $r_{P2 \leftrightarrow P3}$ (一般取 0.1-0.2)。各方向的迁移数量因种群规模不同而不相同,按照对应公式计算:

$$n_{P2 \rightarrow P1} = [n_1 \cdot r_{P1 \leftrightarrow P2}], \quad n_{P3 \rightarrow P1} = [n_1 \cdot r_{P1 \leftrightarrow P3}] \quad (4-31)$$

$$n_{P1 \rightarrow P2} = [n_2 \cdot r_{P1 \leftrightarrow P2}], \quad n_{P1 \rightarrow P3} = [n_3 \cdot r_{P1 \leftrightarrow P3}] \quad (4-32)$$

$$n_{P2 \rightarrow P3} = [n_3 \cdot r_{P2 \leftrightarrow P3}], \quad n_{P3 \rightarrow P2} = [n_2 \cdot r_{P2 \leftrightarrow P3}] \quad (4-33)$$

为了确保迁移操作的可行性,算法还需对计算得到的迁移数量进行边界约束,确保

迁移数量不超过源子种群的可用个体数和目标子种群的可替换位置。如图 4-5 所示展示了对应多种群之间迁移机制的示意图。




图4-5 多种群精英迁移机制示意图

Fig. 4-5 Schematic diagram of the multi-population elite migration mechanism

具体而言，迁移操作按以下特定顺序执行，以避免替换冲突。

(1) 执行从引导变异子种群到主种群的迁移：将 P_2 中排序前 $n_{P2 \rightarrow P1}$ 的优质个体迁移到 P_1 ，替换 P_1 中排序后 $n_{P2 \rightarrow P1}$ 的质量较差的个体；然后将 P_3 中排序前 $n_{P3 \rightarrow P1}$ 的优质个体迁移到 P_1 ，替换 P_1 中从位置 $n_1 - n_{P2 \rightarrow P1} - n_{P3 \rightarrow P1}$ 到位置 $n_1 - n_{P2 \rightarrow P1}$ 的劣质个体，避开已被 P_2 迁移替换的位置防止覆盖。

(2) 执行从主种群到引导变异子种群的迁移：从 P_1 的第一前沿 $\mathcal{F}_1^{(1)}$ 中随机选择 $n_{P1 \rightarrow P2}$ 和 $n_{P1 \rightarrow P3}$ 个个体，分别迁移到 P_2 和 P_3 ，替换它们排序靠后的较差个体。

(3) 执行引导变异子种群之间的相互迁移：与主种群相关的迁移中的排序策略不同，局部引导变异子种群的待迁移个体按照对应的导向目的排序进行替换。对于覆盖引导子种群 P_2 ，其接收连通引导子种群中的连通目标最高的 $n_{P3 \rightarrow P2}$ 个个体，替换自身覆盖目标最低的 $n_{P3 \rightarrow P2}$ 个个体，对于连通引导子种群 P_3 ，其接收覆盖引导子种群中的覆盖目标最高的 $n_{P2 \rightarrow P3}$ 个个体，替换自身连通目标最低的 $n_{P2 \rightarrow P3}$ 个个体，从而实现不同引导策略的种群之间的迁移。

总体而言，该机制通过按比例控制迁移规模，实现了子种群间搜索经验的共享，具有周期性、针对性和协同性等优势。后续实验结果将表明，迁移重组机制能够显著提高

算法的收敛速度和解集质量。

4.4 仿真实验与结果分析

为验证所提 MPG-NSGA-II 算法实际性能与有效性,本节首先介绍仿真场景参数与算法参数设置,然后从所设计的启发式变异机制的有效性、典型场景下的解收敛过程与前沿质量、连通性与覆盖性能和多参数场景稳定性等四个方面对所提算法的性能进行系统分析与验证。

4.4.1 仿真实验设置

本节从仿真场景参数和算法相关参数两个方面对实验参数设置进行说明。在仿真场景方面,作战区域建模为边长 1 km 的正方形二维平面,区域中随机分布若干建筑物以及干扰源,无人机相关参数主要包括集群规模、单机覆盖半径及发射功率,其中覆盖半径决定了无人机对局部环境的侦察范围,发射功率决定了无人机节点间的有效通信距离。所有仿真场景相关参数的具体取值如表 4-1 所示。

表4-1 区域覆盖仿真参数设置

Table 4-1 Simulation parameter settings for area coverage		
参数名称	符号/说明	值
地图尺寸	$L_x \times L_y$	1km x 1km
建筑数量	M	10
无人机数量	N	15 ~ 25
无人机发射功率	P_i	25 dBm
覆盖半径	R_s	150m
SINR 阈值	γ_{th}	10 dB
干扰源位置	o_j	(100m, 900m)
干扰源发射功率	P_j	25 dBm
干扰禁区半径	R_j	150m

算法相关参数设置具体如表 4-2 所示。NSGA-II 算法相关参数需设定种群规模、最大迭代代数、交叉概率与变异概率等核心参数,其中种群规模影响解的多样性,交叉与变异概率则平衡算法的全局搜索与局部开发能力。所提 MPG-NSGA-II 算法相关参数包括种群多样性初始化设置、子种群规模、迁移比例和迁移周期等参数,参考 NSGA-II 及多种群岛模型的经验参数进行合理设置。

表4-2 NSGA-II 和 MPG-NSGA-II 算法参数设置

Table 4-2 Parameter settings of NSGA-II and MPG-NSGA-II algorithms

参数名称	符号/说明	值
种群规模	n	200
子种群 P1 规模	n_1	120
子种群 P2 规模	n_2	40
子种群 P3 规模	n_3	40
最大迭代代数	MaxGen	1000
迁移周期	T_{mig}	40
SBX 交叉概率	p_c	0.9
多项式变异概率	p_m	0.1
SBX 交叉分布指数	η_c	20.0
多项式变异分布指数	η_m	20.0
P1 和 P2 迁移比例	$r_{P1 \leftrightarrow P2}$	0.1
P1 和 P3 迁移比例	$r_{P1 \leftrightarrow P3}$	0.1
P2 和 P3 迁移比例	$r_{P2 \leftrightarrow P3}$	0.1
覆盖连通初始化门限	w_{th}	0.5
覆盖扰动幅值	σ_{max}	100m
连通初始化范围	r_{min}, r_{max}	150m, 300m
局部引导变异比例	β	0.1
变异步长幅值	S_{max}	150m

4.4.2 仿真结果分析

本节基于所搭建的仿真场景展开全面的实验验证。首先验证本文所设计的启发式变异算子在提升覆盖率与连通度两项目标上的作用机制与有效性。在此基础上，面向不同规模的无人机节点场景，引入超体积 HV、均匀性指标 Δ 、间距指标 SP 等指标，对不同算法所求帕累托前沿的收敛性与分布均匀性进行定量对比。最后，进一步对比分析各算法在满足不同的顶点连通约束条件下实际覆盖效果的差异，以证明所提算法在复杂环境下的优势。

4.4.2.1 引导变异机制有效性分析

针对传统多项式变异高随机性与低搜索效率的不足，所提算法系统结合了基于区域覆盖与通信网络的领域知识，并基于此设计了对应的局部引导变异算子机制。该机制利用当前个体的覆盖特征与拓扑状态获取局部启发式变异向量，实现定向变异与进化，以提升算法的搜索效果与收敛速度。本节以 25 架无人机节点的典型城市环境仿真场景为例，实际分析所设计的启发式变异算子在引导种群逼近帕累托前沿过程中的作用机制。

首先是采用 Voronoi 覆盖引导算子 VCGO 的子种群，主要利用基于局部 Voronoi 划分与视距遮挡修正的方法，计算各无人机有效责任区域的几何质心，并以此作为启发式变异的方向。图 4-6 展示了所提算法在典型场景中运行至第 200 代时覆盖导向变异的实际执行情况。其中红色五角星为干扰源，灰色矩形代表城市建筑物，而黑色五角星精确标识了由视距 Voronoi 责任区域计算得出的有效责任区域质心。从图中可以观察到，被选中的对应比例的无人机节点（蓝色圆点）产生的变异向量（红色箭头）精准地指向了各自对应的区域质心。图中标记的变异方向表明，Voronoi 覆盖引导算子 VCGO 能够根据无人机当前位置的局部几何分布与建筑遮挡情况，计算出指向责任区域的启发式变异向量。这种机制驱使无人机主动向未被有效覆盖的视距 Voronoi 责任区域中心移动，从而在迭代过程中高效地消除覆盖盲区，显著加速了集群整体覆盖率目标的优化进程。




图4-6 代数= 200 时覆盖引导变异机制图

Fig. 4-6 Coverage-guided mutation mechanism at generation = 200

对于采用基于节点度连通引导算子 DCGO 的子种群，通过提取网络节点度特征，引导弱连通节点向最易修复链路的方向进行定向变异。如图 4-7 所示，蓝色线条代表当前满足信干噪比阈值的有效通信链路（简化后图中仅显示对应变异节点的通信链路）。图

中发生变异的节点是对应比例的节点度数最小的边缘节点或弱连通节点。变异向量的指向严格遵循了节点度连通引导变异算子 DCGO 的设计逻辑：对于存在潜在可修复单跳链路的节点，其变异方向明确指向使得 SINR 接近阈值的非邻接节点；而对于局部无直接修复目标的孤立或边缘节点，则产生指向集群虚拟中心的连通向量。图中幅度为 0.32 和 8.44 的变异向量分别对应节点度为 1 和节点度为 4 的无人机节点，直观地展示了该机制引导低度数节点向网络主体靠拢或与邻近节点建立新链路的过程。这种基于网络拓扑先验知识的定向修复，避免了随机变异带来的低效，显著加快了网络连通这一目标的收敛速度。




图4-7 代数= 200 时连通导向变异机制图

Fig. 4-7 Connectivity-guided mutation mechanism at generation = 200

作为对比，图 4-8 展示了主导子种群采用常规实数编码多项式变异 PM 时的状态。与 Voronoi 覆盖引导变异算子 VCGO 和节点度连通引导变异算子 DCGO 不同，多项式变异对无人机位置向量施加的是基于概率分布的随机扰动。从图中可以看出，红色变异向量的方向呈现出完全的随机散布状态，对于实际目标的优化效率相对更低。




图4-8 代数= 200 时多项式变异机制图

Fig. 4-8 Polynomial mutation mechanism at generation = 200

综合上述实际迭代过程中的机制表现可知，单一的多项式变异通过高随机性能够有效维持种群的遗传多样性并提供全局探索能力，但在高维复杂搜索空间中直接提高特定连通或覆盖目标的效率较低。本算法所提的 Voronoi 覆盖引导变异算子 VCGO 和节点连通引导变异算子 DCGO 两个局部引导变异算子，结合现有区域覆盖领域的先验知识为算法引入了强大的局部开发能力，使得算法在保持全局探索能力的前提下，通过启发式的定向变异大幅加快了种群向真实帕累托前沿进化的速度并提升了搜索效果，从而能够有效提升算法在多目标优化问题上的整体性能。

4.4.2.2 收敛性与前沿质量分析

为了全面评估所提算法在不同规模集群下的多目标优化性能，本节构建了包含 15、20 和 25 个无人机节点（分别对应空间位置求解的 30、40 和 50 维连续决策变量）的典型城市作战仿真场景。分别采用现有的 NSGA-II 算法和本文所提的 MPG-NSGA-II 算法进行相同代数的迭代进化，统计迭代过程中的超体积变化曲线并进行对比，并对两种

算法在覆盖率与归一化代数连通度双目标优化问题上的帕累托前沿解集质量进行对比分析。

本节从 HV 收敛趋势与最终帕累托前沿解集分布两个维度，对各场景下两种算法的性能进行对比分析。在 15 个节点（30 维变量）的场景中，两种算法的 HV 迭代指标以及帕累托前沿解集分布对比如图 4-9 所示。




图4-9 15 节点场景下解集和迭代效果对比

Fig. 4-9 Comparison of solution sets and convergence performance in the 15-node scenario

从 HV 迭代曲线可以看出，MPG-NSGA-II 在迭代初期呈现出极其陡峭的上升趋势，并迅速拉开与 NSGA-II 的差距。这种加速收敛特性主要源于 Voronoi 覆盖引导与节点度连通引导机制的协同作用有效降低了算法在高维搜索空间中的无效随机搜索开销，加快了向帕累托前沿逼近的速度。随着迭代推进，所提算法能够持续优化种群，使 HV 指标稳步提升。由帕累托前沿分布图直观可见，MPG-NSGA-II（红色虚线）求得的前沿解集在整体上显著支配了传统 NSGA-II 算法（绿色实线）。在覆盖率大于 0.85 的高覆盖目标区间内，MPG-NSGA-II 能够在该区间内获得覆盖率与连通度均更优的前沿解，这表明在同等节点资源下，本文算法能探索到覆盖与连通更为优化的部署方案。

当集群规模扩大至 20 个节点时，算法需要优化的连续决策变量提升至 40 维，搜索空间维度相应提升至 40 维。在这种搜索空间下，传统非定向多项式变异的随机游走策略极易在庞大的搜索空间中陷入局部最优。如图 4-10 (a) 的 HV 收敛曲线所示，传统 NSGA-II 算法在迭代至 200 代左右时便出现了明显的收敛停滞现象，最终 HV 值仅能达到约 0.85，并且在后续的迭代过程中难以实现有效提升，陷入局部最优。如图 4-10 (b) 所示的前沿解集分布也反映出该问题，NSGA-II 求解的前沿解集在高连通和高

覆盖的区域解质量明显差于所提算法，无法提供高质量的部署方案。相比之下，MPG-NSGA-II 依然保持了极其优越的推进效果。凭借局部拓扑修复与覆盖引导的双重启发式机制，算法能够在高维空间中准确把握优化方向。即使面对节点数增加带来复杂的城市障碍物遮挡关系，算法依然能有效维持种群进化，防止算法陷入局部最优，最终 HV 值稳定在 0.91 左右。其帕累托前沿在目标空间中分布更加连续，且在高覆盖端与高连通端均延伸至更优的目标值区域，为决策者提供了更为丰富的战术部署方案。




图4-10 20 节点场景下解集和迭代效果对比

Fig. 4-10 Comparison of solution sets and convergence performance in the 20-node scenario

在 25 节点的大规模场景下，决策变量达到 50 维，节点间连通关系耦合、建筑遮挡以及覆盖重叠的现象更为复杂，求解难度大幅度增加。如图 4-11 所示，MPG-NSGA-II 在该极端场景下依然展示出卓越的收敛鲁棒性。尽管在迭代后期，受限于过于严苛的物理空间约束，算法的跃升幅度有所放缓，但其求得的最终解集依然在连通性保障与区域覆盖最大化上取得了优于 NSGA-II 的均衡性能。传统算法在此规模下求得的解集难以逼近最优前沿，而本文算法通过引导节点扩大覆盖（VCGO 作用）并主动修复孤立集群（DCGO 作用），成功提高了高密度部署下的优化效果，显著提升了大规模集群的宏观协同效能。




图4-11 25 节点场景下解集和迭代效果对比

Fig. 4-11 Comparison of solution sets and convergence performance in the 25-node scenario

为进一步定量评估解集质量，表 4-3 列出了两种算法在各节点规模场景下迭代结束后的前沿解集规模 N 、超体积 HV 、均匀性指标 Δ 与间距指标 SP 。

表4-3 不同节点规模下性能指标对比

Table 4-3 Comparison of metrics under different node scales

节点数	算法	N	HV	$Spread(\Delta)$	$Spacing(SP)$
15	MPG-NSGA-II	75	0.930917	0.967244	0.015991
15	NSGA-II	85	0.847761	0.983063	0.016084
20	MPG-NSGA-II	143	0.911168	0.947098	0.008569
20	NSGA-II	139	0.859698	0.980020	0.009461
25	MPG-NSGA-II	165	0.934231	0.944926	0.008539
25	NSGA-II	146	0.870960	0.991162	0.008572

对表中数据进行分析主要可以得出以下两方面的结论：

(1) 从前沿解集规模 N 与超体积 HV 指标来看，在 15、20 和 25 节点规模下，本文所提 MPG-NSGA-II 算法在不同规模场景中均取得了更高的 HV 值，体现出更优的解集收敛性与质量。具体而言，在 15 节点场景下，MPG-NSGA-II 的解集规模为 75，低于 NSGA-II 的 85，但其 HV 值达到 0.930917，显著优于 NSGA-II 的 0.847761；在 20 节点场景中，MPG-NSGA-II 的 N 为 143，略高于 NSGA-II 的 139，同时 HV 为 0.911168，相较于 NSGA-II 的 0.859698 仍具有明显优势；在 25 节点场景下，MPG-NSGA-II 的 N 为 165，高于 NSGA-II 的 146，且 HV 提升至 0.934231，对比 NSGA-II

II 的 0.870960 优势进一步扩大。上述结果表明, MPG-NSGA-II 并非单纯依赖增加解集规模来提升性能, 而是通过启发式引导变异与多种群协同机制, 有效提升了解集质量, 使其在保持合理解集规模的同时获得更优的整体优化性能。

(2) 从均匀性指标 Spread 与间距指标 Spacing 来看, MPG-NSGA-II 在不同规模场景下整体表现出更优或更稳定的分布特性。在 15 节点场景中, MPG-NSGA-II 的 Spread 为 0.967244, 优于 NSGA-II 的 0.983063, 同时 Spacing 为 0.015991, 略优于 NSGA-II 的 0.016084, 表明其解集分布更加均匀, 且在目标空间中具有更好的分布广度; 在 20 节点场景下, MPG-NSGA-II 的 Spread (0.947098) 明显优于 NSGA-II (0.980020), Spacing (0.008569) 亦优于 NSGA-II (0.009461), 说明其在中等规模下能够兼顾分布广度与均匀性; 在 25 节点场景中, MPG-NSGA-II 的 Spread 为 0.944926, 相较 NSGA-II 的 0.991162 仍具有明显优势, 而两者在 Spacing 指标上接近 (分别为 0.008539 与 0.008572), 表明在较大规模下两种算法均能维持一定的分布均匀性, 但 MPG-NSGA-II 在整体分布质量与前沿延展能力方面仍更具优势。综合来看, 本文算法能够在提升解集质量的同时, 有效克服了传统 NSGA-II 在高维搜索空间中易出现的解集分布不均与退化问题, 从而获得更加均衡且具有代表性的帕累托解集。

综上所述, MPG-NSGA-II 算法在不同节点规模下均表现出稳定且显著优于传统 NSGA-II 的多目标优化性能。从 HV 指标的持续提升与帕累托前沿的整体支配优势可以看出, 所提算法在高维复杂搜索空间中具备更强的全局搜索能力与收敛效率。同时, 在解集规模并未显著增加的情况下, MPG-NSGA-II 仍能够获得更高质量的帕累托解集。结合均匀性指标和间距结果, 说明该算法不仅能够有效逼近真实帕累托前沿, 还能在保证分布均匀性的同时拓展解集的覆盖范围。随着节点规模的增加, 传统 NSGA-II 在搜索过程中逐渐表现出收敛停滞与解集退化的问题, 而 MPG-NSGA-II 依然能够维持稳定的优化性能, 展现出良好的规模适应能力与鲁棒性。上述优势主要得益于启发式引导变异机制与多种群协同进化策略的协同作用, 前者提升局部搜索精度, 后者增强全局探索能力, 二者共同实现了全局探索与局部开发的有效平衡。

4.4.2.3 连通性与覆盖性能分析

在现代城市作战环境中, 无人机节点极易遭到敌方电磁干扰或火力物理摧毁。因此, 单纯依赖归一化代数连通度难以准确衡量网络在实战环境下的节点抗毁损能力。为此, 本节利用图论中的顶点连通度 (k -连通性) 对解集进行评估。 k -连通性表示网络在任意移除 $k-1$ 个节点后仍保持连通的特性, 能够更直接地衡量网络在城市作战场景下的抗毁损能力, 为不同算法的部署方案提供更具工程意义的对比依据。由于覆盖范围与

代数连通度在本质上是相互竞争的目标, 本节进一步提取前沿解集中在不同 k -连通约束下对应的最大覆盖率, 以直观呈现算法的工程应用价值。

图 4-12 展示了在不同节点规模 (15、20 和 25 节点) 下, 两种算法在不同顶点连通度约束条件下的最大覆盖性能对比。从整体趋势来看, 随着节点数量的增加, 无人机集群可用于覆盖与通信骨干构建的无人机资源同步增加, 使得在相同连通度约束下的最大覆盖率整体呈现上升趋势。同时, 在各节点规模下, 随着顶点连通度的不断提高, 覆盖率均呈现单调下降趋势, 这是由于更高的连通冗余要求迫使更多节点用于维持网络结构, 从而压缩了可用于扩展覆盖边界的自由度。然而, 相较于传统 NSGA-II 算法, 所提的 MPG-NSGA-II 算法在各节点规模下均能够维持更高的覆盖水平, 其优势在高连通约束区域尤为显著, 体现出更优的连通-覆盖协同优化能力。

具体而言, 在 15 节点场景下, 受无人机资源数量限制, 连通性与覆盖率之间的冲突最为突出。由图 4-12 (a) 可见, 当顶点连通度由低 (如 $k=1\sim3$) 逐步提升至高 (如 $k=6\sim8$) 时, 两种算法的覆盖率均由接近 0.9 以上逐步下降至约 0.6 左右甚至更低。但在整个变化过程中, MPG-NSGA-II 始终保持对 NSGA-II 的稳定优势, 在中高连通区间内通常可获得约 5% 的覆盖率提升。这表明在资源紧张条件下, 所提算法能够更高效地协调节点分布, 在保证基本连通性的同时尽可能扩大有效覆盖区域。在 20 节点场景下, 随着无人机数量增加, 集群在覆盖与连通之间具备更大的协调空间。由图 4-12 (b) 可见, 在低连通度区域, 两种算法均可达到约 0.9 以上的高覆盖水平; 而在高连通约束 (如 $k\geq 6$) 下, 覆盖率下降趋势依然存在, 但所提的 MPG-NSGA-II 算法的下降幅度明显小于 NSGA-II 算法。在关键的中高连通区间, 所提算法相较传统方法可稳定提升约 5% - 10% 的覆盖性能, 说明其在中等规模场景下能够更有效地利用新增节点资源, 在维持网络鲁棒性的同时减少覆盖损失。在 25 节点的大规模场景下, 系统整体性能进一步提升。由图 4-12 (c) 可见, 在低连通约束下, 两种算法均可实现接近 1.0 的覆盖率, 而随着连通度提升, 覆盖率逐步下降至约 0.7 左右。然而, MPG-NSGA-II 在整个连通度区间内均显著优于 NSGA-II, 尤其在高连通要求 (如 $k\geq 7$) 下, 其覆盖优势进一步扩大, 提升幅度可达约 10% 甚至更高。这表明在高维复杂约束环境下, 所提算法能够有效避免传统方法中因节点冗余连接导致的空间利用率下降问题, 实现更优的全局资源配置。

综上所述, 所提的 MPG-NSGA-II 算法在不同节点规模及不同连通约束条件下均展现出更优的覆盖保持能力, 尤其在高连通、高约束场景中优势更加突出。这充分验证了所提算法在复杂环境下实现连通性保障与覆盖性能最大化协同优化方面的有效性与稳定性。




图4-12 不同节点数量下顶点连通度与覆盖性能分析

Fig. 4-12 Analysis of vertex connectivity and coverage performance under different node numbers

为更直观地对比相同场景下，不同抗毁强度约束（不同的顶点连通度）下所需的无人机集群部署规模，图 4-13 给出了节点规模 $N = 15 \sim 25$ 的无人机集群在顶点连通度 $k = 0 \sim 10$ 约束下的最大覆盖率性能边界。整体来看，随着节点数量的增加，系统可用于覆盖与通信骨干构建的无人机数量显著增加，使得在各连通度约束下的最大覆盖率整体呈现上升趋势。然而，该提升效果并非线性增长，而是随着节点规模的扩大逐渐减弱，即由低节点规模向中等规模过渡时覆盖性能提升显著，而在高节点规模（如 $N \geq 23$ ）时，进一步增加节点所带来的覆盖增益逐渐趋于饱和，体现出典型的边际收益递减特性。

从顶点连通度角度分析，在 $k = 0$ （不考虑连通约束）时，各节点规模均可获得较高覆盖率，且随节点数增加呈现明显提升趋势，由 $N = 15$ 时约 90% 提升至 $N = 23$ 以上时接近或达到 100%，此时节点资源仅用于最大化覆盖区域。当连通度提升至 $k = 1$

时, 各曲线出现小幅下降, 但整体趋势与 $k = 0$ 类似, 覆盖率随节点数增加稳步提升, 且在 $N \geq 23$ 时已基本稳定在 99% 左右。进一步地, 在 $k=2 \sim 5$ 的中等连通约束下, 覆盖率下降趋势更加明显, 但不同节点规模之间仍保持稳定间隔, 表明节点增加能够有效弥补连通性约束带来的覆盖损失。而在高连通约束 ($k=6 \sim 10$) 下, 覆盖率整体下降至约 85%~98% 区间, 但随着节点数增加, 曲线间差距逐渐缩小, 说明在高冗余通信要求下, 节点资源更多被用于维持网络结构, 覆盖性能提升空间受到限制。




图4-13 不同节点数目下网络顶点连通度和覆盖性能分析

Fig. 4-13 Analysis of network vertex connectivity and coverage performance under different node numbers

从节点规模角度分析, 可以进一步观察不同覆盖目标所需的最小节点规模。当以覆盖率达到 99% 作为性能阈值时, 在低连通约束 ($k=0 \sim 2$) 下, 仅需约 $N=22 \sim 23$ 即可满足要求; 在中等连通约束 ($k=3 \sim 5$) 下, 则需增加至约 $N=23 \sim 24$; 而在较高连通要求 ($k \geq 6$) 下, 需要 25 架无人机规模才能达到 99% 覆盖率, 表明高强度抗毁损约束对系统资源提出了更高要求。同时可以看到, 当节点数从 15 增加至 20 时, 覆盖率提升幅度较大, 而从 23 增加至 25 时, 提升幅度明显减小, 进一步验证了节点规模扩展的边际效益递减特性。

针对前述多目标优化算法获取的解集, 图 4-14 展示了 25 节点规模下, 集群在 0、

5、10 顶点连通度约束下的实际部署方案对比。




图4-14 不同顶点连通度下部署方案

Fig. 4-14 Deployment strategies under different vertex connectivity

实验结果表明，在不同连通性需求下，所提算法均展现出较高的区域覆盖性能。当节点规模 $N = 25$ 时，该部署方案在所有连通度约束下均能保障区域覆盖率达到 99% 以上，有效实现了对监测区域的高覆盖率部署。随着顶点连通度的增加，网络拓扑结构显著趋于复杂，节点间的通信链路密度大幅提升，从而增强了集群在应对节点故障或强

干扰环境下的鲁棒性。在 $k = 10$ 的高连通度约束场景下，由于节点位置需高度聚集以满足严苛的连通性要求，局部区域不可避免地出现了少量覆盖盲区，但整体盲区占比极低，仍保持了 99% 左右的极高覆盖水平。观察部署拓扑可知，所提算法在优化过程中有效平衡了连通冗余与空间分布均匀性，使无人机在满足高连通度约束的同时，仍能向覆盖盲区方向延伸，有效降低建筑遮挡造成的阴影区比例。

综上所述，节点数量的增加能够显著提升无人机集群在不同连通约束下的覆盖性能，但其增益随规模扩大逐渐减弱，体现出资源利用效率的阶段性特征。结合图 4-12 与图 4-13 的结果可以看出，所提 MPG-NSGA-II 算法在不同节点规模及连通约束下均能获得平滑且高质量的性能边界，能够在保证网络鲁棒性的同时最大化覆盖效率，展现出良好的规模适应性与综合优化能力。

4.4.2.4 多参数场景稳定性分析

为全面评估所提算法在不同场景下的稳定性与有效性，本节分别从建筑数量、干扰节点数量和场景尺寸三个关键参数出发构建更为复杂的城市作战仿真场景，其中建筑数量为 40 的场景用于测试高建筑密度场景下的性能；干扰节点数量为 3 的场景用于测试强干扰场景下的性能；场景尺寸为 $1.5\text{km} \times 1.5\text{km}$ 的场景用于测试更大规模与更高优化维度场景下的性能。采用现有的 NSGA-II 算法和本文所提的 MPG-NSGA-II 算法进行相同代数的迭代进化，统计各算法帕累托前沿解集在不同顶点连通度约束下的最大覆盖率，并给出部分典型部署方案。

首先，在高建筑密度场景下，在原典型参数保持不变的基础上，将建筑物数量由 20 增加至 40，以构建更加复杂的空间约束环境，对应求解结果如图 4-15 所示。由图 4-15 (a) 可以看出，在不同顶点连通度约束下，所提 MPG-NSGA-II 算法在覆盖性能上整体优于传统 NSGA-II 算法，尤其在较高连通度要求（如 $k \geq 3$ ）时优势更加明显。随着建筑物数量增加，场景中建筑遮挡效应加剧，有效视距范围进一步压缩，通信链路建立难度提高，导致传统算法在高约束条件下难以同时兼顾覆盖与连通性目标，表现为覆盖率下降较快。而所提算法通过 VCGO 与 DCGO 算子分别引导节点填补覆盖盲区与修复弱连通链路，能够有效识别关键节点并优化其部署位置，从而在复杂障碍环境中维持较优的覆盖水平。图 4-15 (b) 所示的 $k = 1$ 部署方案进一步验证了上述分析。在高密度建筑环境中，所提算法生成的无人机分布更加均匀，且关键节点之间形成稳定的多跳通信链路结构，在保证全局连通性的同时有效覆盖狭窄边缘区域。相比之下，NSGA-II 算法易出现覆盖盲区，部分节点承担过多中继任务，导致网络结构稳定性较差。因此，在高建筑密度场景下，所提算法在复杂空间约束与通信连通性耦合条件下仍能够保持较高

覆盖性能与网络结构稳定性，体现出更强的环境适应能力与鲁棒性。




图4-15 高建筑密度场景算法对比

Fig. 4-15 Comparison of algorithms in high building-density scenario

其次，在强干扰场景下，在原典型参数保持不变的基础上，将干扰源数量由 1 增加至 3，分别在场景右上与右下区域新增干扰节点，以增强电磁环境的复杂度，对应求解结果如图 4-16 所示。由图 4-16 (a) 可以看出，随着干扰源数量的增加，算法的覆盖性能相对单个干扰节点场景均有所下降，但所提 MPG-NSGA-II 算法在不同顶点连通度约束下始终保持更高的覆盖率，且下降幅度相对较缓。这是由于多干扰源叠加使更多区域受到电磁干扰，通信链路建立难度显著增加，传统 NSGA-II 算法在进化过程中难以有效搜索满足通信约束的可行解，导致所求部署方案中连通链路易断裂。而所提算法通过 DCGO 引导低度节点向可修复链路方向定向移动，从而在规避干扰区域的同时重建有效通信链路，从而提高网络整体连通目标。由图 4-16 (b) 可见，在对应场景的 $k = 1$ 部署方案中，所提算法能够在干扰区域附近找到合理的无人机部署位置，使无人机的通信链路既避开强干扰区域，又能保证关键区域的覆盖。而传统算法则更容易在干扰区域附近形成断裂链路或覆盖缺失。因此，在强电磁干扰环境下，所提算法在相同顶点连通度约束下能够保持更高的覆盖率，验证了其在复杂电磁环境中的适用性与稳定性。




图4-16 强干扰场景算法对比

Fig. 4-16 Comparison of algorithms in strong interference scenario

最后，在大规模场景下，将区域尺寸扩展为 $1.5 \text{ km} \times 1.5 \text{ km}$ ，无人机数量增加至 50 架（对应 100 维优化变量）。为保持建筑密度与典型场景基本一致，建筑数量相应设为 40 栋，以验证算法在更大空间尺度下的性能表现，对应求解结果如图 4-17 所示。由图 4-17 (a) 可以看出，在场景尺度扩展后，算法的覆盖性能均有所下降，但所提 MPG-NSGA-II 算法在各顶点连通度约束下仍保持领先优势。随着空间尺度增大，节点间平均距离增加，通信链路更易断裂，导致连通目标更加难以优化。传统 NSGA-II 算法在此条件下往往需要牺牲覆盖性能以维持连通结构，而所提算法通过多种群协同进化机制，在全局探索与局部开发之间实现更有效的平衡，从而在保证连通性的同时提升覆盖效率。由图 4-17 (b) 所示的 $k = 9$ 的部署方案可见，在更大规模场景中，所提算法能够形成合理的节点分布，实现覆盖性能与连通性的协同优化。而传统算法生成的解则更容易出现链路稀疏或局部冗余的问题，导致整体效率下降。

综上所述，在高建筑密度、强干扰及大规模等多参数场景下，所提算法均能保持稳定的优化性能，在覆盖率与连通性指标上持续优于对比算法，体现出较强的规模适应能力与工程应用潜力。




图4-17 大规模场景算法对比

Fig. 4-17 Comparison of algorithms in large-scale scenario

4.5 本章小结

本章针对复杂城市作战环境下无人机集群区域覆盖侦察部署的多目标优化问题进行了系统建模与算法设计。首先，针对城市建筑物遮挡与强电磁干扰并存的场景，构建了基于视距约束的感知覆盖模型与基于城市信道路径损耗和信干噪比门限的网络连通模型，并将其建模为以最大化区域覆盖率和归一化代数连通度为目标的复杂高维多目标优化问题。然后，提出了一种基于多种群引导协同进化的通信保持区域覆盖算法 MPG-NSGA-II。其中，在初始化阶段引入了连通-贪心覆盖混合策略以保障初始种群的质量与多样性；在进化迭代阶段，通过构建多种群协同进化架构，设计了基于先验几何与网络拓扑知识的 Voronoi 覆盖引导算子与节点度连通引导算子，并实现对应的多种群精英迁移机制，有效平衡了全局探索与局部开发能力。最后，通过在不同参数配置的仿真场景下开展对比实验，对算法性能进行了系统验证。实验结果表明，所提算法在收敛速度、解集分布质量、不同连通约束下的覆盖性能及多参数场景适应性等方面均显著优于对比算法，达到了预期的优化效果。

第五章 总结与展望

5.1 全文总结

本文立足于未来城市作战中大规模无人机集群智能协同的迫切需求,深入考虑了高密度建筑遮挡与强电磁干扰对集群通信拓扑的显著制约作用,针对现有作战任务规划方法在通信约束建模方面的不足,以及算法在高维复杂场景下易陷入局部最优的问题,将无人机集群通信连通保持作为核心优化目标,系统性地构建了复杂城市环境下的无人机路径规划与区域覆盖优化算法框架,从算法设计层面提升了无人机集群在复杂约束环境下的任务执行能力。本文的核心研究成果与理论价值可总结为以下两个方面:

(1) 在通信保持路径规划方面,创新性地提出了分层分簇的 C-RRT*-APF 通信保持路径规划算法,有效降低了传统势场法在大规模集群场景中易出现的局部死锁与路径振荡风险。本研究通过设计分层机制将基于采样的路径规划算法和人工势场法进行结合,在全局规划层,创新性地将簇间距离作为全局路径约束基础,为跨簇通信网络的维持提供了抗干扰保障;在局部规划层,通过动态提取最大信干噪比瓶颈生成树,仅对网络拓扑中的主干链路设计通信保持引力,避免了传统全连接邻居势场方法导致多源势场复杂耦合的问题。该机制显著减少了多源势场叠加引发的振荡与死锁现象。仿真实验表明,所提算法不仅在密集建筑障碍环境中保障了集群飞行安全,高效完成了路径规划任务,更在强干扰条件下维持了显著高于对比算法的通信保持性能。

(2) 在区域覆盖侦察部署方面,创新性地提出了基于多种群引导协同进化的 MPG-NSGA-II 算法,有效克服了传统多目标进化算法在求解此类复杂高维问题时搜索效率不足的缺陷。针对视距受限与干扰叠加的复杂城市作战场景,本研究将传统确定性覆盖方法与通信网络拓扑的领域知识融合于 NSGA-II 多目标优化框架。具体而言,针对变异机制,本算法设计了面向覆盖与连通目标的启发式局部引导变异算子。其中 Voronoi 覆盖引导算子 VCGO 能够通过计算责任区域质心以高效填补覆盖盲区,节点度连通引导算子 DCGO 通过定向修复弱连通链路以高效增强网络连通性。同时所提算法采用多种群岛模型精英迁移策略促进不同目标导向的子种群在固定周期内实现多种群协同进化。仿真实验性能评估表明该算法在全局探索与局部开发之间取得了平衡,所求帕累托前沿在超体积、分布均匀性等多项指标上均显著优于对比算法,验证了所提领域先验知识引导的启发式进化机制在提升多目标优化收敛性与解集质量方面的有效性。

综上所述,本文所构建的综合城市作战环境模型与任务模型,不仅为复杂城市环境下无人机集群通信保持与任务规划的联合建模提供了系统性的方法框架,更为高复杂干扰条件下的无人机集群自主路径规划及区域覆盖组网提供了切实可行的算法支撑,对推进智能无人机集群作战体系的工程化应用具有重要的参考价值。

5.2 不足与展望

尽管本文在复杂城市作战环境下的无人机集群通信保持任务规划方面取得了具有理论与工程意义的成果,但受限于现有条件,在环境建模维度、算法工程化应用等方面仍存在一定局限。为推动该技术向实战化方向演进,未来的研究工作可从以下三个方面展开:

(1) 环境拓展与复杂性提升:目前研究主要基于二维静态场景,未来可将其拓展至三维连续空间,并引入高机动的动态干扰源(如伴随式干扰机)。结合现有算法, **C-RRT*** 的搜索空间需扩展至三维(增加高度维度),局部人工势场应升级为三维模型;同时,针对动态干扰,簇间距离约束需引入自适应机制,局部规划 **MBST-APF** 应结合干扰轨迹预测来提前调整通信引力,从而提升三维高动态对抗下的拓扑重构能力。

(2) 优化目标与任务约束增加:现有模型尚未显式考虑无人机电池能耗等潜在约束。未来研究应建立包含飞行推进能耗与通信能耗的综合能耗模型,在算法扩展上,可在 **MPG-NSGA-II** 框架内将集群能耗最小化或能量均衡作为额外优化目标,并在局部引导算子中增加剩余电量评估,以保障覆盖任务持续有效执行。在 **C-RRT*-APF** 中,可将能耗指标直接纳入全局 **C-RRT*** 的节点代价函数,以实现兼顾通信稳定与低能耗的路径规划目标。

(3) 实物验证与实际工程落地:当前性能评估依赖理想化的纯软件仿真,通信与感知模型较为简化,且对底层动力学约束的考虑相对有限。后续研究需结合物理硬件开展半物理仿真或多机实飞测试。具体而言,需将 **MBST-APF** 生成的航点序列与 **ROS** 等飞控系统融合,验证真实动力学延迟下的系统稳定性;同时,利用真实复杂信道下实测的信噪比数据,校准 **MPG-NSGA-II** 连通引导算子的判定阈值,有效弥补仿真与物理环境的差异。

通过以上多个方面的研究,可进一步提升智能无人机集群的综合协同作战能力,为未来城市作战场景下无人机集群智能化组网与任务规划系统的工程化发展提供理论与方法参考。

参 考 文 献

- [1] 薛健, 赵琳, 向贤财, 等. 非完全信息下无人机集群对抗研究综述[J]. 电子与信息学报, 2024, 46: 1157 – 1172.
- [2] HAN Y, LIU H, WANG Y, et al. A Comprehensive Review for Typical Applications Based Upon Unmanned Aerial Vehicle Platform[J]. IEEE J Sel Top Appl Earth Observ Remote Sens, 2022, 15: 9654–9666.
- [3] JAVAID S, SAEED N, QADIR Z, et al. Communication and Control in Collaborative UAVs: Recent Advances and Future Trends[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(6): 5719–5739.
- [4] 贾高伟, 王建峰. 无人机集群任务规划方法研究综述[J]. 系统工程与电子技术, 2021, 43: 99–111.
- [5] ZHANG Z, JIANG J, LING K V, et al. Cooperative Path Planning for Heterogeneous UAV Swarms: A Stackelberg Game Approach[J]. IEEE Transactions on Automation Science and Engineering, 2025, 22: 18531–18548.
- [6] HAN J, YAN Y, ZHANG B. Towards Efficient Multi-UAV Air Combat: An Intention Inference and Sparse Transmission Based Multiagent Reinforcement Learning Algorithm[J]. IEEE Transactions on Artificial Intelligence, 2025, 6(12): 3441–3452.
- [7] WU J, ZHANG N, LI D, et al. A Context-Aware Feature Fusion Method for Multi-UAV Cooperative Air Combat[J]. IEEE Transactions on Intelligent Transportation Systems, 2025, 26(5): 7197–7210.
- [8] WU D, JIN C, YAO H, et al. Dynamic Routing Optimization Method for UAV Swarm Networks: An Evolutionary Game Approach[J]. IEEE Transactions on Sustainable Computing, 2025, 10(04): 616–627.
- [9] ZHOU Q, FENG H, LIU Y. Multigene and Improved Anti-Collision RRT* Algorithms for Unmanned Aerial Vehicle Task Allocation and Route Planning in an Urban Air Mobility Scenario[J]. Biomimetics, 2024, 9(3).
- [10] LADOSZ P, OH H, ZHENG G, et al. Gaussian Process Based Channel Prediction for Communication-Relay UAV in Urban Environments[J]. IEEE Transactions on Aerospace and Electronic Systems, 2020, 56(1): 313–325.
- [11] 庞强伟, 胡永江, 李文广. 基于垂直区域宽度分解的无人机覆盖航迹规划[J]. 系统工程与电子技术, 2019, 41(11): 2550 – 2558.
- [12] LIU D, ZHU X, BAO W, et al. SMART: Vision-Based Method of Cooperative Surveillance and Tracking by Multiple UAVs in the Urban Environment[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(12): 24941–24956.
- [13] 杨闰麟, 陈才轶, 郭正玉, 等. 基于 MATD3 的无人机智能协同路径规划方法[J]. 厦门大学学报(自然科学版), 2025, 64: 241 – 252.
- [14] LÓPEZ B, MUÑOZ J, QUEVEDO F, et al. 4D Trajectory Planning Based on Fast Marching Square for UAV Teams[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(6): 5703–

- 5717.
- [15] 刘京奥, 姜晓爱, 王永超, 等. 复杂环境下旋翼无人机集群协同多目标跟踪[J]. 北京航空航天大学学报, 1 - 25.
- [16] SOLEYMANI S A, GOUDARZI S, XIAO P, et al. Multiagent Q-Learning With Particle Filtering for UAV Tracking in Open-RAN Environment[J]. IEEE Transactions on Aerospace and Electronic Systems, 2025, 61(4): 10439–10458.
- [17] YAN P, GUO J, SU X, et al. Long-Term Tracking of Evasive Urban Target Based on Intention Inference and Deep Reinforcement Learning[J]. IEEE Transactions on Neural Networks and Learning Systems, 2024, 35(11): 16886–16900.
- [18] FEI C, LU Z, JIANG W. Heuristic Optimization-Based Trajectory Planning for UAV Swarms in Urban Target Strike Operations[J]. Drones-Basel, 2024, 8(12).
- [19] SU W, GAO M, GAO X, et al. A Decision-Making Method for Distributed Unmanned Aerial Vehicle Swarm considering Attack Constraints in the Cooperative Strike Phase[J]. International Journal of Aerospace Engineering, 2023, 2023.
- [20] OUBBATI O S, ATIQUZZAMAN M, BAZ A, et al. Dispatch of UAVs for Urban Vehicular Networks: A Deep Reinforcement Learning Approach[J]. IEEE Transactions on Vehicular Technology, 2021, 70(12): 13174–13189.
- [21] PRASAD N L, RAMKUMAR B. 3-D Deployment and Trajectory Planning for Relay Based UAV Assisted Cooperative Communication for Emergency Scenarios Using Dijkstra's Algorithm[J]. IEEE Transactions on Vehicular Technology, 2023, 72(4): 5049–5063.
- [22] RAHMAN M, SARKAR N, LUTUI R. A Survey on Multi-UAV Path Planning: Classification, Algorithms, Open Research Problems, and Future Directions[J]. Drones-Basel, 2025, 9(4).
- [23] AL-TURJMAN F, ZAHMATKESH H, AL-OQILY I, et al. Optimized Unmanned Aerial Vehicles Deployment for Static and Mobile Targets' Monitoring[J]. Comput Commun, 2020, 149: 27–35.
- [24] MESTRES A, RODRIGUEZ-NATAL A, CARNER J, et al. Knowledge-Defined Networking[J]. Acm Sigcomm Computer Communication Review, 2017, 47(3).
- [25] WIJESEKARA P A D S N, GUNAWARDENA S. A Comprehensive Survey on Knowledge-Defined Networking[J]. Telecom, 2023, 4(3): 477–596.
- [26] ZHOU Y, RAO B, WANG W. UAV Swarm Intelligence: Recent Advances and Future Trends[J]. IEEE Access, 2020, 8: 183856–183878.
- [27] DU Z, LUO C, MIN G, et al. A Survey on Autonomous and Intelligent Swarms of Uncrewed Aerial Vehicles (UAVs)[J]. IEEE Transactions on Intelligent Transportation Systems, 2025, 26(10): 14477–14500.
- [28] KHUWAJA A, CHEN Y, ZHAO N, et al. A Survey of Channel Modeling for UAV Communications[J]. Ieee Communications Surveys and Tutorials, 2018, 20(4): 2804–2821.
- [29] KHAWAJA W, GUVENC I, MATOLAK D, et al. A Survey of Air-to-Ground Propagation Channel Modeling for Unmanned Aerial Vehicles[J]. Ieee Communications Surveys and Tutorials, 2019, 21(3): 2361–2391.
- [30] SUPRAMONGKONSET J, DUANGSUWAN S, MAW M, et al. Empirical Path Loss Channel Characterization Based on Air-to-Air Ground Reflection Channel Modeling for UAV-Enabled

- Wireless Communications[J].Wireless Communications & Mobile Computing,2021,2021.
- [31] JAVED S, HASSAN A, AHMAD R, et al.State-of-the-Art and Future Research Challenges in UAV Swarms[J].Ieee Internet of Things Journal,2024,11(11): 19023–19045.
- [32] SHARON G, STERN R, FELNER A, et al.Conflict-based search for optimal multi-agent pathfinding[J].Artificial Intelligence,2015,21940–66.
- [33] KOTTINGER J, ALMAGOR S, LAHIJANIAN M, et al.Conflict-Based Search for Multi-Robot Motion Planning with Kinodynamic Constraints[C].In: ed. IEEE International Conference on Intelligent Robots and Systems,2022.13494–13499.
- [34] WANG Z, GONG H, NIE M, et al.Research on Multi-UAV Cooperative Dynamic Path Planning Algorithm Based on Conflict Search[J].Drones-Basel,2024,8(6).
- [35] HE W, QI X, LIU L.A novel hybrid particle swarm optimization for multi-UAV cooperate path planning[J].Applied Intelligence,2021,51(10): 7350–7364.
- [36] MENG Q, CHEN K, QU Q.PPSwarm: Multi-UAV Path Planning Based on Hybrid PSO in Complex Scenarios[J].Drones-Basel,2024,8(5).
- [37] GÜVEN I, YANMAZ E.Multi-objective path planning for multi-UAV connectivity and area coverage[J].Ad Hoc Networks,2024,160.
- [38] KHANEGHAEI M, ASADI D, EBRAHIMI B, et al.Intelligent hybrid optimization algorithms for multi-agent aerial robots path planning: review of the recent emerging trends and open research directions[J].Artificial Intelligence Review,2026.
- [39] 闫皎洁, 张锬石, 胡希平.基于强化学习的路径规划技术综述[J].计算机工程,2021,47: 16 – 25.
- [40] BAYERLEIN H, THEILE M, CACCAMO M, et al.Multi-UAV Path Planning for Wireless Data Harvesting With Deep Reinforcement Learning[J].Ieee Open Journal of the Communications Society,2021,21171–1187.
- [41] YU L, WU F, XU Z, et al.UAV path design with connectivity constraint based on deep reinforcement learning[J].Physical Communication,2022,52.
- [42] YUTING CHENG D L, W ERIC WONG, MAN ZHAO.Multi-UAV Collaborative Path Planning using Hierarchical Reinforcement Learning and Simulated Annealing[J].Int J Performability Eng,2022,18(7): 463–474.
- [43] LI W, XIONG Y, XIONG Q.Reinforcement Learning-Guided Particle Swarm Optimization for Multi-Objective Unmanned Aerial Vehicle Path Planning[J].Symmetry-Basel,2025,17(8).
- [44] ZHANG C, YAO W, ZUO Y, et al.Robust Multiple Unmanned Aerial Vehicle Network Design in a Dense Obstacle Environment[J].Drones-Basel,2023,7(8).
- [45] ZHU L, MA C, LI J, et al.Connectivity-Maintenance UAV Formation Control in Complex Environment[J].Drones-Basel,2023,7(4).
- [46] GONG J, JIANG B, MA Y, et al.Distributed Adaptive Fault-Tolerant Formation Control for Heterogeneous Multiagent Systems With Communication Link Faults[J].Ieee Transactions on Aerospace and Electronic Systems,2023,59(2): 784–795.
- [47] WEI H, LI S, LIU Z, et al.Multi-UAV Cooperation for Anti-jamming Communication[C].In: ed.1035–1040.
- [48] MA B, JI Y, FANG L.A Multi-UAV Formation Obstacle Avoidance Method Combined with

- Improved Simulated Annealing and an Adaptive Artificial Potential Field[J].Drones-Basel,2025,9(6).
- [49] CABREIRA T M, BRISOLARA L B, FERREIRA JR. P R.Survey on Coverage Path Planning with Unmanned Aerial Vehicles[J].Drones-Basel,2019,3(1): 4.
- [50] CHEN L, ZHANG Z, ZHOU L, et al.Efficient Deployment Optimization Design for Multi-UAV Cooperative Sensing System[J].Ieee Open Journal of Vehicular Technology,2025,62305–2316.
- [51] ZHU X, ZHAI L, LI N, et al.Multi-Objective Deployment Optimization of UAVs for Energy-Efficient Wireless Coverage[J].Ieee Transactions on Communications,2024,72(6): 3587–3601.
- [52] ZHANG X, DUAN L.Fast Deployment of UAV Networks for Optimal Wireless Coverage[J].IEEE Transactions on Mobile Computing,2019,18(3): 588–601.
- [53] SHARMA J, BHUTANI A.Review on Deployment, Coverage and Connectivity in Wireless Sensor Networks[C].In: ed.802–807.
- [54] ABDULWAHID H, MISHRA A.Deployment Optimization Algorithms in Wireless Sensor Networks for Smart Cities: A Systematic Mapping Study[J].Sensors,2022,22(14).
- [55] BOUALEMA A, DE RUNZ C, KHOLIDY H, et al.A New Classification of Target Coverage Models in WSNs, Survey and Algorithms and Future Directions[C].In: ed.:Springer Nature Singapore.249–261.
- [56] WU F, GUI Y, WANG Z, et al.A survey on barrier coverage with sensors[J].Frontiers of Computer Science,2016,10(6): 968–984.
- [57] MUHSEN D, SADIQ A, RAHEEM F.A Survey on Swarm Robotics for Area Coverage Problem[J].Algorithms,2024,17(1).
- [58] LI X, SAVKIN A.Networked Unmanned Aerial Vehicles for Surveillance and Monitoring: A Survey[J].Future Internet,2021,13(7).
- [59] 张海君, 夏清悦, 马旭, 等.6G 低空通信场景下无人机部署优化综述[J].航空学报,2025,46: 148 – 173.
- [60] HOWARD A, MATARIC M, SUKHATME G.Mobile sensor network deployment using potential fields: A distributed, scalable solution to the area coverage problem[C].In: ed.,2002.299–308.
- [61] LI X, MITTON N, RYL I, et al.Localized Sensor Self-deployment with Coverage Guarantee in Complex Environment[C].In: ed. Lecture Notes in Computer Science,2009.138–151.
- [62] MUSIKAWAN P, KONGSOROT Y, MUNEEAWANG P, et al.An enhanced obstacle-aware deployment scheme with an opposition-based competitive swarm optimizer for mobile WSNs[J].Expert Systems with Applications,2022,189.
- [63] KIM Y H, KIM C M, YANG D S, et al.Regular sensor deployment patterns for p-coverage and q-connectivity in wireless sensor networks[C].In: ed.290–295.
- [64] WANG G, CAO G, LA PORTA T, et al.Movement-assisted sensor deployment[C].In: ed. Ieee Infocom Series,2004.2469–2479.
- [65] RAHIMI Z, GHANBARI R, MOHAJERZADEH A, et al.3-D UAV Small Cell Base Station Positioning and Resource Allocation in Cellular Network: A Stochastic Optimization Approach[J].Ieee Internet of Things Journal,2024,11(6): 10951–10963.
- [66] CORTÉS J, MARTÍNEZ S, KARATAS T, et al.Coverage control for mobile sensing

- networks[J].Ieee Transactions on Robotics and Automation,2004,20(2): 243–255.
- [67] SCHWAGER M, SLOTINE J, RUS D, et al.Decentralized, adaptive control for coverage with networked robots[C].In: ed. IEEE International Conference on Robotics and Automation ICRA,2007.3289–+.
- [68] REZAEE H, SALVATO E, FENU G, et al.Resilient Coverage by Teams of Quadrotor UAVs: Theory and Experiments[J].IEEE Transactions on Control Systems Technology,2024,32(6): 2009–2022.
- [69] KENNEDY J, EBERHART R.Particle swarm optimization[C].In: ed.1942–1948 vol.1944.
- [70] STORN R, PRICE K.Differential Evolution – A Simple and Efficient Heuristic for global Optimization over Continuous Spaces[J].Journal of Global Optimization,1997,11(4): 341–359.
- [71] YOON Y, KIM Y.An Efficient Genetic Algorithm for Maximum Coverage Deployment in Wireless Sensor Networks[J].Ieee Transactions on Cybernetics,2013,43(5): 1473–1483.
- [72] WEN X, RUAN Y, LI Y, et al.Improved Genetic Algorithm based 3-D deployment of UAVs[J].Journal of Communications and Networks,2022,24(2): 223–231.
- [73] WANG X, WANG S.Hierarchical Deployment Optimization for Wireless Sensor Networks[J].Ieee Transactions on Mobile Computing,2011,10(7): 1028–1041.
- [74] YUHENG Z, LIYAN Z, CHUNPENG L.3-D Deployment Optimization of UAVs Based on Particle Swarm Algorithm[C].In: ed.954–957.
- [75] DAS V, BANERJEE A, NATH I, et al.Differential Evolution and Neural Network-Based Approach to Optimize Coverage Area of Wireless Sensor Network[J].SN Computer Science,2025,6(5): 506.
- [76] SENGUPTA S, DAS S, NASIR M, et al.Multi-objective node deployment in WSNs: In search of an optimal trade-off among coverage, lifetime, energy consumption, and connectivity[J].Engineering Applications of Artificial Intelligence,2013,26(1): 405–416.
- [77] NDAM NJOYAA, ABDOU W, DIPANDA A, et al.Optimization of sensor deployment using multi-objective evolutionary algorithms[J].Journal of Reliable Intelligent Environments,2016,2(4): 209–220.
- [78] KONSTANTINIDIS A, YANG K.Multi-objective energy-efficient dense deployment in Wireless Sensor Networks using a hybrid problem-specific MOEA/D[J].Applied Soft Computing,2011,11(6): 4117–4134.
- [79] THIRUGNANSAMBANDAM K, BHATTACHARYYA D, FRNDA J, et al.Augmented Node Placement Model in t-WSN Through Multiobjective Approach[J].Computers, Materials & Continua,2021,69(3): 3629–3644.
- [80] RADMANESH M, KUMAR M, GUENTERT P, et al.Overview of Path-Planning and Obstacle Avoidance Algorithms for UAVs: A Comparative Study[J].Unmanned Syst,2018,6(2): 95–118.
- [81] KAVRAKI L E, SVESTKA P, LATOMBE J C, et al.Probabilistic roadmaps for path planning in high-dimensional configuration spaces[J].IEEE Transactions on Robotics and Automation,1996,12(4): 566–580.
- [82] LAVALLE S M.Rapidly-exploring random trees : a new tool for path planning[J].The annual research report,1998.
- [83] KARAMAN S, FRAZZOLI E.Sampling-based algorithms for optimal motion planning[J].The

- international journal of robotics research,2011,30(7): 846–894.
- [84] ZHANG Q, LI H. MOEA/D: A Multiobjective Evolutionary Algorithm Based on Decomposition[J]. IEEE Transactions on Evolutionary Computation, 2007, 11(6): 712–731.
- [85] HOANG L H, LONG N V, PHUONG N N T, et al. Soft Computing: Biomedical and Related Applications [M]. Springer. 2021: 183–200.

攻读学位期间学术论文和科研成果目录

学术论文

[1] 第一作者. 复杂对抗环境下集群连通保持分簇路径规划[J]. 指挥与控制学报, 2026. (已录用)